

Fundamentos e Estatística Descritiva

Como resumir dados sem mentir — e por que quase todo resumo mente um pouco

Descrever dados é o primeiro ato de modelagem, não uma etapa preliminar. Toda medida-resumo é uma compressão com perda: este material mostra exatamente o que cada uma joga fora, quando isso é aceitável e quando destrói a decisão de negócio que depende dela.

Nível: Intermediário — requer Python; a estatística é construída do zero

Pre-requisitos: NumPy e pandas básicos

Carga sugerida: 6 a 8 horas (leitura + 3 notebooks)

Notebooks: 01-medidas-resumo · 02-robustez-e-outliers · 03-visualizacao-distribuicoes

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este capítulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. Tipos de variável: a decisão que vem antes de tudo	4
3. Medidas de posição	5
3.1 A média aritmética e o que ela realmente é	5
3.2 Médias que não são a aritmética	5
4. Medidas de dispersão	7
4.1 Variância, desvio-padrão e a correção de Bessel	7
4.2 Alternativas robustas	7
4.3 Coeficiente de variação	8
5. Momentos: assimetria e curtose	9
6. Quantis, percentis e o mundo real de SLA	10
6.1 Por que engenharia mede latência em p99, e não em média	10
7. Relação entre variáveis	11
7.1 Covariância e correlação de Pearson	11
7.2 Spearman e Kendall	11
7.3 O quarteto de Anscombe	12
8. Padronização e escala	13
9. Um protocolo de descrição que funciona	14
10. Formulário do capítulo	15
11. Erros que custam caro — checklist	16
12. Para ir além	17

1. Por que este capítulo existe

Existe uma crença confortável de que estatística descritiva é a parte fácil — a que se resolve com `df.describe()` antes de começar o trabalho "de verdade". Essa crença custa caro. Praticamente todo desastre de modelagem que eu já vi autopsiar tinha, na origem, um resumo mal interpretado: uma média calculada sobre uma distribuição bimodal, um desvio-padrão sobre uma cauda pesada, uma correlação sobre uma relação em forma de U.

Vale fixar a ideia central antes de qualquer fórmula:

DEFINICAO

Uma medida-resumo é uma função que colapsa n números em um só. Como $n > 1$, a função **não é injetora**: infinitas amostras diferentes produzem o mesmo resumo. Escolher um resumo é escolher **qual informação descartar**.

A pergunta profissional nunca é "qual é a média?". É "o que eu perco ao substituir estes 4 milhões de transações pela média delas, e essa perda é tolerável para a decisão que vou tomar?".

ANALOGIA

Um resumo estatístico é como a foto de uma cidade tirada de um avião a dez mil metros. A média diz onde fica o centro geográfico. O desvio-padrão diz o quanto a cidade se espalha. Nenhum dos dois diz que existe um rio cortando a cidade ao meio — e é o rio que determina onde você consegue construir. Histograma e quantis são o voo baixo.

1.1 O que você vai conseguir fazer ao final

- Escolher entre média, mediana e média aparada com um argumento técnico, não por hábito.
- Explicar por que a variância amostral divide por $n - 1$ e o que acontece se você esquecer disso.
- Ler assimetria e curtose como diagnóstico, e não como números decorativos.
- Definir SLAs em percentis e entender por que p99 é uma métrica de engenharia fundamentalmente diferente da média.
- Detectar, antes de modelar, os três padrões que mais quebram modelos: bimodalidade, cauda pesada e mistura de populações.

2. Tipos de variável: a decisão que vem antes de tudo

Antes de calcular qualquer coisa, é preciso saber que tipo de número está na sua mão. A taxonomia clássica de Stevens organiza as variáveis em quatro **escalas de medida**, e cada escala autoriza um conjunto diferente de operações.

Escala	Exemplo	O que faz sentido	O que não faz sentido
Nominal	UF, canal de aquisição	Contagem, moda, frequência	Média, ordenação
Ordinal	Nota NPS 1–5, rating de crédito AAA–D	Mediana, quantis, ordenação	Média (com ressalva), diferenças
Intervalar	Temperatura em °C, data	Média, diferença, desvio-padrão	Razão ("30 °C é o dobro de 15 °C" é falso)
Razão	Receita, latência, contagem	Tudo, inclusive razão e média geométrica	—

O erro mais comum e mais caro dessa tabela é tratar **ordinal como razão**. Uma nota de satisfação de 1 a 5 tem ordem, mas não tem distância definida: a diferença de experiência entre 1 e 2 não é a mesma entre 4 e 5. Calcular "NPS médio = 3,8" empilha uma suposição de equidistância que ninguém verificou.

ARMADILHA COMUM

Variáveis categóricas codificadas como inteiros (`estado = 1, 2, 3, ...`) passam despercebidas por qualquer `describe()`: o pandas calcula média, desvio-padrão e quantis sem reclamar. O output é sintaticamente válido e semanticamente lixo. Antes de qualquer análise, verifique o **dtype** e a **cardinalidade** de cada coluna.

Uma distinção adicional, ausente em Stevens mas decisiva na prática: variáveis **contadas** (inteiros não-negativos, com massa em zero) versus variáveis **medidas** (contínuas). Contagens quase nunca são simétricas e quase nunca são bem descritas por média $\pm$ desvio-padrão. Elas pedem Poisson, binomial negativa ou modelos com inflação de zeros — assunto do módulo de distribuições.

3. Medidas de posição

3.1 A média aritmética e o que ela realmente é

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

A média tem uma caracterização variacional que explica todo o seu comportamento — e que vale memorizar, porque ela reaparece em regressão, em redes neurais e em praticamente todo lugar onde se minimiza erro quadrático:

$$\bar{x} = \arg \min_c \sum_{i=1}^n (x_i - c)^2$$

Ou seja: **a média é o ponto que minimiza a soma dos erros quadráticos**. Como o erro é elevado ao quadrado, um ponto três vezes mais distante pesa nove vezes mais. Isso não é um defeito acidental; é a definição. A média é sensível a valores extremos *por construção*.

A mediana tem a caracterização análoga com erro absoluto:

$$\text{mediana}(x) = \arg \min_c \sum_{i=1}^n |x_i - c|$$

NOTA

Essa dualidade é a mesma que separa a função de perda MSE da MAE em regressão. Um modelo treinado com MSE prevê a **média** condicional; treinado com MAE, prevê a **mediana** condicional. Quando alguém reclama que "o modelo superestima na maioria dos casos mas o erro médio está ótimo", quase sempre a resposta está aqui.

3.2 Médias que não são a aritmética

Três médias aparecem com frequência no mercado e são sistematicamente usadas erradas.

Média geométrica — para taxas de crescimento compostas:

$$G = \left(\prod_{i=1}^n x_i \right)^{1/n} = \exp \left(\frac{1}{n} \sum_{i=1}^n \ln x_i \right)$$

Se uma carteira rende +50% num ano e −50% no seguinte, a média aritmética dos retornos é 0% — e você teria concluído, erradamente, que ficou no zero a zero. Na verdade $1,5 \times 0,5 = 0,75$: você perdeu 25%. A média geométrica dos fatores $(1,5 \times 0,5)^{1/2} \approx 0,866$ acerta a resposta.

Média harmônica — para taxas por unidade fixa (velocidade, throughput):

$$H = \frac{n}{\sum_{i=1}^n 1/x_i}$$

Vale sempre a desigualdade $H \leq G \leq \bar{x}$, com igualdade apenas se todos os valores forem idênticos. O F1-score, aliás, é exatamente a média harmônica entre precisão e recall — e é harmônica justamente para penalizar o desequilíbrio entre as duas.

Média aparada (*trimmed mean*) — descarta os $\alpha\%$ extremos de cada cauda antes de promediar. É o meio-termo controlado entre média e mediana, e é o que o Comitê Olímpico usa nas notas de ginástica pelo mesmo motivo que um cientista de dados deveria usar: neutralizar juízes extremos sem jogar fora toda a informação.

NO MERCADO

O Banco Central do Brasil publica o **IPCA com médias aparadas** como medida de núcleo de inflação, precisamente porque a média cheia é sequestrada por choques pontuais (uma geadas que triplica o preço do tomate não é inflação estrutural). Esse é o mesmo raciocínio que você deve aplicar a métricas de produto: o pico de um bug não é o comportamento do sistema.

4. Medidas de dispersão

4.1 Variância, desvio-padrão e a correção de Bessel

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

A pergunta que todo aluno faz — *por que $n - 1$?* — tem uma resposta precisa. Se usássemos n , o estimador seria **viesado para baixo**. A intuição: a soma de quadrados é calculada em torno de $\bar{x}$, que é ela própria estimada dos mesmos dados e portanto está "puxada" para o centro da amostra. Os desvios em torno de $\bar{x}$ são sistematicamente menores do que seriam em torno do μ verdadeiro, que você não conhece.

Formalmente, $E[\sum (x_i - \bar{x})^2] = (n - 1)\sigma^2$, e dividir por $n - 1$ corrige exatamente esse fator. Diz-se que a amostra tem $n - 1$ **graus de liberdade**: uma vez fixada a média, o último desvio fica determinado pelos outros $n - 1$, porque $\sum (x_i - \bar{x}) = 0$.

ARMADILHA COMUM

`numpy.var()` usa `ddof=0` (divide por n) e `pandas.Series.var()` usa `ddof=1` (divide por $n - 1$). As duas bibliotecas mais usadas do ecossistema discordam no default. Em n grande a diferença é irrelevante; em amostras pequenas — validação cruzada com poucos folds, testes A/B em segmentos pequenos, calibração por estrato — ela muda a conclusão. Sempre passe `ddof` explicitamente.

4.2 Alternativas robustas

O desvio-padrão herda a fragilidade da média, e piora: os desvios são elevados ao quadrado. Duas alternativas:

Amplitude interquartil (IQR), $IQR = Q_3 - Q_1$, cobre os 50% centrais dos dados e ignora completamente as caudas.

Desvio absoluto mediano (MAD):

$$MAD = \text{mediana}(|x_i - \text{mediana}(x)|)$$

Para dados aproximadamente normais, $1,4826 \times MAD$ estima o mesmo que σ — a constante existe só para tornar as duas escalas comparáveis. A diferença é a robustez, que se mede pelo **ponto de ruptura** (*breakdown point*): a fração de observações que podem ser corrompidas arbitrariamente sem que o estimador vá para o infinito.

Estimador	Ponto de ruptura	Leitura prática
Média	0%	Um único ponto contaminado destrói a estimativa
Média aparada 10%	10%	Aguenta 10% de lixo em cada cauda

Estimador	Ponto de ruptura	Leitura prática
Mediana	50%	Aguenta metade dos dados corrompidos
Desvio-padrão	0%	Idem à média, e mais sensível ainda
MAD / IQR	50%	Referência para detecção de outliers

4.3 Coeficiente de variação

$$CV = \frac{s}{\bar{x}}$$

Adimensional, permite comparar dispersão entre grandezas de escalas diferentes ("a variabilidade do ticket médio é maior que a do tempo de sessão?"). Só faz sentido para variáveis de razão com $\bar{x} > 0$ — aplicar CV a temperatura em Celsius ou a uma variável que troca de sinal produz um número sem significado.

5. Momentos: assimetria e curtose

Os momentos centrais padronizados descrevem o **formato** da distribuição, indo além de centro e espalhamento.

$$\tilde{\mu}_k = \mathbb{E}\left[\left(\frac{X-\mu}{\sigma}\right)^k\right]$$

Assimetria (*skewness*), $k=3$: mede o desequilíbrio entre as caudas. Positiva significa cauda longa à direita — o caso típico de receita, renda, tempo de resposta e valor de sinistro, em que a maioria é pequena e alguns poucos são enormes. Quando a assimetria é positiva, vale a ordenação $\text{moda} < \text{mediana} < \text{média}$, e é exatamente por isso que "a maioria das pessoas ganha menos que a média".

Curtose (*kurtosis*), $k=4$: mede o peso das caudas. A normal tem curtose 3; por isso se reporta a **curtose excedente** $\tilde{\mu}_4 - 3$, que é zero para a normal. Excedente positivo indica caudas mais pesadas que a normal — mais eventos extremos do que o modelo gaussiano prevê.

NO MERCADO

A crise de 2008 é, em boa medida, um erro de curtose. Modelos de risco calibravam VaR supondo retornos normais. Sob normalidade, uma queda de 5 desvios-padrão acontece uma vez a cada milhão de dias úteis — ou seja, "nunca". Nos dados reais de mercado, com curtose excedente alta, esse evento ocorre a cada poucos anos. O modelo não estava errado por pouco: estava errado por várias ordens de magnitude, e só na cauda — justamente onde o dinheiro estava.

ARMADILHA COMUM

Assimetria e curtose amostrais são estimadores de **alta variância**: dependem de potências terceira e quarta, dominadas pelos pontos extremos. Com $n < 300$ eles são ruidosos a ponto de serem quase inúteis isoladamente. Use-os como sinal de alerta acompanhado de histograma e QQ-plot, nunca como veredito.

6. Quantis, percentis e o mundo real de SLA

O quantil de ordem $q \in (0, 1)$ é o valor x_q tal que uma fração q dos dados fica abaixo dele. Formalmente, via função de distribuição acumulada:

$$x_q = F^{-1}(q) = \inf \{x : F(x) \geq q\}$$

Em dados discretos, esse ínfimo raramente cai exatamente sobre uma observação, e existem **nove definições distintas de quantil amostral** na literatura (implementadas em `numpy.quantile(..., method=...)`). Para n grande a escolha é irrelevante; para n pequeno, dois times podem reportar p95 diferentes a partir dos mesmos dados e passar uma tarde discutindo.

6.1 Por que engenharia mede latência em p99, e não em média

Um serviço com latência média de 100 ms parece saudável. Mas se a distribuição tem cauda longa, o p99 pode ser 2 000 ms. Isso significa que **1 em cada 100 requisições** demora dois segundos.

O ponto crítico, e frequentemente ignorado: uma única tela de aplicativo costuma disparar dezenas de chamadas. Se uma página faz 50 requisições independentes, a probabilidade de **pelo menos uma** cair na cauda do p99 é

$$1 - (1 - 0,01)^{50} \approx 39,5\%$$

Quase 40% dos carregamentos de página sofrem o pior caso do p99. A média nunca revelaria isso — e é por essa razão que SLAs sérios são escritos em percentis altos, nunca em média.

ANALOGIA

Planejar capacidade pela média é como comprar um colete salva-vidas para a profundidade média de um rio. A profundidade média é de 1,20 m; você se afoga no trecho de 3 m.

7. Relação entre variáveis

7.1 Covariância e correlação de Pearson

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] \quad \rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

A covariância tem unidade (reais × minutos, por exemplo), o que a torna incomparável entre pares de variáveis. Pearson normaliza para $[-1, 1]$.

Duas limitações precisam ficar absolutamente claras:

- 1 **Pearson mede apenas relação linear.** Se $Y = X^2$ com X simétrico em torno de zero, então $\rho = 0$ — e a dependência é total. Correlação zero **não** é independência.
- 2 **Pearson é frágil a outliers**, pela mesma razão que a média é: entram produtos de desvios.

7.2 Spearman e Kendall

Spearman é o Pearson calculado sobre os **postos** (*ranks*). Captura qualquer relação monotônica, não só linear, e é robusto a outliers, porque o maior valor vira apenas "posto n ", não importa quão distante esteja.

Kendall tau conta pares concordantes e discordantes:

$$\tau = \frac{C - D}{\binom{n}{2}}$$

É mais interpretável (é uma probabilidade de concordância) e mais estável em amostras pequenas, ao custo de ser mais caro computacionalmente.

Situação	Use
Relação linear, sem outliers, dados contínuos	Pearson
Relação monotônica não-linear, ou outliers presentes	Spearman
Amostra pequena, ou muitos empates	Kendall
Relação não-monotônica (U, ciclo)	Nenhum dos três — use <i>mutual information</i> ou gráfico

ARMADILHA COMUM

A matriz de correlação é a ferramenta de EDA mais usada e mais mal usada do mercado. Um **heatmap** de Pearson não vê relações em U, não vê interações, é distorcido por outliers e diz *nada* sobre causalidade. Trate-a como um índice para decidir quais pares merecem um *scatter plot* — nunca como conclusão.

7.3 O quarteto de Anscombe

Quatro conjuntos de dados com **médias, variâncias, correlação e reta de regressão idênticas até a segunda casa decimal** — e com formatos completamente diferentes: um linear, um quadrático, um linear com um outlier, e um que é uma coluna vertical mais um ponto isolado. É a demonstração definitiva de que estatísticas-resumo não substituem o gráfico. O notebook 03 reproduz o quarteto e sua versão moderna, o *Datasaurus Dozen*.

8. Padronização e escala

O **z-score** recentra e reescala:

$$z_i = \frac{x_i - \bar{x}}{s}$$

Após a transformação, $\bar{z} = 0$ e $s_z = 1$. É requisito para todo algoritmo sensível a distância ou a magnitude de coeficientes: k-NN, k-means, SVM, PCA, regressão regularizada e redes neurais. Árvores e ensembles de árvores são invariantes a transformações monotônicas e não precisam.

ARMADILHA COMUM

O erro de vazamento mais comum do mercado: calcular média e desvio-padrão **no conjunto completo** e só depois separar treino e teste. A estatística de padronização carrega informação do teste para dentro do treino, e a performance reportada fica otimista. O ajuste (**fit**) pertence exclusivamente ao treino. Este é o tema central do módulo *Encoding, Escala e Vazamento de Dados*.

9. Um protocolo de descrição que funciona

Sequência que eu recomendo aplicar a toda variável nova, nesta ordem:

- 1 **Tipo e cardinalidade.** Qual é o dtype? Quantos valores únicos? Uma coluna "numérica" com 4 valores distintos é categórica disfarçada.
- 2 **Completeness.** Qual o percentual de ausentes? Há um valor sentinela disfarçado (-999, 0, 1900-01-01) fazendo o papel de nulo?
- 3 **Posição e dispersão robustas juntas.** Reporte média e mediana. Se divergem muito, há assimetria ou contaminação — investigue antes de seguir.
- 4 **Quantis, não só o desvio-padrão.** Mínimo, p1, p25, p50, p75, p99, máximo. O par (p1, p99) revela cauda que o desvio-padrão esconde.
- 5 **Formato.** Histograma com número de *bins* variado, mais um *boxplot* ou *violin*. Bimodalidade quase sempre significa duas populações misturadas — e duas populações misturadas quase sempre pedem dois modelos.
- 6 **Plausibilidade de domínio.** Idade negativa, receita de R\$ 0,00 em pedido fechado, timestamp no futuro. Nenhuma estatística substitui olhar 30 linhas cruas.

NO MERCADO

Em produção, esse mesmo protocolo vira **monitoramento**. Perfis descritivos (média, quantis, taxa de nulos, cardinalidade) de cada feature são calculados por janela e comparados com a janela de treino. Quando o p99 de uma feature dobra, o modelo já está degradando — e você descobre isso *antes* do impacto aparecer na métrica de negócio, que costuma ter semanas de atraso. Retomamos isso no tema *MLOps e Produção*.

10. Formulário do capítulo

FORMULARIO

Posição — média $\bar{x} = \frac{1}{n} \sum x_i$; mediana = minimiza $\sum |x_i - c|$; geométrica $G = (\prod x_i)^{1/n}$; harmônica $H = n / \sum (1/x_i)$; vale $H \leq G \leq \bar{x}$.

Dispersão — variância amostral $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$; IQR = $Q_3 - Q_1$; MAD = mediana($|x_i - \text{mediana}(x)|$); CV = $s/\bar{x}$.

Formato — assimetria $\tilde{\mu}_3$; curtose excedente $\tilde{\mu}_4 - 3$; para assimetria positiva, moda < mediana < $\bar{x}$.

Associação — $\rho = \text{Cov}(X, Y) / (\sigma_X \sigma_Y)$; Spearman = Pearson sobre postos; $\tau = (C - D) / \binom{n}{2}$.

Padronização — $z_i = (x_i - \bar{x})/s$; ajuste **só** no treino.

11. Erros que custam caro — checklist

- Reportar média sem mediana em variável assimétrica.
- Calcular média de variável ordinal sem justificar a equidistância.
- Usar `ddof` default sem verificar qual biblioteca está sendo chamada.
- Concluir independência a partir de correlação zero.
- Definir SLA em média quando o usuário sente a cauda.
- Padronizar antes de separar treino e teste.
- Interpretar assimetria/curtose amostrais com n pequeno.
- Confiar na matriz de correlação sem olhar um único *scatter plot*.

12. Para ir além

- Tukey, *Exploratory Data Analysis* (1977) — a origem do boxplot e da filosofia de olhar antes de testar.
- Huber & Ronchetti, *Robust Statistics* — formalização de ponto de ruptura.
- Wilke, *Fundamentals of Data Visualization* — disponível gratuitamente online.
- Taleb, *Statistical Consequences of Fat Tails* — denso, e o melhor tratamento de por que a intuição gaussiana falha.