

Distribuições de Probabilidade

O catálogo de modelos de incerteza que todo cientista de dados precisa reconhecer de olhos fechados

Uma distribuição não é uma curva bonita: é uma hipótese sobre o mecanismo que gerou seus dados. Este material apresenta cada distribuição a partir da história física que a produz — e mostra como reconhecer essa história olhando para os dados.

Nível: Intermediário — a probabilidade é construída do zero

Pre-requisitos: Módulo 01 (Fundamentos e Estatística Descritiva)

Carga sugerida: 8 a 10 horas (leitura + 4 notebooks)

Notebooks: 01-discretas · 02-continuas · 03-tlc-e-lei-dos-grandes-numeros · 04-ajuste-a-dados-reais

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. A ideia que organiza o capítulo	3
1.1 Duas grandes famílias	3
2. Ferramentas comuns a todas as distribuições	4
3. Distribuições discretas	5
3.1 Bernoulli — o átomo	5
3.2 Binomial — somando Bernoullis	5
3.3 Poisson — eventos raros num intervalo	5
3.4 Binomial negativa — a Poisson com superdispersão	6
3.5 Geométrica — quanto tempo até o primeiro sucesso	6
4. Distribuições contínuas	7
4.1 Normal — e por que ela está em todo lugar	7
4.2 Log-normal — quando os efeitos se multiplicam	7
4.3 Exponencial — tempo até o próximo evento	7
4.4 Weibull — falha com desgaste	8
4.5 Uniforme, Beta, Gama e Qui-quadrado	8
4.6 t de Student — a normal com incerteza sobre a escala	8
5. Como escolher: um guia de decisão	9
6. Os dois teoremas que sustentam tudo	10
6.1 Lei dos Grandes Números	10
6.2 Teorema Central do Limite	10
7. Formulário do capítulo	11
8. Erros que custam caro — checklist	12
9. Para ir além	13

1. A ideia que organiza o capítulo

Estudantes costumam decorar distribuições como quem decora tabela periódica: nome, fórmula, média, variância. É a forma mais rápida de esquecer tudo e a mais lenta de aprender.

A abordagem deste capítulo é outra. **Cada distribuição é a resposta matemática a uma história sobre como os dados nasceram.** Se você conhece a história, a fórmula deixa de ser arbitrária, e — o que importa muito mais na prática — você consegue fazer o caminho inverso: olhar para um problema de negócio e reconhecer qual história está acontecendo ali.

ANALOGIA

Pense em distribuições como **ferramentas de oficina**. Ninguém decora o catálogo de chaves de boca. Você olha a porca, vê o formato, e pega a chave certa. Uma contagem de eventos raros num intervalo é uma "porca de Poisson"; um tempo até a falha é uma "porca exponencial". O trabalho é aprender a olhar a porca.

1.1 Duas grandes famílias

	Discretas	Contínuas
O que descrevem	Contagens, categorias, sucessos	Medidas, tempos, grandezas
Função que as define	PMF: $P(X = x)$	PDF: $f(x)$, com $P(X = x) = 0$
Como se soma	$\sum_x P(X = x) = 1$	$\int f(x) dx = 1$
Exemplo de negócio	Nº de cliques, nº de sinistros	Latência, receita, temperatura

Um ponto que confunde quase todo iniciante: para variáveis contínuas, $P(X = 3,14) = 0$. Não é uma esquisitice técnica — é consequência de haver infinitos valores possíveis. Só faz sentido perguntar por $P(a \leq X \leq b) = \int_a^b f(x) dx$. A densidade $f(x)$ pode inclusive ser maior que 1; o que precisa somar 1 é a **área**, não a altura.

2. Ferramentas comuns a todas as distribuições

Antes do catálogo, cinco objetos que se aplicam a qualquer distribuição.

Função de distribuição acumulada (CDF) — a mais útil na prática:

$$F(x) = P(X \leq x)$$

Função quantil — a inversa da CDF, que responde "qual valor deixa 95% abaixo de si?". É o que produz um p95 e o que define um VaR.

$$Q(p) = F^{-1}(p)$$

Esperança e variância:

$$\mathbb{E}[X] = \sum_x x P(X = x) \quad \text{ou} \quad \int x f(x) dx$$

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Função geradora de momentos, $M_X(t) = \mathbb{E}[e^{tx}]$, cujas derivadas em $t=0$ produzem os momentos. Ela é a ferramenta que prova, em três linhas, que a soma de normais independentes é normal e que a soma de Poissons é Poisson.

Propriedades de transformação — as duas que mais se usam no dia a dia:

$$\mathbb{E}[aX + b] = a \mathbb{E}[X] + b \quad \text{Var}(aX + b) = a^2 \text{Var}(X)$$

Note que b some da variância (deslocar não muda espalhamento) e que a entra ao quadrado. Isso explica por que o erro-padrão da média é $\sigma/\sqrt{n}$ e não σ/n — assunto do módulo de inferência.

3. Distribuições discretas

3.1 Bernoulli — o átomo

História: um único experimento com dois resultados. Converteu ou não converteu. Clicou ou não clicou. Pagou ou deu calote.

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

$$\mathbb{E}[X] = p \quad \text{Var}(X) = p(1 - p)$$

Detalhe com consequência prática: a variância é máxima em $p = 0,5$ (vale 0,25) e vai a zero nos extremos. É por isso que **testes A/B com taxas de conversão muito baixas precisam de amostras enormes** — não porque a variância seja alta, mas porque o *efeito relativo* que você quer detectar fica pequeno perto do ruído.

3.2 Binomial — somando Bernoullis

História: n experimentos de Bernoulli **independentes** e com o **mesmo** p ; conte quantos sucessos.

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$\mathbb{E}[X] = np \quad \text{Var}(X) = np(1 - p)$$

ARMADILHA COMUM

As duas hipóteses da binomial — independência e p constante — são violadas o tempo todo em dados de produto. Usuários que vieram da mesma campanha não são independentes; a taxa de conversão às 3 da manhã não é a mesma do horário de pico. Quando isso acontece, a variância real é **maior** que $np(1 - p)$: é a **superdispersão**, e ela faz seus intervalos de confiança ficarem estreitos demais. Você declara significância que não existe.

3.3 Poisson — eventos raros num intervalo

História: eventos ocorrem de forma independente, a uma taxa média constante λ por intervalo. Conte quantos ocorreram.

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

$$\mathbb{E}[X] = \lambda \quad \text{Var}(X) = \lambda$$

A propriedade mais característica — e o melhor teste diagnóstico de campo — é **média igual a variância**. Se você suspeita de Poisson, calcule a razão Var/média nos dados. Se der muito acima de 1, não é Poisson: é superdispersão, e o modelo correto é a **binomial negativa**.

A Poisson é o limite da binomial quando $n \rightarrow \infty$ e $p \rightarrow 0$ com $np = \lambda$ fixo. Traduzindo: **muitas oportunidades, cada uma improvável**. É por isso que ela modela tão bem chamadas em call center, sinistros de seguro, falhas de servidor, acessos por segundo e defeitos por lote.

NO MERCADO

Precificação de seguros é essencialmente um modelo de frequência $\times$ severidade. A **frequência** de sinistros é Poisson (ou binomial negativa) e a **severidade** de cada sinistro é uma distribuição de cauda pesada (log-normal, gama ou Pareto). O prêmio é aproximadamente $\mathbb{E}[\text{frequência}] \times \mathbb{E}[\text{severidade}]$ mais uma margem de risco derivada da variância. Toda seguradora do mundo roda alguma versão disso.

3.4 Binomial negativa — a Poisson com superdispersão

História: conte fracassos até obter r sucessos. Mas o uso moderno é outro, e mais importante: ela é uma **mistura de Poissons** em que o próprio λ varia entre indivíduos segundo uma distribuição gama.

Essa segunda leitura é a que importa. Se cada cliente tem sua própria taxa de compra e essas taxas variam na população, a contagem agregada é binomial negativa, não Poisson. A variância vira

$$\text{Var}(X) = \mu + \frac{\mu^2}{r}$$

sempre maior que a média — exatamente o que se observa em quase todo dado de contagem do mundo real.

3.5 Geométrica — quanto tempo até o primeiro sucesso

$$P(X = k) = (1 - p)^{k-1}p, \quad \mathbb{E}[X] = \frac{1}{p}$$

Tem a propriedade de **falta de memória**: se você já tentou 10 vezes sem sucesso, a distribuição do número de tentativas restantes é idêntica à do começo. É a versão discreta da exponencial, e a base da modelagem de churn em tempo discreto.

4. Distribuições contínuas

4.1 Normal — e por que ela está em todo lugar

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

A normal não é onipresente por acaso, nem porque "a natureza gosta dela". Há três razões técnicas:

- 1 **Teorema Central do Limite.** Somas e médias de muitas contribuições independentes tendem à normal, praticamente sem importar a distribuição de origem.
- 2 **Máxima entropia.** Entre todas as distribuições com uma dada média e variância, a normal é a que assume *menos* além disso. É a escolha honestamente mais ignorante.
- 3 **Conveniência algébrica.** Somas de normais são normais; combinações lineares de normais são normais; a normal é conjugada consigo mesma. Isso torna a matemática tratável.

A regra empírica 68-95-99,7 (dentro de 1, 2 e 3 desvios-padrão) merece ser decorada, com uma ressalva: ela **só vale se os dados forem realmente normais**, e a maior parte dos dados de negócio não é.

ARMADILHA COMUM

"Assumir normalidade" quase nunca significa assumir que *os dados* são normais. Em regressão linear, a suposição é sobre os **resíduos**, não sobre X nem sobre y . Em testes de média, o TLC cuida da distribuição da **média amostral**, não das observações. Confundir esses três níveis é o erro conceitual mais comum de quem aprendeu estatística por receita.

4.2 Log-normal — quando os efeitos se multiplicam

Se $\ln X \sim \mathcal{N}(\mu, \sigma^2)$, então X é log-normal. Surge sempre que o resultado é o **produto** de muitos fatores independentes (o TLC atua sobre o log).

$$\mathbb{E}[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right) \quad \text{mediana}(X) = e^\mu$$

Repare: a média é sempre **maior** que a mediana, e a diferença cresce exponencialmente com σ . É a assinatura matemática de "ticket médio muito acima do ticket típico". Renda, receita por cliente, tempo de resposta, tamanho de arquivo e preço de imóvel são todos aproximadamente log-normais.

4.3 Exponencial — tempo até o próximo evento

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0 \quad \mathbb{E}[X] = \frac{1}{\lambda} \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

É a irmã contínua da Poisson: **se as contagens por intervalo são Poisson(λ), os tempos entre eventos são Exponencial(λ)**. Essas são duas descrições do mesmo processo.

Também é **sem memória**: $P(X > s + t \mid X > s) = P(X > t)$. Um componente que já durou 1.000 horas tem a mesma distribuição de vida restante que um novo — o que é uma hipótese frequentemente *falsa* na engenharia real, e é exatamente por isso que existe a Weibull.

4.4 Weibull — falha com desgaste

$$f(x) = \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$$

O parâmetro de forma k é o que importa:

k	Taxa de falha	Fase do produto
$k < 1$	Decrescente	Mortalidade infantil (defeitos de fábrica)
$k = 1$	Constante	Falhas aleatórias (= exponencial)
$k > 1$	Crescente	Desgaste, envelhecimento

Juntas, essas três fases formam a **curva da banheira** da confiabilidade. A Weibull é o modelo padrão em manutenção preditiva e análise de sobrevivência industrial.

4.5 Uniforme, Beta, Gama e Qui-quadrado

Uniforme $U(a, b)$ — ignorância total dentro de um intervalo. É a base de todo gerador de números aleatórios: qualquer distribuição pode ser amostrada aplicando $F^{-1}(U)$ a uma uniforme (método da **transformada inversa**).

Beta $Beta(\alpha, \beta)$ — definida em $[0, 1]$, é a distribuição natural para modelar uma **probabilidade desconhecida**. É a priori conjugada da binomial, e por isso o motor de testes A/B bayesianos e de algoritmos de *multi-armed bandit* (Thompson sampling). Interpretação memorável: $\alpha - 1$ sucessos e $\beta - 1$ fracassos observados.

Gama — soma de k exponenciais independentes. Modela tempo até a k -ésima falha, e é a distribuição de severidade preferida em seguros.

Qui-quadrado χ_k^2 — soma de k normais padrão ao quadrado. Você raramente a "vê" nos dados; ela aparece como distribuição de **estatísticas de teste** (teste qui-quadrado de independência, teste da razão de verossimilhança).

4.6 t de Student — a normal com incerteza sobre a escala

Quando você estima σ a partir da amostra em vez de conhecê-lo, a estatística padronizada deixa de ser normal e passa a seguir uma t com $n - 1$ graus de liberdade. Ela tem **caudas mais pesadas** que a normal — exatamente para pagar o preço de não conhecer a variância. Com $df > 30$ as duas são praticamente indistinguíveis.

5. Como escolher: um guia de decisão

A pergunta do negócio	Distribuição	Sinal nos dados
Converteu ou não?	Bernoulli	Só 0 e 1
Quantos sucessos em n tentativas?	Binomial	Inteiro limitado por n
Quantos eventos por hora/dia?	Poisson	Inteiro ≥ 0 ; Var $\approx$ média
Quantos eventos, com clientes heterogêneos?	Binomial negativa	Inteiro ≥ 0 ; Var $\gg$ média
Quanto tempo até o próximo evento?	Exponencial	Contínuo > 0 ; sem memória
Quanto tempo até falhar, com desgaste?	Weibull	Contínuo > 0 ; taxa de falha varia
Receita, renda, latência	Log-normal	Contínuo > 0 ; simétrico em escala log
Média de muitas contribuições	Normal	Simétrico; QQ-plot na diagonal
Uma proporção desconhecida	Beta	Contínuo em $[0, 1]$
Contagem com excesso de zeros	Poisson/BN inflada em zero	Pico enorme em 0

NO MERCADO

O erro mais caro em modelagem de contagens é usar **regressão linear** para prever número de eventos. Ela permite previsões negativas (n° de pedidos = -3), assume variância constante (falso: contagens têm variância proporcional à média) e assume resíduos simétricos. O correto é uma **GLM** com família Poisson ou binomial negativa e função de ligação log. É uma troca de uma linha de código que muda o resultado por completo.

6. Os dois teoremas que sustentam tudo

6.1 Lei dos Grandes Números

A média amostral converge para a média populacional conforme n cresce:

$$\bar{X}_n \rightarrow \mu \quad \text{quando} \quad n \rightarrow \infty$$

Ela justifica que estimar funciona — mas **exige que μ exista**. Para distribuições de cauda muito pesada (Pareto com $\alpha \leq 1$, Cauchy) a média teórica é infinita ou indefinida e a média amostral **nunca converge**, por mais dados que você colete. Vimos isso empiricamente no módulo anterior.

6.2 Teorema Central do Limite

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \rightarrow \mathcal{N}(0, 1)$$

A distribuição da **média amostral** tende à normal, quase independentemente da distribuição de origem — desde que a variância seja finita.

Três consequências que se usam todos os dias:

- 1 O erro-padrão da média cai com $\sqrt{n}$, não com n . **Para reduzir o erro pela metade é preciso quadruplicar a amostra.** É a economia fundamental de todo teste A/B.
- 2 Testes t e intervalos de confiança funcionam mesmo com dados não-normais, desde que n seja suficiente.
- 3 " $n \geq 30$ " é uma regra de bolso, não um teorema. Para dados muito assimétricos, pode ser necessário n de centenas ou milhares. Para dados já quase simétricos, $n = 10$ basta. A pergunta certa é sempre sobre a assimetria, não sobre um número mágico.

ARMADILHA COMUM

O TLC fala sobre a distribuição da **média**, não sobre a distribuição dos **dados**. Coletar mais dados não torna sua variável mais normal — ela continua exatamente tão assimétrica quanto era. O que fica normal é a distribuição amostral da estatística.

7. Formulário do capítulo

FORMULARIO

Bernoulli(p): $\mathbb{E} = p$, $\text{Var} = p(1 - p)$.

Binomial(n, p): $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$; $\mathbb{E} = np$, $\text{Var} = np(1 - p)$.

Poisson(λ): $P(X = k) = \lambda^k e^{-\lambda} / k!$; $\mathbb{E} = \text{Var} = \lambda$.

Binomial negativa: $\text{Var} = \mu + \mu^2/r > \mu$.

Normal(μ, σ^2): $f(x) = (2\pi\sigma^2)^{-1/2} \exp(-(x - \mu)^2 / 2\sigma^2)$.

Log-normal: $\mathbb{E}[X] = \exp(\mu + \sigma^2/2)$, mediana = e^μ .

Exponencial(λ): $f(x) = \lambda e^{-\lambda x}$; $\mathbb{E} = 1/\lambda$, $\text{Var} = 1/\lambda^2$.

Weibull(k, λ): $k < 1$ mortalidade infantil, $k = 1$ exponencial, $k > 1$ desgaste.

TLC: $(\bar{X}_n - \mu) / (\sigma / \sqrt{n}) \rightarrow \mathcal{N}(0, 1)$.

8. Erros que custam caro — checklist

- Assumir Poisson sem checar se $\text{Var} \approx \text{média}$.
- Usar regressão linear para contagens.
- Aplicar a regra 68–95–99,7 a dados assimétricos.
- Confundir normalidade dos dados com normalidade dos resíduos.
- Usar o TLC com $n = 30$ em dados de cauda pesada.
- Ignorar excesso de zeros (a maioria dos dados de contagem em produto tem).
- Modelar tempo até falha com exponencial quando há desgaste evidente.

9. Para ir além

- Blitzstein & Hwang, *Introduction to Probability* — o melhor livro-texto atual, disponível gratuitamente com vídeos das aulas de Harvard.
- Wasserman, *All of Statistics*, capítulos 2 e 3 — denso e direto ao ponto.
- Hilbe, *Modeling Count Data* — a referência prática sobre superdispersão.