

Inferência e Estimação

De uma amostra para a população — e o preço honesto dessa extrapolação

Inferência é o ato de afirmar algo sobre o que você não viu, a partir do pouco que viu. Este material constrói o aparato inteiro: estimadores e suas propriedades, máxima verossimilhança, erro-padrão, intervalos de confiança e bootstrap — com atenção especial ao que um intervalo de confiança realmente promete (e ao que ele decididamente não promete).

Nível: Intermediário — todo o cálculo necessário é construído no texto

Pre-requisitos: Módulos 01 e 02 (Descritiva e Distribuições)

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-estimadores-e-propriedades · 02-maxima-verossimilhança · 03-intervalos-e-bootstrap

Autoria: Material do curso de ML & DL

Versão: 1.0

Sumário

1. O problema, formulado com precisão	3
2. Propriedades de um bom estimador	4
2.1 Viés	4
2.2 Variância e erro quadrático médio	4
2.3 Consistência e eficiência	4
3. Erro-padrão: a medida da incerteza	6
4. Máxima verossimilhança	7
4.1 A ideia	7
4.2 Por que o MLE é o método padrão	7
5. Intervalos de confiança	9
5.1 A definição, com a interpretação correta	9
5.2 Construção para a média	9
5.3 Para proporções: por que a fórmula do livro é ruim	9
6. Bootstrap: inferência sem fórmula	11
6.1 A ideia central	11
6.2 Variantes	11
7. Tamanho de amostra: planejando antes de coletar	13
8. Formulário do capítulo	14
9. Erros que custam caro — checklist	15
10. Para ir além	16

1. O problema, formulado com precisão

Você tem 3.000 usuários de um total de 4 milhões. Mediu a taxa de conversão desses 3.000 e obteve 4,2%. A pergunta de negócio é sobre os 4 milhões, não sobre os 3.000.

Formalmente: existe uma **população** governada por um parâmetro desconhecido θ (uma taxa, uma média, um coeficiente). Você observa uma **amostra** $X_1, \dots, X_n$ e calcula uma **estatística** $\hat{\theta}$ — uma função dos dados. A inferência é o conjunto de técnicas que responde: *o que $\hat{\theta}$ autoriza dizer sobre θ ?*

DEFINIÇÃO

Um **estimador** é uma função da amostra: $\hat{\theta} = g(X_1, \dots, X_n)$. Como a amostra é aleatória, o estimador é **ele próprio uma variável aleatória** — ele tem uma distribuição, chamada **distribuição amostral**. Compreender inferência é compreender essa distribuição.

ANALOGIA

Estimar é como avaliar a temperatura de uma piscina inteira enfiando um dedo em um ponto. O valor que você sente é uma estimativa. Ela tem dois defeitos possíveis: um **viés** (se seu dedo está sempre frio, você subestima sempre) e uma **variância** (se a piscina tem correntes, cada ponto dá um número diferente). Inferência é quantificar esses dois defeitos.

2. Propriedades de um bom estimador

2.1 Viés

$$\text{Viés}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$$

Um estimador é **não-viesado** se acerta *na média* ao longo de infinitas amostras. É a propriedade que motiva o $n - 1$ da variância amostral, vista no módulo 01.

Um alerta importante: **não-viesado não significa bom**. Um estimador pode ser não-viesado e ter variância tão alta que cada estimativa individual é inútil.

2.2 Variância e erro quadrático médio

$$\text{EQM}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Viés}(\hat{\theta})^2$$

Essa decomposição é uma das identidades mais importantes de toda a estatística aplicada — e é literalmente a mesma decomposição viés-variância que reaparece em machine learning. Ela diz que **aceitar um pouco de viés em troca de muito menos variância pode reduzir o erro total**.

NO MERCADO

Regressão Ridge é exatamente esse trade. O estimador de mínimos quadrados é não-viesado; a Ridge é viesada de propósito. Em problemas com muitas variáveis correlacionadas, a Ridge tem EQM *menor* — ela erra menos, na prática, apesar de ser viesada. O mesmo raciocínio justifica *shrinkage* em estimativas por segmento (empréstimo de força entre grupos pequenos).

2.3 Consistência e eficiência

Consistência: $\hat{\theta} \rightarrow \theta$ conforme $n \rightarrow \infty$. É o requisito mínimo — um estimador inconsistente não melhora com mais dados.

Eficiência: entre estimadores não-viesados, o de menor variância. Existe um piso teórico para essa variância, o **limite de Cramér-Rao**:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}$$

onde $I(\theta)$ é a **informação de Fisher**, que mede quanto uma observação carrega de informação sobre θ :

$$I(\theta) = \mathbb{E}\left[\left(\frac{\partial}{\partial \theta} \log f(X | \theta)\right)^2\right]$$

A leitura intuitiva: a informação de Fisher mede quão *pontuda* é a verossimilhança. Verossimilhança pontuda significa que os dados distinguem bem valores próximos de θ — muita informação, pouca variância possível.

3. Erro-padrão: a medida da incerteza

O **erro-padrão** é o desvio-padrão da distribuição amostral do estimador. Para a média:

$$EP(\bar{X}) = \frac{\sigma}{\sqrt{n}} \qquad \widehat{EP}(\bar{X}) = \frac{s}{\sqrt{n}}$$

ARMADILHA COMUM

Desvio-padrão e erro-padrão são coisas diferentes e a confusão entre os dois é epidêmica. O **desvio-padrão** s descreve o espalhamento dos **dados** e não diminui com n — coletar mais dados não torna as pessoas mais parecidas. O **erro-padrão** $s/\sqrt{n}$ descreve a precisão da **estimativa** e tende a zero. Um gráfico com barras de erro precisa dizer qual dos dois está mostrando; barras de erro-padrão são $\sim\sqrt{n}$ vezes menores e fazem qualquer diferença parecer dramática.

Para proporções:

$$\widehat{EP}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

4. Máxima verossimilhança

É o método de estimação mais importante que existe. Regressão logística, GLMs, modelos de sobrevivência, redes neurais treinadas com entropia cruzada — todos são máxima verossimilhança por baixo do capô.

4.1 A ideia

A **função de verossimilhança** é a probabilidade dos dados observados, vista como função do parâmetro:

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

O estimador de máxima verossimilhança (MLE) é o θ que torna os dados observados os mais prováveis possíveis:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta)$$

Na prática, maximiza-se a **log-verossimilhança**, porque produtos viram somas (numericamente estáveis e algebricamente tratáveis):

$$\ell(\theta) = \sum_{i=1}^n \log f(x_i | \theta)$$

ANALOGIA

Você encontra uma pegada na areia. A verossimilhança pergunta: para cada animal possível, qual a chance de ele deixar *exatamente* esta pegada? O MLE é o animal que torna a pegada menos surpreendente. Note a inversão: não perguntamos "qual animal é mais provável?" (isso seria bayesiano, e exigiria saber quais animais existem na região) — perguntamos "sob qual animal esta pegada seria mais esperada?".

4.2 Por que o MLE é o método padrão

Sob condições de regularidade, o MLE tem três propriedades assintóticas:

- 1 **Consistente:** $\hat{\theta} \rightarrow \theta$.
- 2 **Assintoticamente normal:** $\hat{\theta} \approx \mathcal{N}(\theta, \frac{1}{nI(\theta)})$.
- 3 **Assintoticamente eficiente:** atinge o limite de Cramér-Rao.

A propriedade 2 é o motor prático de tudo: é dela que saem os erros-padrão e os p-valores reportados por `statsmodels`, por `sklearn` e por qualquer software estatístico.

Invariância: se $\hat{\theta}$ é o MLE de θ , então $g(\hat{\theta})$ é o MLE de $g(\theta)$. Isso permite estimar odds ratio a partir do MLE dos coeficientes, sem refazer nada.

ARMADILHA COMUM

O MLE é **viesado** em amostras finitas. O exemplo canônico: o MLE da variância divide por n , não por $n - 1$ — é exatamente o estimador viesado do módulo 01. As boas propriedades do MLE são *assintóticas*; com n pequeno elas podem não valer.

5. Intervalos de confiança

5.1 A definição, com a interpretação correta

Um intervalo de confiança de 95% para θ é um intervalo aleatório $[\hat{L}, \hat{U}]$ construído de modo que

$$P(\hat{L} \leq \theta \leq \hat{U}) = 0,95$$

onde a probabilidade é sobre **amostras repetidas**, não sobre θ .

DEFINICAO

A interpretação correta: *se eu repetisse este experimento infinitas vezes e construísse um intervalo a cada vez, 95% desses intervalos conteriam o valor verdadeiro.*

A interpretação **incorreta**, e quase universal: "há 95% de chance de θ estar neste intervalo". No paradigma frequentista, θ é uma constante fixa — ela está ou não está dentro do seu intervalo específico, com probabilidade 0 ou 1. O que tem 95% de probabilidade é o **procedimento**, não o intervalo particular que você calculou.

Se a segunda interpretação é a que você quer (e geralmente é), a ferramenta correta é o **intervalo de credibilidade bayesiano** — módulo 05.

5.2 Construção para a média

$$\bar{x} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$$

Usa-se a distribuição t porque σ foi estimado a partir dos dados. Com $n > 30$ a diferença para a normal é desprezível.

5.3 Para proporções: por que a fórmula do livro é ruim

O intervalo de Wald, $\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/n}$, é o que todo mundo aprende e tem comportamento **ruim** quando p é próximo de 0 ou 1, ou quando n é pequeno. Ele pode produzir limites fora de $[0, 1]$ e sua cobertura real fica bem abaixo dos 95% nominais.

Método	Quando usar
Wald	Praticamente nunca; só didático
Wilson	Padrão recomendado — bom em todo regime
Agresti-Coull	Simples: some 2 sucessos e 2 fracassos e use Wald
Clopper-Pearson	Exato e conservador; auditoria e regulação

NO MERCADO

Em testes A/B com conversões raras (0,5% ou menos), o intervalo de Wald sistematicamente sobrestima a certeza. Times de produto declaram vitórias que não se sustentam. A troca para Wilson custa uma linha de código (`statsmodels.stats.proportion.proportion_confint(..., method="wilson")`) e corrige o problema.

6. Bootstrap: inferência sem fórmula

Nem toda estatística tem fórmula fechada para o erro-padrão. Qual é o erro-padrão da **mediana**? E do **p95**? E do coeficiente de Gini? E da diferença entre as medianas de dois grupos?

O bootstrap responde a todas essas perguntas com o mesmo algoritmo.

6.1 A ideia central

Você não pode reamostrar da população — só tem uma amostra. Mas se a amostra é representativa, ela é uma **maquete da população**. Então reamostre *dela*, com reposição, e observe a variabilidade que aparece.

O algoritmo cabe em quatro linhas:

- 1 Sorteie n observações **com reposição** da sua amostra de tamanho n .
- 2 Calcule a estatística nessa reamostra, obtendo $\hat{\theta}^*$.
- 3 Repita B vezes (tipicamente $B = 2.000$ a 10.000).
- 4 Use a distribuição de $\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}$ como se fosse a distribuição amostral de $\hat{\theta}$.

O desvio-padrão dessas B réplicas estima o erro-padrão. Os percentis 2,5 e 97,5 formam o intervalo.

ANALOGIA

Bootstrap é o Barão de Münchhausen se puxando pelos próprios cabelos para sair do pântano — daí o nome. Parece trapaça, mas funciona porque a variabilidade *entre reamostras da amostra* imita a variabilidade *entre amostras da população*.

6.2 Variantes

Variante	Como funciona	Quando usar
Percentil	Percentis das réplicas	Padrão simples; estatística quase não-viesada
BCa	Corrige viés e assimetria	Recomendado por padrão; mais caro
Bootstrap-t	Estudentiza cada réplica	Melhor cobertura; exige EP por réplica
Por blocos	Reamostra blocos contíguos	Séries temporais (preserva autocorrelação)
Por grupos	Reamostra grupos inteiros	Dados agrupados (usuários com várias sessões)

ARMADILHA COMUM

O bootstrap padrão assume observações **independentes e identicamente distribuídas**. Aplicá-lo a séries temporais, a dados agrupados (várias linhas por usuário) ou a dados espaciais produz intervalos estreitos demais, porque destrói a estrutura de dependência. Use bootstrap por blocos ou por grupos. Este é um erro extremamente comum em análises de produto.

O bootstrap também falha para estatísticas de **extremo** (máximo, mínimo) e quando n é muito pequeno (abaixo de ~20 a 30).

7. Tamanho de amostra: planejando antes de coletar

Invertendo a fórmula da margem de erro $E = z \cdot \sigma / \sqrt{n}$:

$$n = \left(\frac{z\sigma}{E} \right)^2$$

Para proporções, o pior caso ($p = 0,5$, variância máxima) dá:

$$n = \frac{z^2 \cdot 0,25}{E^2}$$

Com $z = 1,96$ e $E = 0,03$, isso dá $n \approx 1.067$ — o famoso "mil entrevistados" das pesquisas eleitorais, com margem de 3 pontos.

Repare no expoente: **a amostra cresce com o quadrado da precisão desejada**. É a economia do $\sqrt{n}$ vista pelo avesso.

8. Formulário do capítulo

FORMULARIO

Viés $= \mathbb{E}[\hat{\theta}] - \theta$; **EQM** $= \text{Var}(\hat{\theta}) + \text{Viés}^2$.

Erro-padrão da média $= \sigma/\sqrt{n}$; **de proporção** $= \sqrt{\hat{p}(1 - \hat{p})/n}$.

Log-verossimilhança $\ell(\theta) = \sum_i \log f(x_i | \theta)$; $\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta)$.

Normalidade assintótica do MLE: $\hat{\theta} \approx \mathcal{N}(\theta, 1/(nI(\theta)))$.

IC para a média: $\bar{x} \pm t_{\alpha/2, n-1} s/\sqrt{n}$.

Tamanho de amostra: $n = (z\sigma/E)^2$.

9. Erros que custam caro — checklist

- Dizer "há 95% de chance de θ estar no intervalo".
- Trocar desvio-padrão por erro-padrão em gráficos (ou não dizer qual é).
- Usar Wald para proporções raras.
- Aplicar bootstrap i.i.d. a séries temporais ou dados agrupados.
- Confiar nas propriedades assintóticas do MLE com n pequeno.
- Calcular tamanho de amostra sem definir antes o efeito mínimo relevante.
- Reportar estimativa pontual sem nenhuma medida de incerteza.

10. Para ir além

- Efron & Tibshirani, *An Introduction to the Bootstrap* — a fonte original.
- Wasserman, *All of Statistics*, capítulos 6 a 9.
- Brown, Cai & DasGupta (2001), *Interval Estimation for a Binomial Proportion* — o artigo que documenta o mau comportamento do intervalo de Wald.