

Testes de Hipótese

Decidir sob incerteza com uma régua explícita para o erro que você aceita cometer

Um teste de hipótese não descobre a verdade: ele controla a taxa de um tipo específico de erro. Este material constrói a lógica do teste desde o princípio, apresenta o catálogo de testes clássicos com seus pressupostos, trata poder e tamanho de amostra como problema de projeto, e enfrenta o problema das comparações múltiplas — a razão silenciosa pela qual tanta descoberta não se reproduz.

Nível: Intermediário

Pre-requisitos: Módulos 01 a 03 (Descritiva, Distribuições, Inferência)

Carga sugerida: 10 a 12 horas (leitura + 4 notebooks)

Notebooks: 01-logica-do-teste · 02-testes-classicos · 03-poder-e-tamanho-de-amostra · 04-comparacoes-multiplas

Autoria: Material do curso de ML & DL

Versão: 1.0

Sumário

1. O que um teste de hipótese realmente faz	3
1.1 As duas hipóteses	3
1.2 Os dois erros	3
2. O p-valor: definição precisa e usos errados	5
2.1 O que o p-valor NÃO é	5
2.2 A relação com intervalos de confiança	5
3. O catálogo de testes	6
3.1 Comparação de médias	6
3.2 Proporções e tabelas de contingência	6
3.3 Aderência e normalidade	6
4. Poder estatístico	7
4.1 A maldição do estudo subdimensionado	7
5. Comparações múltiplas	8
5.1 Correções	8
5.2 Outras formas de p-hacking	8
6. Formulário do capítulo	9
7. Erros que custam caro — checklist	10
8. Para ir além	11

1. O que um teste de hipótese realmente faz

Comece por descartar a intuição errada. Um teste de hipótese **não** responde "minha hipótese é verdadeira?" nem "qual a probabilidade de eu estar certo?".

Ele responde a uma pergunta muito mais estreita e muito mais estranha:

Se não houvesse efeito nenhum, com que frequência eu veria um resultado tão extremo quanto o que vi?

Se essa frequência for suficientemente baixa, você declara que a hipótese de "efeito nenhum" é uma explicação pouco confortável para o que observou — e a rejeita. É um argumento por contradição probabilística, não uma prova.

ANALOGIA

O teste de hipótese é um **júri**, não um detector de verdade. A hipótese nula é a presunção de inocência. Você não "prova a inocência"; você apenas decide se há evidência **além da dúvida razoável** para condenar. O nível α é a definição operacional de "dúvida razoável" — e é você quem escolhe onde colocá-la, com base no custo de condenar um inocente.

1.1 As duas hipóteses

- **Hipótese nula (H_0):** o estado de coisas que se assume por padrão.

Normalmente "não há efeito", "as médias são iguais", "o coeficiente é zero".

- **Hipótese alternativa (H_1):** o que você suspeita.

H_0 é sempre a hipótese **específica** — a que permite calcular a distribuição da estatística de teste. É por isso que você nunca "aceita H_0 ": não encontrar evidência contra não é o mesmo que ter evidência a favor.

1.2 Os dois erros

	H_0 é verdadeira	H_0 é falsa
Rejeita H_0	Erro Tipo I (α) — falso positivo	Decisão correta (poder = $1 - \beta$)
Não rejeita H_0	Decisão correta	Erro Tipo II (β) — falso negativo

O ponto que define o método: **você escolhe α antes de ver os dados**. O 0,05 não tem nada de sagrado — foi uma conveniência de Fisher em 1925 que virou tradição. Em física de partículas usa-se 5σ ($\alpha \approx 3 \times 10^{-7}$); em triagem médica exploratória usa-se 0,10.

ARMADILHA COMUM

α e β trocam entre si. Reduzir α (menos falsos positivos) aumenta β (mais falsos negativos), com n fixo. A única forma de melhorar os dois ao mesmo tempo é **aumentar n** ou **reduzir a variância**. Toda discussão sobre "qual α usar" é, no fundo, uma discussão sobre qual dos dois erros custa mais caro no seu contexto.

2. O p-valor: definição precisa e usos errados

$$p = P(\text{estatística tão ou mais extrema que a observada} \mid H_0)$$

Cada palavra importa. O p-valor é uma probabilidade **condicional a H_0 ser verdadeira**, calculada sobre **dados hipotéticos** que você não observou.

2.1 O que o p-valor NÃO é

Interpretação errada	Por que está errada
"Probabilidade de H_0 ser verdadeira"	Isso é $P(H_0 \mid \text{dados})$; o p-valor é $P(\text{dados} \mid H_0)$
"Probabilidade de o resultado ser sorte"	Confunde as duas condicionais acima
" $p = 0,04$ é o dobro de forte que $p = 0,08$ "	O p-valor não é uma medida de tamanho de efeito
" $p > 0,05$ prova que não há efeito"	Ausência de evidência não é evidência de ausência
" $p < 0,05$ significa que o efeito é importante"	Significância estatística $\neq$ relevância prática

A última linha é a mais cara de todas no mercado.

NO MERCADO

Com $n = 10$ milhões de usuários, uma diferença de 0,003 p.p. na taxa de clique sai com $p < 0,001$. É estatisticamente significativa e comercialmente irrelevante — o efeito não paga nem o custo de manter o código da variante. **Sempre reporte o tamanho do efeito com seu intervalo de confiança**, e defina o *efeito mínimo relevante* antes do experimento.

2.2 A relação com intervalos de confiança

Um teste bilateral ao nível α rejeita $H_0 : \theta = \theta_0$ **se e somente se** o intervalo de confiança de $(1 - \alpha)$ não contém θ_0 . São duas faces da mesma moeda — mas o intervalo é estritamente mais informativo, porque mostra a magnitude e a precisão, não só a decisão.

3. O catálogo de testes

3.1 Comparação de médias

Teste	Situação	Pressupostos-chave
t de uma amostra	Média vs. valor de referência	Normalidade da média (TLC)
t de Welch	Duas amostras independentes	Não exige variâncias iguais
t pareado	Duas medidas do mesmo sujeito	Normalidade das diferenças
ANOVA	Três ou mais grupos	Normalidade, homocedasticidade
Mann-Whitney U	Duas amostras, não-paramétrico	Testa deslocamento de distribuição
Wilcoxon	Pareado, não-paramétrico	Simetria das diferenças
Kruskal-Wallis	3+ grupos, não-paramétrico	—

NOTA

Use Welch por padrão, não o teste t de Student clássico. O teste de Student exige variâncias iguais; o de Welch não, e perde quase nada de poder quando elas são iguais. A prática de "primeiro testar se as variâncias são iguais e depois escolher o teste" é pior do que simplesmente usar Welch sempre — o pré-teste distorce a taxa de erro do teste principal.

3.2 Proporções e tabelas de contingência

- **Teste z de duas proporções** — o padrão de A/B testing.
- **Qui-quadrado de independência** — para tabelas $r \times c$. Requer frequências esperadas ≥ 5 em quase todas as células.
- **Exato de Fisher** — para tabelas pequenas, onde o qui-quadrado falha.

3.3 Aderência e normalidade

- **Kolmogorov-Smirnov, Anderson-Darling, Shapiro-Wilk.**

ARMADILHA COMUM

Todo teste de normalidade tem poder crescente com n . Com n pequeno ele aceita tudo (inclusive dados claramente não-normais); com n grande ele rejeita tudo (porque nenhum dado real é exatamente normal). Ele responde "é *exatamente* normal?" quando a pergunta útil é "o desvio importa para a minha análise?". **Use QQ-plot.**

4. Poder estatístico

O **poder** é a probabilidade de detectar um efeito que realmente existe:

$$\text{Poder} = 1 - \beta = P(\text{rejeitar } H_0 \mid H_1 \text{ verdadeira})$$

Ele depende de quatro quantidades, e fixadas três, a quarta fica determinada:

- 1 α — nível de significância.
- 2 n — tamanho da amostra.
- 3 **Tamanho do efeito** — a magnitude que você quer detectar.
- 4 **Variabilidade** — o ruído dos dados.

Para comparação de duas médias, o tamanho de efeito padronizado é o **d de Cohen**:

$$d = \frac{\mu_1 - \mu_0}{\sigma}$$

e o n por grupo, para α e poder dados, é aproximadamente

$$n \approx \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2}{d^2}$$

Com $\alpha = 0,05$ e poder de 80%, o numerador vale $\approx 15,7$, então $n \approx 15,7/d^2$ por grupo. Um efeito pequeno ($d = 0,2$) exige ≈ 393 por grupo; um efeito muito pequeno ($d = 0,05$) exige ≈ 6.300 .

ARMADILHA COMUM

Análise de poder post-hoc é inútil. Calcular o poder *depois* do experimento usando o efeito *observado* não acrescenta informação nenhuma: ele é uma função determinística do p-valor obtido. Se deu não-significativo, o poder observado será baixo — sempre, por construção. A análise de poder tem de ser feita **antes**, com o efeito mínimo relevante definido pelo negócio.

4.1 A maldição do estudo subdimensionado

Um experimento com poder baixo tem um problema pior do que "não detectar nada": quando ele *detecta* algo, a estimativa é **exagerada**. Só efeitos anormalmente grandes conseguem cruzar o limiar de significância com pouca amostra. Isso se chama **erro de tipo M** (magnitude), e é uma das causas centrais da crise de replicação nas ciências sociais e biomédicas.

5. Comparações múltiplas

Se você testa 20 hipóteses independentes ao nível $\alpha = 0,05$ e nenhuma é verdadeira, a chance de pelo menos um falso positivo é

$$1 - (1 - 0,05)^{20} \approx 64\%$$

Com 100 testes, sobe para 99,4%. Testar muitas coisas **garante** achar algo.

ANALOGIA

É o atirador texano: dispara na parede do celeiro e depois desenha o alvo em volta do maior aglomerado de furos. A regra de ouro é declarar o alvo **antes** de atirar.

5.1 Correções

Método	Controla	Comportamento
Bonferroni — use α/m	FWER	Simples, muito conservador
Holm	FWER	Uniformemente melhor que Bonferroni; use este
Benjamini-Hochberg	FDR	Menos conservador; padrão em exploração

A distinção entre **FWER** (probabilidade de *qualquer* falso positivo) e **FDR** (proporção esperada de falsos positivos entre as descobertas) é a decisão de projeto principal. Para uma decisão confirmatória única, controle FWER. Para triagem exploratória de milhares de hipóteses (genômica, seleção de features, varredura de segmentos), controle FDR.

NO MERCADO

O caso clássico em produto: rodar um teste A/B e, ao não achar efeito na métrica principal, procurar em 30 segmentos até um deles dar significativo ("funcionou para mulheres de 25-34 no Android!"). Isso é *p-hacking* por *slicing*, e a taxa real de falso positivo é próxima de 80%. A análise por segmento precisa ser **pré-registrada** e **corrigida**.

5.2 Outras formas de p-hacking

- **Espiar continuamente** e parar quando fica significativo. Isso infla o erro

tipo I para bem acima de 50% com espiadas frequentes. A solução são métodos sequenciais próprios (limites de O'Brien-Fleming, testes sempre válidos).

- **Testar várias métricas** e reportar a que funcionou.
- ****Escolher a transformação, a exclusão de outliers ou os covariáveis depois de**

ver o resultado** — os "graus de liberdade do pesquisador".

6. Formulário do capítulo

FORMULARIO

p-valor = $P(\text{estatística tão extrema} \mid H_0)$.

t de Welch: $t = (\bar{x}_1 - \bar{x}_2) / \sqrt{s_1^2/n_1 + s_2^2/n_2}$.

z de duas proporções: $z = (\hat{p}_1 - \hat{p}_2) / \sqrt{\hat{p}(1 - \hat{p})(1/n_1 + 1/n_2)}$.

d de Cohen = $(\mu_1 - \mu_0)/\sigma$; convenção: 0,2 pequeno, 0,5 médio, 0,8 grande.

Tamanho de amostra (2 médias, 80% de poder, $\alpha = 0,05$): $n \approx 15,7/d^2$ por grupo.

FWER com m testes = $1 - (1 - \alpha)^m$; **Bonferroni:** use α/m .

7. Erros que custam caro — checklist

- Interpretar o p-valor como probabilidade de H_0 .
- Reportar significância sem tamanho de efeito e intervalo.
- "Aceitar H_0 " a partir de $p > 0,05$.
- Escolher o teste depois de ver os dados.
- Espiar o experimento e parar ao atingir significância.
- Analisar dezenas de segmentos sem correção.
- Fazer análise de poder post-hoc.
- Usar teste de normalidade com n grande como critério de decisão.

8. Para ir além

- Wasserstein & Lazar (2016), *ASA Statement on p-Values* — a declaração oficial da American Statistical Association sobre os usos indevidos.
- Gelman & Carlin (2014), *Beyond Power Calculations* — erros de tipo S e M.
- Ioannidis (2005), *Why Most Published Research Findings Are False*.
- Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* — a referência prática de A/B testing em escala industrial.