

Estatística Bayesiana

Atualizar crenças com dados, e finalmente poder dizer "95% de chance de o efeito estar aqui"

A inferência bayesiana troca a pergunta. Em vez de "com que frequência eu veria estes dados se não houvesse efeito?", ela pergunta "o que eu devo acreditar sobre o efeito, dado o que observei?". Este material constrói o teorema de Bayes desde a intuição, apresenta as famílias conjugadas que dão solução fechada, implementa MCMC do zero, e mostra por que a indústria migrou para o pensamento bayesiano em A/B testing, previsão de demanda e sistemas de decisão.

Nível: Intermediário

Pre-requisitos: Módulos 01 a 04 (Descritiva, Distribuições, Inferência, Testes)

Carga sugerida: 10 a 12 horas (leitura + 4 notebooks)

Notebooks: 01-teorema-de-bayes · 02-conjugadas-e-posteriori · 03-mcmc-do-zero · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. A troca de pergunta	3
1.1 O teorema, e o que cada termo faz	3
2. O exemplo que resolve a intuição: o teste médico	5
3. Prioris: o que são e como escolher	6
3.1 O que a priori faz com pouco e com muito dado	6
4. Famílias conjugadas: quando existe solução fechada	7
5. Intervalo de credibilidade × intervalo de confiança	8
6. MCMC: o que fazer quando não há conjugada	9
7. Por que a indústria migrou	10
8. O custo do método	11
9. Erros que custam caro — checklist	12
10. Para ir além	13

1. A troca de pergunta

Todo o módulo anterior girou em torno de uma quantidade: $P(\text{dados} | H_0)$. O p-valor responde "se a hipótese nula fosse verdadeira, com que frequência eu veria algo tão extremo?". É uma resposta honesta a uma pergunta que quase ninguém faz.

A pergunta que as pessoas realmente fazem é a inversa:

Dado o que eu observei, o que devo acreditar sobre o parâmetro?

Isto é, $P(\theta | \text{dados})$. Trocar uma condicional pela outra não é detalhe de notação — é uma mudança de objeto. E ela tem preço: para inverter a condicional você precisa declarar o que acreditava **antes** de ver os dados.

ANALOGIA

Pense em um diagnóstico médico. O exame tem 99% de sensibilidade — essa é a verossimilhança, $P(\text{positivo} | \text{doente})$. Mas o paciente quer saber $P(\text{doente} | \text{positivo})$, e essa depende criticamente de quão comum a doença é na população. Sem a prevalência, o resultado do exame é ininterpretável. A **prevalência é a priori**, e ela não é opcional: ignorá-la é assumir uma, geralmente uma absurda.

1.1 O teorema, e o que cada termo faz

$$P(\theta | D) = \frac{P(D | \theta) P(\theta)}{P(D)}$$

Termo	Nome	O que representa
$P(\theta)$	priori	o que você acreditava antes de ver os dados
$P(D \theta)$	verossimilhança	quão bem cada valor de θ explica os dados
$P(\theta D)$	posteriori	a crença atualizada — o objeto de interesse
$P(D)$	evidência	constante de normalização; garante que a posteriori integre 1

Na prática quase sempre se trabalha com a versão proporcional, porque $P(D)$ não depende de θ :

$$P(\theta | D) \propto P(D | \theta) \times P(\theta)$$

Em palavras: **posteriori** $\propto$ **verossimilhança** $\times$ **priori**.

FORMULARIO

A leitura operacional: a posteriori é a priori *reponderada* pela verossimilhança. Onde os dados são informativos, a verossimilhança é pontuda e domina; onde os dados são escassos, a priori sobrevive. O bayesiano não escolhe entre teoria e dados — ele especifica a taxa de câmbio entre as duas.

2. O exemplo que resolve a intuição: o teste médico

Uma doença atinge 1 em cada 1.000 pessoas. Existe um exame com 99% de sensibilidade e 99% de especificidade. Você testa positivo. Qual a chance de estar doente?

A resposta intuitiva — 99% — está errada por quase duas ordens de grandeza.

Em 100.000 pessoas: 100 têm a doença, e o exame acerta 99 delas. Das 99.900 saudáveis, o exame erra em 1%, produzindo **999 falsos positivos**. Entre os 1.098 positivos, apenas 99 estão doentes:

$$P(\text{doente} \mid +) = \frac{99}{99 + 999} \approx 9,0\%$$

ARMADILHA COMUM

Esse é o **erro da taxa-base**, e ele reaparece disfarçado em todo modelo de classificação de evento raro. Um detector de fraude com 99% de acurácia aplicado a uma base com 0,1% de fraude gera dez alarmes falsos para cada fraude verdadeira. É a mesma conta, e a razão pela qual precisão e recall existem: a acurácia esconde a taxa-base.

3. Prioris: o que são e como escolher

A objeção clássica à inferência bayesiana é que a priori é subjetiva. A resposta madura é que **toda análise tem uma priori** — a frequentista simplesmente não a declara. Máxima verossimilhança é matematicamente idêntica a inferência bayesiana com priori uniforme, o que é uma escolha, e frequentemente uma escolha ruim (uniforme em θ não é uniforme em $\log \theta$).

Tipo de priori	Quando usar	Exemplo
Informativa	há conhecimento sólido de domínio ou histórico	conversão histórica do site é 3% $\pm$ 0,5%
Fracamente informativa	você sabe a ordem de grandeza, não o valor	"o lift está entre -50% e +50%"
Não informativa / de referência	quer deixar os dados falarem	Jeffreys, uniforme no espaço adequado
Regularizadora	quer evitar estimativas absurdas com pouco dado	Beta(2,2) evita $\hat{p} = 0$ ou 1

NO MERCADO

Em A/B testing de e-commerce, usar a taxa de conversão histórica como priori Beta é o que impede um resultado de "0 conversões em 40 visitas" de virar uma estimativa de conversão zero. A priori informativa não é um viés escondido — é o histórico da empresa entrando na conta explicitamente, e auditável.

3.1 O que a priori faz com pouco e com muito dado

A propriedade que resolve a maior parte da ansiedade sobre subjetividade: conforme n cresce, a verossimilhança domina e prioris razoavelmente diferentes convergem para a mesma posteriori. Com $n = 10$, a priori manda; com $n = 10.000$, ela é irrelevante. A escolha da priori importa exatamente onde você tem pouco dado — que é onde declarar suas suposições importa mais.

4. Famílias conjugadas: quando existe solução fechada

Uma priori é **conjugada** para uma verossimilhança quando a posteriori pertence à mesma família da priori. Isso transforma inferência em aritmética.

Verossimilhança	Priori conjugada	Posteriori
Bernoulli / Binomial(p)	Beta(α, β)	Beta($\alpha + k, \beta + n - k$)
Poisson(λ)	Gama(α, β)	Gama($\alpha + \sum x_i, \beta + n$)
Normal(μ), σ conhecido	Normal(μ_0, τ_0^2)	Normal (média ponderada por precisão)
Exponencial(λ)	Gama(α, β)	Gama($\alpha + n, \beta + \sum x_i$)
Multinomial	Dirichlet(α)	Dirichlet($\alpha + \mathbf{k}$)

FORMULARIO

Beta-Binomial, o cavalo de batalha:

priori Beta(α, β) + k sucessos em n ensaios $\Rightarrow$ posteriori Beta($\alpha + k, \beta + n - k$).

Média posterior = $\frac{\alpha + k}{\alpha + \beta + n}$.

Interpretação de α e β : **pseudo-contagens**. Beta(3, 97) é literalmente "eu já vi 3 sucessos em 100 tentativas".

A conjugação Normal-Normal revela algo ainda mais bonito. Com priori $\mathcal{N}(\mu_0, \tau_0^2)$ e n observações de média $\bar{x}$ e variância conhecida σ^2 , a média posterior é

$$\mu_{\text{post}} = \frac{\frac{1}{\tau_0^2} \mu_0 + \frac{n}{\sigma^2} \bar{x}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}$$

— uma média ponderada entre a priori e os dados, com pesos iguais às **precisões** (inverso das variâncias). Quem tem menos incerteza pesa mais. É exatamente a fórmula do filtro de Kalman, e a mesma ideia por trás de regularização Ridge: a penalidade L2 **é** uma priori normal sobre os coeficientes.

5. Intervalo de credibilidade × intervalo de confiança

Esta é a diferença que mais importa na comunicação de resultados.

	Intervalo de confiança (95%)	Intervalo de credibilidade (95%)
Objeto aleatório	o intervalo	o parâmetro
Interpretação	95% dos intervalos assim construídos conteriam θ	há 95% de probabilidade de θ estar aqui
Depende de priori	não	sim
Frase legítima	"o procedimento acerta 95% das vezes"	"95% de chance de o efeito estar entre A e B"

O intervalo de credibilidade diz **exatamente** o que todo mundo já interpreta erradamente do intervalo de confiança. Existem duas construções comuns: o **intervalo de caudas iguais** (percentis 2,5 e 97,5 da posteriori) e o **HDI** (*highest density interval*), a região mais estreita que contém 95% da massa. Em posterioris assimétricas ou bimodais, o HDI é o resumo honesto.

6. MCMC: o que fazer quando não há conjugada

Fora dos casos conjugados, a posteriori não tem forma fechada — o denominador $P(D)$ é uma integral intratável em dimensão alta. A saída não é calcular a posteriori, e sim **amostrar** dela.

O algoritmo de **Metropolis-Hastings** é surpreendentemente simples:

- 1 Comece em um valor qualquer θ_t .
- 2 Proponha $\theta^* \sim q(\cdot | \theta_t)$ (por exemplo, um passo gaussiano).
- 3 Calcule a razão $r = \frac{P(D | \theta^*)P(\theta^*)}{P(D | \theta_t)P(\theta_t)}$.
- 4 Aceite θ^* com probabilidade $\min(1, r)$; senão, fique onde está.
- 5 Repita.

O denominador $P(D)$ **cancela na razão** — é por isso que o método funciona sem nunca calcular a integral. Após um período de aquecimento (*burn-in*), as amostras vêm da posteriori.

ARMADILHA COMUM

MCMC não avisa quando falha. Cadeia presa em uma moda, taxa de aceitação de 2% ou de 95%, autocorrelação altíssima — em todos esses casos o algoritmo devolve números com toda a confiança. **Sempre diagnostique:** trace plot (deve parecer ruído branco, não um passeio), $\hat{R} < 1,01$ entre múltiplas cadeias, e tamanho efetivo de amostra (ESS) na casa das centenas no mínimo. Taxa de aceitação-alvo: ~23% para passeio aleatório multivariado, ~44% em uma dimensão.

Ferramentas modernas (Stan, PyMC, NumPyro) usam **HMC/NUTS**, que aproveita o gradiente da log-posteriori para propor saltos longos e bem direcionados em vez de tatear. A diferença de eficiência em dimensão alta é de ordens de grandeza — mas a lógica de aceitar/rejeitar continua sendo a de Metropolis.

7. Por que a indústria migrou

NO MERCADO

A/B testing bayesiano. A pergunta do time de produto nunca foi "rejeitamos H_0 ?", e sim "qual a chance de B ser melhor que A, e quanto eu perco se escolher errado?". A posteriori responde as duas diretamente: $P(p_B > p_A)$ é uma média sobre amostras, e a **perda esperada** de escolher a variante errada é calculável. Além disso, não há problema de *peeking*: a posteriori é válida a qualquer momento, porque não há taxa de erro de longo prazo sendo controlada.

Outros lugares onde o pensamento bayesiano venceu:

- **Multi-armed bandits** (Thompson Sampling): alocar tráfego proporcionalmente à probabilidade de cada variante ser a melhor. Ganha dinheiro durante o experimento, em vez de esperar o fim.
- **Modelos hierárquicos**: estimar conversão por loja, região ou usuário com *shrinkage* automático — lojas com pouco dado são puxadas para a média global. É a solução principiada para o problema de "essa loja converteu 100%, com 2 visitas".
- **Previsão de demanda e séries temporais** (Prophet, modelos de espaço de estados): incerteza propagada corretamente até o horizonte de previsão.
- **Deep learning**: dropout como aproximação bayesiana, ensembles profundos e quantificação de incerteza em modelos de decisão crítica.

8. O custo do método

Ser justo com as objeções:

- **Escolher priori dá trabalho** e exige defender a escolha. Análise de sensibilidade (rodar com 2 ou 3 prioris) deixa de ser opcional.
- **Custo computacional.** MCMC em modelo grande leva minutos a horas, contra milissegundos de um `fit` frequentista.
- **Diagnóstico é obrigatório** e é uma competência a mais.
- **Comunicação:** parte do público espera p-valor, e "probabilidade de o efeito ser positivo" precisa ser explicada.

Nenhuma dessas é razão para não usar. São razões para usar com disciplina.

FORMULARIO

Resumo operacional

Posteriori $\propto$ verossimilhança $\times$ priori.

Beta-Binomial: $\text{Beta}(\alpha + k, \beta + n - k)$. **Gama-Poisson:** $\text{Gama}(\alpha + \sum x_i, \beta + n)$.

Normal-Normal: média ponderada pelas precisões $1/\tau_0^2$ e n/σ^2 .

Metropolis-Hastings: aceite com $\min\left(1, \frac{\mathcal{L}(\theta^*)\pi(\theta^*)}{\mathcal{L}(\theta_i)\pi(\theta_i)}\right)$.

Diagnóstico mínimo: $\hat{R} < 1,01$, ESS > 400, aceitação 20–50%.

9. Erros que custam caro — checklist

- Usar priori informativa forte sem declarar e sem análise de sensibilidade.
- Reportar o intervalo de credibilidade como se fosse de confiança (ou vice-versa).
- Rodar MCMC sem olhar trace plot nem $\hat{R}$.
- Interpretar $P(p_B > p_A) = 0,93$ como "93% de lift" — é probabilidade de ser melhor, não magnitude do efeito.
- Esquecer a taxa-base ao interpretar um classificador de evento raro.
- Usar priori uniforme achando que é "neutra" — ela não é invariante a reparametrização.
- Escolher a priori depois de ver os dados.

10. Para ir além

- McElreath, *Statistical Rethinking* — o melhor livro-texto de inferência

bayesiana aplicada que existe, com código.

- Gelman et al., *Bayesian Data Analysis* (BDA3) — a referência canônica.
- Kruschke, *Doing Bayesian Data Analysis* — didático, forte em HDI e ROPE.
- Documentação do Stan sobre *prior choice recommendations* — o guia prático mais usado para escolher prioris fracamente informativas.