

A/B Testing e Desenho Experimental

A engenharia de fazer o experimento valer, antes de qualquer análise

A maior parte dos experimentos em produção não falha na análise — falha no desenho. Este material trata A/B testing como problema de engenharia: unidade de aleatorização, escolha de métricas, dimensionamento, os testes de sanidade que detectam um experimento inválido, técnicas de redução de variância como CUPED e estratificação, e o catálogo de armadilhas (SRM, peeking, efeito novidade, interferência entre unidades) que invalidam resultados aparentemente limpos.

Nível: Intermediário

Pre-requisitos: Módulos 01 a 05 (Descritiva, Distribuições, Inferência, Testes, Bayesiana)

Carga sugerida: 10 a 12 horas (leitura + 4 notebooks)

Notebooks: 01-desenho-e-aleatorizacao · 02-analise-de-experimento · 03-cuped-e-variancia · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que experimentar	3
2. A unidade de aleatorização	4
3. Métricas: a hierarquia que evita autoengano	5
3.1 Métricas proxy e o horizonte do teste	5
4. Dimensionamento: decidir antes, não depois	6
5. Os testes de sanidade que salvam a análise	7
5.1 Sample Ratio Mismatch (SRM)	7
5.2 Teste A/A	7
5.3 Checagem de pré-experimento	7
6. Redução de variância: mais poder sem mais tráfego	8
6.1 CUPED (Controlled-experiment Using Pre-Experiment Data)	8
6.2 Outras técnicas	8
7. O catálogo de armadilhas	9
8. Intenção de tratar × efeito no tratado	10
9. Erros que custam caro — checklist	11
10. Para ir além	12

1. Por que experimentar

Toda análise observacional sofre do mesmo problema: quem escolheu usar o recurso novo é diferente de quem não escolheu, em dezenas de dimensões que você não mediu. Comparar os dois grupos mede a diferença entre as **pessoas**, não o efeito do **recurso**.

A aleatorização resolve isso de um jeito que nenhum controle estatístico consegue: ao sortear quem recebe o tratamento, você garante que os dois grupos são equivalentes em **tudo** — inclusive nas variáveis que você nem sabe que existem. É a única técnica que controla confundidores não observados.

ANALOGIA

Aleatorizar é embaralhar o baralho antes de distribuir. Não importa o quanto as cartas estavam ordenadas antes; depois do embaralhamento, qualquer diferença sistemática entre as mãos foi eliminada por construção. Se uma mão vencer consistentemente, a causa está no que você fez com ela depois — não em como as cartas chegaram.

O preço é que experimentar custa tempo, tráfego e disciplina. E o retorno só existe se o desenho estiver certo — uma análise impecável de um experimento mal desenhado produz um número preciso e errado.

2. A unidade de aleatorização

A primeira decisão, e a que mais gente erra.

Unidade	Quando usar	Risco
Usuário (mais comum)	mudanças de UI, features, preço	precisa de identidade estável entre sessões
Sessão	mudanças que não persistem	mesma pessoa vê versões diferentes — inconsistência visível
Cluster (loja, cidade, empresa)	efeitos de rede, marketplaces	perde muito poder; n efetivo é o número de clusters
Tempo (switchback)	logística, precificação dinâmica	contaminação entre períodos

A regra: aleatorize na **menor unidade que não gere interferência** entre tratamento e controle. Se o efeito de tratar um usuário vaza para outro — redes sociais, marketplaces, sistemas de entrega — a suposição de independência quebra e a estimativa fica viesada.

ARMADILHA COMUM

Interferência (SUTVA violada). Em um marketplace, dar desconto ao grupo B faz o grupo A perder as ofertas que B comprou. O efeito medido não é "o que acontece se todos receberem o desconto" — é "o que acontece a quem recebe, às custas de quem não recebe". Testes de preço, algoritmos de matching e mudanças de ranking sofrem disso quase sempre, e a saída é aleatorizar por região, por mercado ou por período.

3. Métricas: a hierarquia que evita autoengano

Um experimento tem uma métrica primária, algumas secundárias e um conjunto de guardrails. Escolher tudo isso **antes** de ver os dados é o que separa um experimento de uma pescaria.

- **Métrica primária** (uma só): a que decide o lançamento. Deve ser sensível ao tratamento, mensurável no horizonte do teste, e alinhada ao objetivo real.
- **Métricas secundárias**: ajudam a entender o mecanismo. Não decidem nada sozinhas.
- **Guardrails**: métricas que não podem piorar, mesmo que a primária melhore — tempo de carregamento, taxa de erro, receita, cancelamentos, reclamações.

NO MERCADO

A tensão clássica: uma mudança que aumenta cliques em 8% e derruba a receita por sessão em 2%. Sem guardrail de receita, o experimento é declarado vencedor e a empresa perde dinheiro por trimestres até alguém notar. Times maduros bloqueiam o lançamento automaticamente quando um guardrail degrada além de um limite pré-definido.

3.1 Métricas proxy e o horizonte do teste

O que interessa (retenção em 12 meses, LTV) não cabe em um experimento de duas semanas. A saída é usar **proxies** — mas proxies precisam ser validados contra o resultado de longo prazo em experimentos anteriores, não escolhidos por conveniência. Uma proxy não validada é uma hipótese disfarçada de métrica.

4. Dimensionamento: decidir antes, não depois

O tamanho de amostra sai de quatro números: efeito mínimo relevante (MDE), variância da métrica, α e poder desejado.

FORMULARIO

Para comparar duas médias com variância σ^2 :

$$n \approx \frac{2\sigma^2(z_{1-\alpha/2} + z_{1-\beta})^2}{\Delta^2} \text{ por grupo.}$$

Com $\alpha = 0,05$ e poder de 80%, o numerador constante vale $\approx 15,7$, então $n \approx 15,7 \sigma^2 / \Delta^2$.

Para proporções, $\sigma^2 = p(1 - p)$.

O **MDE não é o efeito que você espera** — é o menor efeito que mudaria a decisão de negócio. Definir MDE de 0,5% quando a empresa só implantaria uma mudança que rendesse 3% é queimar tráfego para responder uma pergunta que ninguém fez.

ARMADILHA COMUM

Análise de poder post-hoc. Calcular "o poder que tivemos" a partir do efeito observado é uma reescrita do p-valor, não informação nova. O poder é uma propriedade do **desenho**, e só existe antes do experimento.

5. Os testes de sanidade que salvam a análise

Antes de olhar a métrica primária, verifique se o experimento é válido.

5.1 Sample Ratio Mismatch (SRM)

Se a alocação era 50/50 e você observa 50,4% / 49,6% com 200 mil usuários, o experimento está quebrado. Um qui-quadrado de aderência responde em uma linha.

SRM é o sintoma, não a doença. As causas típicas: bots atribuídos a um grupo só, falha no SDK que descarta eventos de uma variante, redirecionamento que perde usuários, filtro aplicado depois da aleatorização.

ARMADILHA COMUM

Um experimento com SRM não pode ser analisado, ponto. Não existe correção estatística — a aleatorização falhou, e você não sabe *quem* foi perdido. A única ação é achar a causa e refazer.

5.2 Teste A/A

Rode a mesma versão contra ela mesma. Você deveria observar p-valores uniformes e ~5% de "significância" espúria. Se der significativo com frequência maior, há algo errado na infraestrutura — atribuição, logging ou a própria métrica.

5.3 Checagem de pré-experimento

Compare os grupos em métricas **anteriores** ao tratamento. Elas devem ser indistinguíveis. Diferença pré-existente significa aleatorização quebrada ou contaminação.

6. Redução de variância: mais poder sem mais tráfego

Como $n \propto \sigma^2$, cortar a variância pela metade tem o mesmo efeito que dobrar a amostra — de graça.

6.1 CUPED (Controlled-experiment Using Pre-Experiment Data)

A ideia: use uma covariável X medida **antes** do experimento (tipicamente a mesma métrica no período anterior) para remover a variabilidade que já existia.

FORMULARIO

$$Y_{\text{cuped}} = Y - \theta(X - \bar{X}), \text{ com } \theta = \frac{\text{Cov}(Y, X)}{\text{Var}(X)}.$$

A variância cai por um fator $(1 - \rho^2)$, onde ρ é a correlação entre Y e X . Com $\rho = 0,7$, a variância cai 51% — equivalente a dobrar o tráfego.

CUPED é não-viesado porque X é anterior ao tratamento e, portanto, não pode ter sido afetado por ele. Essa é a condição inegociável: **qualquer covariável medida depois da aleatorização pode ser um colisor e enviesar o resultado**.

6.2 Outras técnicas

- **Estratificação / aleatorização por blocos**: garante balanceamento em variáveis conhecidas (plataforma, país, segmento) em vez de torcer por ele.
- **Winsorização** de métricas de cauda pesada (receita, tempo na página): apara o 0,1% superior antes de analisar. Reduz variância enormemente, mas muda o estimando — declare que você está estimando uma média winsorizada.
- **Regressão com covariáveis** (CUPAC): generalização do CUPED usando um modelo preditivo treinado em dados pré-experimento.

7. O catálogo de armadilhas

Armadilha	O que acontece	Defesa
Peeking	parar ao ver significância infla o erro tipo I para ~20%	duração fixa, ou teste sequencial (O'Brien-Fleming, always-valid)
SRM	alocação desbalanceada denuncia perda de dados	qui-quadrado antes de tudo; abortar se falhar
Efeito novidade	usuários reagem à mudança, não ao valor dela	rodar tempo suficiente; olhar o efeito por semana
Comparações múltiplas	20 segmentos $\Rightarrow$ 64% de chance de falso positivo	métrica primária declarada; FDR nos exploratórios
Interferência	tratamento vaza para o controle	aleatorizar por cluster/região/tempo
Simpson	efeito positivo em cada segmento, negativo no total	checar composição dos grupos; usar médias ponderadas
Métrica de razão	usuário com 1.000 eventos domina a média	delta method ou bootstrap por usuário
Sobrevivência	analisar só quem completou o funil	analisar por intenção de tratar (ITT)

NO MERCADO

A regra de ouro da indústria (Kohavi, na Microsoft e Airbnb): a **maioria** das ideias testadas não melhora a métrica. Na Bing, cerca de um terço dos experimentos dá resultado positivo, um terço neutro e um terço negativo. Um time cujo A/B test "sempre dá positivo" não tem boas ideias — tem um problema de método.

8. Intenção de tratar × efeito no tratado

Se 30% dos usuários alocados ao tratamento nunca chegaram a ver a mudança, comparar "quem viu" com todo o controle é comparar grupos não equivalentes — quem viu é quem chegou mais fundo no funil.

A análise correta por padrão é a de **intenção de tratar (ITT)**: compare os grupos **como alocados**, independentemente do que aconteceu depois. O ITT subestima o efeito em quem realmente foi exposto, mas é a única estimativa não viesada. Para recuperar o efeito no tratado, existe o estimador **CACE/LATE**, que divide o efeito ITT pela taxa de adesão — com suas próprias suposições.

FORMULARIO

$$\text{CACE} = \frac{\text{efeito ITT}}{\text{taxa de adesão}}, \text{ válido sob exclusão (a alocação só afeta o resultado via o tratamento) e ausência de } \textit{defiers}.$$

9. Erros que custam caro — checklist

- Analisar antes de checar SRM.
- Parar o teste ao ver significância.
- Escolher a métrica primária depois de ver os resultados.
- Definir MDE pelo efeito esperado em vez do efeito relevante.
- Ignorar guardrails porque a primária subiu.
- Usar covariável pós-tratamento em CUPED ou em regressão de ajuste.
- Analisar só quem completou o funil, em vez de ITT.
- Fatiar por segmento até achar um resultado positivo.
- Rodar uma semana e generalizar para o ano (sazonalidade, efeito novidade).
- Extrapolar um efeito de 2 semanas para LTV sem proxy validada.

10. Para ir além

- Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* — a referência prática definitiva, escrita por quem rodou dezenas de milhares de experimentos.
- Deng et al. (2013), **Improving the Sensitivity of Online Controlled Experiments by Utilizing Pre-Experiment Data** — o artigo original do CUPED.
- Fabijan et al., **Diagnosing Sample Ratio Mismatch in Online Controlled Experiments** — o catálogo de causas de SRM.
- Johari et al., *Always Valid Inference* — a base dos testes sequenciais modernos que permitem espiar sem inflar erro.