

Análise Exploratória (EDA)

O protocolo que decide se o resto do projeto vale a pena

Análise exploratória não é a etapa que se apressa para "chegar logo no modelo" — é onde se descobre se o dado sustenta a pergunta de negócio, onde vazamentos e armadilhas são pegos antes de custarem caro, e onde nascem as hipóteses que o modelo vai testar. Este material constrói um protocolo disciplinado de EDA e as ferramentas de correlação e associação que sustentam suas conclusões.

Nível: Introdutório a Intermediário

Pre-requisitos: Estatística descritiva (tema 1); noções de pandas

Carga sugerida: 6 a 8 horas (leitura + 2 notebooks)

Notebooks: 01-protocolo-de-eda · 02-relacoes-e-correlacao · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. O protocolo: da estrutura ao conteúdo	4
2.1 Etapa 1 — Forma e proveniência	4
2.2 Etapa 2 — Perfilamento univariado	4
2.3 Etapa 3 — Relações entre variáveis	5
2.4 Etapa 4 — Hipóteses e checagem de vazamento	5
3. Correlação e associação: escolhendo a ferramenta certa	6
3.1 Pearson: mede só a parte linear	6
3.2 Spearman: mede a parte monotônica	6
3.3 Qui-quadrado e Cramér's V: associação entre categóricas	7
3.4 ANOVA e η^2 : associação entre categórica e numérica	7
3.5 Informação mútua: quando nem "monotônico" é garantido	7
4. O paradoxo de Simpson: quando agregação mente	9
5. Erros que custam caro — checklist	10
6. Para ir além	11

1. Por que este módulo existe

A maioria dos projetos de dados que falha, falha silenciosamente muito antes do modelo: uma coluna de data importada como texto, um identificador de cliente tratado como feature numérica, uma variável que na verdade é o próprio alvo disfarçado, um grupo de outliers que representa um segmento de negócio inteiro sendo descartado como "ruído". Nenhum desses problemas aparece na acurácia do modelo — eles aparecem, meses depois, como "por que o modelo em produção está errando tanto".

ANALOGIA

EDA é a inspeção do terreno antes de construir. Um engenheiro não começa a erguer paredes sem saber se o solo é rocha ou areia movediça. Um cientista de dados que pula a EDA está apostando que o "solo" dos dados é firme — às vezes é, e o projeto sai barato dessa aposta; frequentemente não é.

1.1 O que você vai conseguir fazer ao final

- Executar um protocolo de EDA reproduzível, sem depender de "olhar e ver o que aparece".
 - Escolher a medida de correlação/associação certa para cada combinação de tipos de variável (numérica-numérica, categórica-categórica, categórica-numérica).
 - Reconhecer quando correlação linear esconde uma relação real, e quando uma correlação alta esconde uma relação espúria.
 - Detectar, antes de modelar, os sinais mais comuns de vazamento de dados e de paradoxo de agregação (Simpson).
-

2. O protocolo: da estrutura ao conteúdo

EDA disciplinada segue uma ordem: primeiro entender a **forma** dos dados, depois o **conteúdo** de cada variável isolada, depois as **relações** entre variáveis. Pular etapas custa caro — é comum alguém já estar plotando correlações quando ainda nem sabe que 30% de uma coluna são nulos.

2.1 Etapa 1 — Forma e proveniência

- Quantas linhas, quantas colunas, qual o período coberto.
- **Cada linha é o quê?** Uma transação? Um cliente-mês? Essa pergunta parece

óbvia e é a que mais gente erra — confundir a granularidade da linha é a origem de metade dos bugs de agregação.

- Duplicatas exatas e **quase-duplicatas** (mesmo cliente, registros quase idênticos por erro de captura).
- Tipos de dado (**dtype**) — e se eles batem com o tipo **real** da variável (revisite a taxonomia do tema 1: nominal, ordinal, intervalar, razão).

ARMADILHA COMUM

Um identificador (`id_cliente`, `cpf`, `cep`) armazenado como `int64` passa despercebido por qualquer `.describe()` e o pandas calcula média e desvio-padrão dele sem reclamar. O resultado é sintaticamente válido e completamente sem sentido. Sempre audite: toda coluna numérica **é** mesmo uma quantidade, ou é um rótulo disfarçado de número?

2.2 Etapa 2 — Perfilamento univariado

Para cada variável, isoladamente:

- **Numéricas:** distribuição (histograma), medidas de posição e dispersão robustas e não-robustas (tema 1), fração de nulos, fração de zeros (frequentemente um valor "especial" disfarçado de número comum).
- **Catégoricas:** cardinalidade (quantas categorias distintas), frequência de cada categoria, categorias raras (que podem precisar de agrupamento antes de qualquer encoding — assunto do módulo 4).
- **Datas:** intervalo coberto, buracos no tempo, granularidade real (timestamps ou só dia?).

NO MERCADO

Cardinalidade alta em uma coluna categórica (`id_produto` com 50.000 valores únicos) não é um problema de EDA — é um aviso antecipado de um problema de **encoding**: one-hot nessa coluna criaria 50.000 novas colunas. Detectar isso agora, e não na hora de treinar o modelo, economiza retrabalho.

2.3 Etapa 3 — Relações entre variáveis

Aqui entra a maior parte deste módulo: como medir associação entre pares de variáveis de tipos diferentes, e como não se enganar com o resultado. Isso é desenvolvido em detalhe nas próximas seções.

2.4 Etapa 4 — Hipóteses e checagem de vazamento

EDA termina em **perguntas testáveis**, não em gráficos bonitos:

- Que variáveis parecem separar bem a classe/alvo de interesse?
- Existe alguma variável **suspeitosamente** preditiva? (Um sinal clássico de

vazamento: uma feature que só existe **depois** do evento que se quer prever, ou que é uma proxy quase perfeita do alvo.)

- As relações fazem sentido de negócio, ou parecem artefato de coleta?

ARMADILHA COMUM

"Essa feature tem correlação de 0,98 com o alvo" quase nunca é boa notícia antes de investigada — é mais frequentemente vazamento (`data_de_cancelamento` presente nas features de um modelo de previsão de cancelamento) do que um sinal genuinamente forte. Correlação alta demais deve aumentar a suspeita, não a confiança.

3. Correlação e associação: escolhendo a ferramenta certa

A tabela a seguir resume o problema central desta seção: **não existe uma única "correlação"** — existe uma família de medidas, cada uma adequada a um tipo de par de variáveis e a um tipo de relação.

Par de variáveis	Relação linear	Relação monotônica (não-linear)	Relação qualquer
Numérica × Numérica	Pearson	Spearman	Informação mútua
Categórica × Categórica	—	Qui-quadrado / Cramér's V	Informação mútua
Categórica × Numérica	ANOVA (F) / eta ²	—	Informação mútua

3.1 Pearson: mede só a parte linear

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

Já visto no tema 2 como cosseno de vetores centrados. r mede **apenas** o grau de relação linear — uma relação perfeita, porém curva, pode ter r próximo de zero.

3.2 Spearman: mede a parte monotônica

Spearman calcula Pearson sobre os **postos** (ranks) dos dados em vez dos valores brutos. O resultado: captura qualquer relação **monotônica** (sempre crescente ou sempre decrescente), mesmo que não seja uma reta.

DEFINIÇÃO

$\rho_{\text{Spearman}} = r_{\text{Pearson}}(\text{posto}(x), \text{posto}(y))$. Uma relação exponencial $y = e^x$ tem Spearman igual a 1 (é estritamente crescente) mas Pearson bem menor que 1 (a curva se afasta da reta).

NO MERCADO

Spearman é mais robusto a outliers que Pearson, pelo mesmo motivo que a mediana é mais robusta que a média: postos ignoram *quão* extremo um valor é, só a sua ordem. É a escolha padrão quando a relação é suspeita de não ser linear, ou quando há outliers que distorceriam Pearson.

3.3 Qui-quadrado e Cramér's V: associação entre categóricas

Para duas variáveis categóricas, organiza-se uma **tabela de contingência** (contagens cruzadas) e compara-se com o que se esperaria se as variáveis fossem independentes. O teste qui-quadrado de independência mede o quanto essa diferença é estatisticamente significativa; **Cramér's V** normaliza a estatística para um número entre 0 e 1, comparável entre tabelas de tamanhos diferentes:

$$V = \sqrt{\frac{\chi^2/n}{\min(k-1, r-1)}}$$

onde r e k são o número de linhas e colunas da tabela de contingência.

NOTA

χ^2 (qui-quadrado) sozinho cresce com o tamanho da amostra — não é comparável entre datasets de tamanhos diferentes. Cramér's V corrige isso e é a medida que de fato se reporta como "força de associação" entre duas categóricas.

3.4 ANOVA e eta²: associação entre categórica e numérica

Quando uma variável é categórica (grupo) e a outra numérica, a pergunta é: a média da numérica muda entre grupos mais do que se esperaria por acaso? O teste F da ANOVA responde a parte de significância; **eta² (η^2)** mede a **força** — a fração da variância total da variável numérica que é explicada pela pertença ao grupo:

$$\eta^2 = \frac{\text{SQ entre grupos}}{\text{SQ total}}$$

NOTA

Essa é literalmente a mesma decomposição de soma de quadrados (Pitágoras no espaço das observações) construída no módulo de projeção ortogonal do tema 2 — ANOVA é um caso particular de regressão linear com uma feature categórica.

3.5 Informação mútua: quando nem "monotônico" é garantido

A **informação mútua** mede quanta incerteza sobre Y é reduzida ao conhecer X , sem assumir nenhuma forma funcional específica — linear, monotônica, ou qualquer outra. Captura, por exemplo, uma relação em U (onde Y é grande tanto para X pequeno quanto para X grande), que Pearson e Spearman veem como "sem relação".

ARMADILHA COMUM

Informação mútua não tem um teto natural comparável entre pares de variáveis (ao contrário de Pearson/Spearman, limitados a $[-1, 1]$, ou Cramér's V, limitado a $[0, 1]$), e é mais sensível ao tamanho da amostra e ao método de estimação. Use-a para **descobrir** relações que as medidas clássicas não veem — não para comparar "força" de relações diferentes de forma direta.

4. O paradoxo de Simpson: quando agregação mente

Uma correlação pode **inverter de sinal** quando os dados são desagregados por um grupo escondido. O exemplo clássico: uma universidade parece favorecer homens nas admissões gerais, mas, dentro de **cada departamento**, favorece mulheres — porque mulheres se candidatam desproporcionalmente aos departamentos mais concorridos.

ARMADILHA COMUM

Toda vez que uma relação parece forte demais para fazer sentido, ou contrária à intuição de negócio, pergunte: **existe uma variável de agrupamento que, se eu controlar por ela, muda a conclusão?** Isso não é paranoia — é o motivo pelo qual EDA sempre deve incluir a relação **dentro de subgrupos relevantes**, não só agregada.

5. Erros que custam caro — checklist

- Calcular `.describe()` em colunas que são identificadores, não quantidades.
- Reportar Pearson como "a" correlação sem checar se a relação é não-linear.
- Ignorar cardinalidade alta em categóricas até a hora de treinar o modelo.
- Aceitar uma correlação altíssima com o alvo sem investigar vazamento.
- Analisar dados agregados sem checar se a conclusão se sustenta dentro de subgrupos (Simpson).
- Confundir "sem correlação de Pearson" com "sem relação" — Anscombe e o Datasaurus (tema 1) já provaram que isso é falso.
- Pular a etapa de "o que é uma linha" e descobrir tarde que o dataset tem granularidade diferente da esperada.

6. Para ir além

- Tukey, *Exploratory Data Analysis* — o texto fundador da área, ainda relevante.
- Wickham & Grolemund, *R for Data Science*, capítulos de EDA — o protocolo mais citado da prática moderna (as ideias são independentes de linguagem).
- Anscombe (1973) e Matejka & Fitzmaurice (2017, *Datasaurus*) — os dois artigos que provam visualmente por que resumos numéricos não bastam.