

Dados Faltantes e Outliers

O buraco no dado e o ponto fora da curva — e por que nenhum dos dois tem uma resposta universal

"Preencher com a média" e "remover outliers" são os dois reflexos mais automáticos — e mais perigosos — da preparação de dados. Este material constrói o vocabulário certo para diagnosticar por que um dado falta (MCAR, MAR, MNAR) antes de decidir como preenchê-lo, e mostra que um outlier pode ser um erro de digitação ou o cliente mais importante da base — e só a investigação, não uma regra fixa, separa os dois casos.

Nível: Intermediário — requer o módulo de EDA deste tema

Pre-requisitos: Análise Exploratória (EDA); estatística descritiva (tema 1)

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-mecanismos-de-ausencia · 02-estrategias-de-imputacao · 03-outliers · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. Os três mecanismos de ausência	4
2.1 Como diagnosticar (na prática, sem certeza absoluta)	4
3. Estratégias de imputação	5
3.1 Simples: média, mediana, moda	5
3.2 KNN: usar vizinhos parecidos	5
3.3 Múltipla (MICE): a resposta ao problema da incerteza escondida	5
4. Outliers: o problema da definição	7
4.1 Métodos de detecção	7
4.2 O que fazer depois de detectar	7
5. Erros que custam caro — checklist	9
6. Para ir além	10

1. Por que este módulo existe

`df.fillna(df.mean())` é uma linha de código que qualquer pessoa escreve no primeiro dia. É também uma decisão estatística que pode destruir a variância dos dados, introduzir viés sistemático, e — no pior caso — vaziar informação do futuro para o passado. O mesmo vale para outliers: `df[df.z_score.abs() < 3]` parece higiene de dados, mas às vezes está removendo exatamente os casos que o negócio mais precisa entender (fraude, clientes VIP, falhas de equipamento).

ANALOGIA

Um dado faltante é uma pergunta não respondida numa pesquisa. A forma certa de lidar com ela depende de **por que** ela não foi respondida: a pessoa esqueceu (aleatório), a pergunta não se aplicava a ela (estrutural), ou ela evitou responder de propósito porque a resposta era constrangedora (e aí a ausência **é**, ela mesma, uma informação). Tratar os três casos da mesma forma é jogar fora exatamente a informação que mais importa no terceiro caso.

1.1 O que você vai conseguir fazer ao final

- Classificar um padrão de dado faltante em MCAR, MAR ou MNAR, e explicar por que essa classificação muda a estratégia de tratamento.
- Escolher entre imputação simples, por KNN e múltipla (MICE), com justificativa, não por hábito.
- Detectar outliers com métodos robustos e não-robustos, e saber quando cada um falha.
- Decidir — com um processo, não um reflexo — se um outlier deve ser removido, capado, transformado ou preservado.

2. Os três mecanismos de ausência

A literatura de Rubin (1976) formalizou três mecanismos, e a diferença entre eles é a coisa mais importante deste módulo.

DEFINIÇÃO

MCAR (Missing Completely At Random): a probabilidade de faltar não depende de nada — nem do próprio valor, nem de outras variáveis. Exemplo: um sensor que falha aleatoriamente por instabilidade de rede.

MAR (Missing At Random): a probabilidade de faltar depende de **outras variáveis observadas**, mas não do próprio valor faltante (depois de controlar por essas outras variáveis). Exemplo: clientes mais velhos têm mais chance de não preencher o campo "e-mail" — a ausência depende da idade (observada), não do valor do e-mail em si.

MNAR (Missing Not At Random): a probabilidade de faltar depende do **próprio valor que falta**. Exemplo: pessoas com renda muito alta ou muito baixa têm mais chance de não responder "qual sua renda?" numa pesquisa — a ausência carrega informação sobre o valor ausente.

ARMADILHA COMUM

MNAR é o caso mais comum em dados de negócio e o mais ignorado. "Cliente não avaliou o produto" é frequentemente MNAR: clientes com experiências medianas avaliam menos que os muito satisfeitos ou muito insatisfeitos. Imputar essa ausência com a média das avaliações existentes produz um viés sistemático — porque quem respondeu não é uma amostra aleatória de quem não respondeu.

2.1 Como diagnosticar (na prática, sem certeza absoluta)

Não existe um teste que prove MNAR — a própria natureza do problema (o valor que falta é desconhecido) impede verificação direta. O que se pode fazer:

- 1 **Testar se a ausência de uma variável se associa com outras variáveis observadas** (uma regressão logística de "é nulo?" contra as demais colunas). Associação forte sugere MAR (ou MNAR, se a variável associada for um proxy do próprio valor ausente).
- 2 **Buscar padrões estruturais:** nulo que ocorre exatamente quando outra coluna tem um valor específico costuma ser ausência **estrutural**, não uma das três categorias de Rubin — é o caso de "data de cancelamento" ser nula para quem nunca cancelou, visto no módulo anterior.
- 3 **Considerar o processo de negócio:** entender como o dado é coletado costuma revelar o mecanismo mais rápido do que qualquer teste estatístico.

3. Estratégias de imputação

3.1 Simples: média, mediana, moda

Rápidas e frequentemente um baseline razoável — mas com um efeito colateral sistemático: **reduzem artificialmente a variância** da coluna (todo valor imputado é idêntico, então a dispersão em torno dele desaparece) e podem **atenuar correlações** com outras variáveis.

FORMULARIO

Se $p\%$ dos valores de uma coluna são substituídos pela média, a variância observada da coluna cai para aproximadamente $(1-p)$ vezes a variância real — a fração de dados imputados vira "achatamento" artificial. Modelos que dependem de variância (e quase todos dependem) recebem um sinal distorcido exatamente na proporção de dados faltantes.

NO MERCADO

Uma prática que mitiga (não elimina) o problema: além de imputar, criar uma coluna binária indicadora `_era_nulo`. Isso preserva, como uma feature explícita, a informação "esse valor foi observado ou inferido" — útil sobretudo quando a ausência é MAR ou MNAR e carrega sinal preditivo por si só.

3.2 KNN: usar vizinhos parecidos

`KNNImputer` preenche um valor faltante com a média (ponderada pela distância) dos k vizinhos mais próximos, usando as demais colunas para medir similaridade. Captura relações locais que a média global ignora, mas herda todos os problemas de distância vistos no tema 2: **exige padronizar antes**, e é sensível à maldição da dimensionalidade em datasets com muitas colunas.

3.3 Múltipla (MICE): a resposta ao problema da incerteza escondida

Toda imputação simples comete um erro conceitual: trata o valor imputado como se fosse **conhecido com certeza**, quando na verdade é uma estimativa. A **imputação múltipla por equações encadeadas** (MICE — *Multiple Imputation by Chained Equations*, implementada em `sklearn` como `IterativeImputer`) modela cada coluna com nulos como uma regressão nas demais colunas, de forma iterativa, e — na formulação completa — gera **várias** versões imputadas do dataset, cuja variação entre si estima a incerteza da imputação.

NOTA

O `IterativeImputer` do `sklearn`, usado de forma direta (uma imputação só, não múltiplas), já é uma melhoria substancial sobre a média: modela relações entre colunas em vez de ignorá-las. A imputação **múltipla** completa (combinar resultados de vários datasets imputados, com regras de Rubin para agregar) é mais rigorosa estatisticamente e mais rara na prática de mercado do que deveria ser — o custo de implementação correto costuma perder para "roda rápido e destrava o projeto".

ARMADILHA COMUM

Ajustar qualquer imputador (média, KNN, MICE) usando o dataset **inteiro**, antes de separar treino e teste, vaza informação do conjunto de teste para o de treino — o imputador "viu" estatísticas de dados que deveria ignorar. Sempre ajuste (`fit`) o imputador **só no treino**, e aplique (`transform`) da mesma forma no teste. Isso é o mesmo princípio de vazamento que o módulo 4 formaliza com `Pipeline`.

4. Outliers: o problema da definição

Não existe uma definição única e objetiva de outlier — existe um conjunto de regras que sinalizam candidatos, e sempre uma decisão que exige contexto.

4.1 Métodos de detecção

Método	Fórmula / regra	Robustez
Z-score	$\text{abs}(x - \bar{x})/s > 3$	Baixa — média e desvio-padrão são sensíveis a outliers
Z-score modificado	$0.6745\text{abs}(x - \text{mediana})/\text{MAD} > 3.5$	Alta — usa mediana e MAD (tema 1)
Regra do IQR	fora de $[Q1 - 1.5/IQR, Q3 + 1.5/IQR]$	Alta — baseada em quantis
Visual	boxplot, scatter, histograma	Depende do olho, mas pega padrões que regras fixas não pegam

ARMADILHA COMUM

O z-score clássico tem um problema circular: ele usa a média e o desvio-padrão **calculados com os próprios outliers incluídos** — e ambos são sensíveis a outliers (tema 1). Um outlier extremo o suficiente pode inflar tanto o desvio-padrão que ele mesmo deixa de parecer extremo pelo critério. O z-score modificado, baseado em mediana e MAD, evita esse efeito porque ambos têm ponto de ruptura de 50%.

4.2 O que fazer depois de detectar

Detectar não é decidir. As opções, em ordem de quão "destrutivas" são:

- 1 **Investigar a origem.** É erro de digitação (idade = 999), erro de unidade (valor em centavos lido como reais), ou um valor real e raro?
- 2 **Manter e usar um modelo robusto.** Árvores de decisão e gradient boosting são naturalmente resistentes a outliers em features (o particionamento não depende de distância); modelos baseados em distância ou em soma de quadrados (regressão linear, k-means, PCA) são mais vulneráveis.
- 3 **Transformar.** Uma transformação log ou Box-Cox comprime a cauda e reduz o efeito de valores extremos sem descartá-los (o mesmo raciocínio do histograma em escala log do tema 1).
- 4 **Capar (winsorizar).** Substituir valores acima/abaixo de um percentil pelo próprio limite, preservando a existência do ponto sem deixá-lo dominar a escala.
- 5 **Remover.** A opção mais forte, e a única realmente irreversível — usar só depois de descartar erro de coleta como causa e confirmar que o ponto não representa um segmento de negócio real.

NO MERCADO

Em detecção de fraude, os "outliers" **são o problema que o modelo existe para resolver** — removê-los da base de treino equivale a ensinar o modelo a nunca reconhecer fraude. Em manutenção preditiva, o outlier no sinal de um sensor pode ser o primeiro indício de uma falha mecânica real. A pergunta certa nunca é "isso é estatisticamente raro?" — é "isso é raro **e também um erro**, ou é raro **e informativo**?"

5. Erros que custam caro — checklist

- Imputar com a média sem checar o mecanismo de ausência (MCAR/MAR/MNAR).
- Ajustar imputadores no dataset completo antes do split treino/teste.
- Usar z-score clássico para detectar outliers em dados que já têm outliers

(problema circular) — prefira a versão modificada, baseada em mediana/MAD.

- Remover outliers automaticamente sem investigar se são erro ou sinal.
- Ignorar que uma coluna indicadora `_era_nulo` pode carregar sinal preditivo

por si só, mesmo depois de imputar o valor.

- Tratar ausência estrutural (não pode existir) como se fosse MCAR/MAR/MNAR — são categorias diferentes com soluções diferentes.

6. Para ir além

- Rubin, *Inference and Missing Data* (1976) — o artigo que define MCAR/MAR/MNAR.
- van Buuren, *Flexible Imputation of Missing Data* — o tratamento de referência sobre MICE, com o autor do pacote `mice` original em R.
- Aggarwal, *Outlier Analysis* — cobertura ampla de métodos de detecção, estatísticos e baseados em modelo.
- Rousseeuw & Hubert, sobre robustez estatística — a base teórica do z-score modificado e de outras medidas robustas usadas neste módulo.