

Regressão Linear

O modelo mais simples que ainda é o baseline mais honesto do mercado

Regressão linear não é "o modelo básico que se aprende antes dos de verdade" — é o modelo cuja matemática já foi construída nos temas 2 e 3 (projeção ortogonal, gradiente descendente) e cuja interpretabilidade nenhum modelo mais complexo supera. Este material formaliza o modelo, deriva o diagnóstico de resíduos que decide se ele é adequado, e aplica tudo a um caso real de precificação.

Nível: Intermediário — requer Álgebra Linear e Otimização (tema 2) e Preparação de Dados (tema 3)

Pre-requisitos: Vetores, Matrizes e Projeções; Cálculo e Gradiente Descendente; todos os módulos do tema 3

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-regressao-do-zero · 02-suposicoes-e-diagnostico · 03-caso-real-precificacao · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. O modelo estatístico	4
3. Interpretação de coeficientes	5
3.1 Erro-padrão, intervalo de confiança e p-valor de um coeficiente	5
4. R^2: quanto da variância o modelo explica	6
5. Diagnóstico de resíduos: como saber se o modelo serve	7
6. Multicolinearidade, de novo	8
7. Regressão linear como baseline	9
8. Erros que custam caro — checklist	10
9. Para ir além	11

1. Por que este módulo existe

Regressão linear é o único modelo deste tema cuja matemática você já construiu inteira, em dois temas anteriores: o tema 2 mostrou que ajustar uma reta é uma projeção ortogonal, e que $\hat{\beta} = (X^T X)^{-1} X^T y$ nasce da exigência de que o resíduo seja perpendicular às features. O tema 3 encheu essa formulação de cuidados práticos — sem eles, o "modelo mais simples" produz os erros mais silenciosos. Este módulo não repete a derivação geométrica — ele formaliza o modelo estatístico por trás dela, o diagnóstico que diz se ele é adequado, e o caso de uso mais comum em produção: precificação.

ANALOGIA

Se os modelos deste tema fossem ferramentas de uma oficina, a regressão linear seria a chave de fenda: simples, previsível, e a primeira coisa que um profissional experiente tenta antes de pegar a furadeira elétrica. Não porque seja fraca — porque, quando o parafuso é o problema certo, nada é mais rápido de usar nem mais fácil de explicar por que funcionou.

1.1 O que você vai conseguir fazer ao final

- Escrever o modelo de regressão linear com os pressupostos estatísticos explícitos, não só a fórmula do ajuste.
 - Diagnosticar, com gráficos e testes, quando os pressupostos são violados e o que fazer a respeito.
 - Interpretar coeficientes, intervalos de confiança e R^2 com o rigor que o tema 1 e o tema 2 já construíram.
 - Aplicar regressão linear a um problema real de precificação, incluindo a preparação de dados que o tema 3 ensinou.
-

2. O modelo estatístico

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$$

O tema 2 já mostrou **como** encontrar $\hat{\beta}$ (projeção ortogonal). O que falta é a parte estatística: ε_i é modelado como uma variável aleatória, e é sobre ela que recaem os pressupostos que tornam válidas as inferências (intervalos de confiança, testes de hipótese sobre coeficientes).

DEFINICAO

Os quatro pressupostos clássicos (memorizáveis pelo acrônimo **LINE**): **L**inearidade (a relação entre X e $E[y]$ é de fato linear nos parâmetros), **I**ndependência dos erros, **N**ormalidade dos erros, e **E**quivariância — variância constante dos erros (homocedasticidade). Nenhum desses pressupostos é necessário para *calcular* $\hat{\beta}$ — o tema 2 fez isso com álgebra pura. Eles são necessários para que erros-padrão, intervalos de confiança e p-valores dos coeficientes **signifiquem o que dizem significar**.

ARMADILHA COMUM

Um erro comum: achar que "linear" significa "só retas". A regressão é linear **nos parâmetros** — $y = \beta_0 + \beta_1 x + \beta_2 x^2$ é uma regressão linear (é linear em $\beta_0, \beta_1, \beta_2$), ainda que a curva ajustada seja uma parábola. É por isso que polinômios, splines e até certas interações cabem no mesmo arcabouço matemático do tema 2 — só muda a matriz X que se constrói antes de projetar.

3. Interpretação de coeficientes

Em $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, o coeficiente β_1 é: **o quanto y muda, em média, para um aumento de uma unidade em x_1 , mantendo x_2 constante.**

NOTA

"Mantendo x_2 constante" não é retórica — é o teorema de Frisch-Waugh-Lovell do tema 2: β_1 é literalmente o coeficiente da parte de x_1 que é **ortogonal** a x_2 . Quando x_1 e x_2 são correlacionadas, o "efeito isolado" de x_1 só existe depois de remover dela o que x_2 já explica.

ARMADILHA COMUM

Coefficientes de features em escalas muito diferentes não são diretamente comparáveis em magnitude — um coeficiente de 50.000 numa feature em milhões e um coeficiente de 0,003 numa proporção podem representar efeitos de importância parecida. Para comparar magnitude de efeito entre features, padronize-as antes (tema 3) e compare os coeficientes padronizados.

3.1 Erro-padrão, intervalo de confiança e p-valor de um coeficiente

Sob os pressupostos LINE, $\hat{\beta}_j$ tem uma distribuição amostral com erro-padrão calculável a partir de $\hat{\sigma}^2(X^\top X)^{-1}$ (a diagonal dessa matriz, mais precisamente). Isso permite testar $H_0: \beta_j = 0$ (tema 1) e construir intervalos de confiança — a mesma lógica de inferência construída para médias, agora aplicada a coeficientes de regressão.

NO MERCADO

Um coeficiente estatisticamente significativo ($p < 0,05$) não é automaticamente um coeficiente **relevante** para o negócio — com n grande, até efeitos minúsculos ficam significativos. E um coeficiente não significativo não prova ausência de efeito — pode ser apenas falta de poder estatístico (tema 1, módulo 4). Sempre reporte a magnitude do coeficiente (e seu intervalo de confiança) junto do p-valor.

4. R^2 : quanto da variância o modelo explica

$$R^2 = \frac{\text{SQ explicada}}{\text{SQ total}} = 1 - \frac{\text{SQ residual}}{\text{SQ total}}$$

Já visto no tema 2 como $\cos^2$ do ângulo entre y e $\hat{y}$ centrados.

ARMADILHA COMUM

R^2 **nunca diminui** quando se adiciona uma nova feature ao modelo — mesmo uma feature de ruído puro. Isso torna R^2 enganoso para comparar modelos com números diferentes de features. O R^2 **ajustado** penaliza pelo número de parâmetros:

$$R^2_{aj} = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

e só aumenta se a nova feature reduzir o erro mais do que o esperado por puro acaso.

5. Diagnóstico de resíduos: como saber se o modelo serve

O diagnóstico é a parte prática que decide se os pressupostos LINE são razoáveis para os dados em mãos.

Gráfico	O que revela
Resíduo vs. valor previsto	Padrão curvo = não-linearidade; funil = heterocedasticidade
Q-Q plot dos resíduos	Desvio da reta = não-normalidade dos erros
Resíduo vs. cada feature	Padrão restante = a feature precisa de transformação (ex.: log, polinômio)
Alavancagem (leverage) vs. resíduo	Pontos influentes que distorcem o ajuste sozinhos

FORMULARIO

A **distância de Cook** combina alavancagem e magnitude do resíduo num único número por observação, medindo o quanto os coeficientes mudariam se aquele ponto fosse removido. Pontos com distância de Cook alta merecem investigação — não remoção automática (tema 3, módulo 2: outlier não é sinônimo de erro).

ARMADILHA COMUM

Um padrão em forma de funil no gráfico resíduo-vs-previsto (heterocedasticidade — variância do erro cresce com o valor previsto) não invalida os coeficientes estimados (eles continuam não-viesados), mas invalida os erros-padrão calculados da forma clássica — os intervalos de confiança ficam errados. A correção mais simples costuma ser transformar o alvo (log, se ele for positivo e a variância crescer com a média — o mesmo padrão de dados assimétricos do tema 1).

6. Multicolinearidade, de novo

O tema 2 já mostrou que colinearidade **infla variância, não envies**a coeficientes. Aqui, a consequência prática: coeficientes instáveis (mudam muito com pequenas mudanças nos dados), sinais que trocam de forma contraintuitiva, e intervalos de confiança largos demais para serem úteis.

NO MERCADO

VIF acima de 5-10 (tema 2) é o sinal de alerta. As saídas práticas: remover uma das features colineares, combiná-las, ou usar regularização (Ridge, próximo módulo) — que foi desenhada precisamente para estabilizar $X^T X$ mal condicionada.

7. Regressão linear como baseline

NO MERCADO

Antes de qualquer modelo mais sofisticado, treinar uma regressão linear (ou logística, para classificação) é o primeiro passo profissional em qualquer projeto novo — não por ingenuidade, mas porque ela estabelece um **piso de comparação interpretável**. Se um Random Forest bate a regressão linear por uma margem pequena, isso é informação: talvez o problema seja majoritariamente linear, e a complexidade extra não compense o custo de interpretabilidade perdido.

8. Erros que custam caro — checklist

- Reportar coeficientes sem checar resíduos — um modelo com pressupostos violados pode ter coeficientes tecnicamente calculados e estatisticamente sem sentido.
- Comparar magnitude de coeficientes de features em escalas diferentes sem padronizar.
- Usar R^2 para decidir se vale a pena adicionar uma feature — use R^2 ajustado ou validação cruzada (tema 6).
- Ignorar heterocedasticidade e reportar intervalos de confiança calculados da forma clássica mesmo assim.
- Tratar colinearidade removendo features às cegas, sem entender por que estão correlacionadas.
- Pular direto para um modelo complexo sem primeiro estabelecer o baseline linear.

9. Para ir além

- Kutner et al., *Applied Linear Statistical Models* — o tratado de referência sobre diagnóstico de regressão.
- Gelman & Hill, *Data Analysis Using Regression and Multilevel Models* — a ponte entre a teoria clássica e a prática aplicada moderna.
- Cook & Weisberg, *Residuals and Influence in Regression* — o texto que formaliza a distância de Cook e outras medidas de influência.