

Regressão Linear

O modelo mais simples que ainda é o baseline mais honesto do mercado

Regressão linear não é "o modelo básico que se aprende antes dos de verdade" — é o modelo cuja matemática já foi construída nos temas 2 e 3 (projeção ortogonal, gradiente descendente) e cuja interpretabilidade nenhum modelo mais complexo supera. Este material formaliza o modelo, deriva o diagnóstico de resíduos que decide se ele é adequado, e aplica tudo a um caso real de precificação.

Nível: Intermediário — requer Álgebra Linear e Otimização (tema 2) e Preparação de Dados (tema 3)

Pre-requisitos: Vetores, Matrizes e Projeções; Cálculo e Gradiente Descendente; todos os módulos do tema 3

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-regressao-do-zero · 02-suposicoes-e-diagnostico · 03-caso-real-precificacao · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.1

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	4
2. O modelo estatístico	5
2.1 Um exemplo numérico completo, do início ao fim	5
3. Interpretação de coeficientes	7
3.1 Erro-padrão, intervalo de confiança e p-valor de um coeficiente	7
4. R^2: quanto da variância o modelo explica	9
5. Diagnóstico de resíduos: como saber se o modelo serve	10
6. Multicolinearidade, de novo	12
7. Regressão linear como baseline	13
8. Erros que custam caro — checklist	14
9. Para ir além	15


1. Por que este módulo existe

Regressão linear é o único modelo deste tema cuja matemática você já construiu inteira, em dois temas anteriores: o tema 2 mostrou que ajustar uma reta é uma projeção ortogonal, e que $\hat{\beta} = (X^T X)^{-1} X^T y$ nasce da exigência de que o resíduo seja perpendicular às features. O tema 3 encheu essa formulação de cuidados práticos — sem eles, o "modelo mais simples" produz os erros mais silenciosos. Este módulo não repete a derivação geométrica — ele formaliza o modelo estatístico por trás dela, o diagnóstico que diz se ele é adequado, e o caso de uso mais comum em produção: precificação.

ANALOGIA

Se os modelos deste tema fossem ferramentas de uma oficina, a regressão linear seria a chave de fenda: simples, previsível, e a primeira coisa que um profissional experiente tenta antes de pegar a furadeira elétrica. Não porque seja fraca — porque, quando o parafuso é o problema certo, nada é mais rápido de usar nem mais fácil de explicar por que funcionou.

Vale começar pela imagem que resume o módulo inteiro: uma reta ajustada não é "a melhor reta que alguém desenhou à mão" — é a reta que minimiza, de forma matematicamente exata, a soma dos quadrados das distâncias verticais até cada ponto observado. Essas distâncias são os **resíduos**, e são eles — não a reta em si — o objeto central de todo o módulo.



A reta ajustada minimiza a soma dos resíduos ao quadrado — cada segmento vermelho é a distância vertical entre a observação e a previsão.

1.1 O que você vai conseguir fazer ao final

- Escrever o modelo de regressão linear com os pressupostos estatísticos explícitos, não só a fórmula do ajuste.
 - Diagnosticar, com gráficos e testes, quando os pressupostos são violados e o que fazer a respeito.
 - Interpretar coeficientes, intervalos de confiança e R^2 com o rigor que o tema 1 e o tema 2 já construíram.
 - Aplicar regressão linear a um problema real de precificação, incluindo a preparação de dados que o tema 3 ensinou.
-

2. O modelo estatístico

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$$

O tema 2 já mostrou **como** encontrar $\hat{\beta}$ (projeção ortogonal). O que falta é a parte estatística: ε_i é modelado como uma variável aleatória, e é sobre ela que recaem os pressupostos que tornam válidas as inferências (intervalos de confiança, testes de hipótese sobre coeficientes).

DEFINIÇÃO

Os quatro pressupostos clássicos (memorizáveis pelo acrônimo **LINE**): **L**inearidade (a relação entre X e $E[y]$ é de fato linear nos parâmetros), **I**ndependência dos erros, **N**ormalidade dos erros, e **E**quivariância — variância constante dos erros (homocedasticidade). Nenhum desses pressupostos é necessário para *calcular* $\hat{\beta}$ — o tema 2 fez isso com álgebra pura. Eles são necessários para que erros-padrão, intervalos de confiança e p-valores dos coeficientes **signifiquem o que dizem significar**.

ARMADILHA COMUM

Um erro comum: achar que "linear" significa "só retas". A regressão é linear **nos parâmetros** — $y = \beta_0 + \beta_1 x + \beta_2 x^2$ é uma regressão linear (é linear em $\beta_0, \beta_1, \beta_2$), ainda que a curva ajustada seja uma parábola. É por isso que polinômios, splines e até certas interações cabem no mesmo arcabouço matemático do tema 2 — só muda a matriz X que se constrói antes de projetar.

2.1 Um exemplo numérico completo, do início ao fim

Para tornar tudo concreto antes de generalizar, considere uma imobiliária que registrou o preço de 5 apartamentos (em R\$ mil) contra a área (em m²):

Área (m ²)	Preço (R\$ mil)
40	220
55	290
70	355
85	410
100	495

Ajustando preço = $\beta_0 + \beta_1 \cdot \text{área}$ por mínimos quadrados (o **sklearn** faz isso numa linha, mas vale ver a conta uma vez): $\bar{x} = 70$, $\bar{y} = 354$, e

$$\beta_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{16350}{3150} \approx 5,19, \quad \beta_0 = \bar{y} - \beta_1 \bar{x} \approx -9,3$$

O modelo final é preço $\approx -9,3 + 5,19 \cdot \text{área}$: cada metro quadrado adicional soma, em média, **R\$ 5.190** ao preço previsto. Para um apartamento de 60 m², a previsão é

$-9,3 + 5,19 \times 60 \approx 301,9$ mil reais. O intercepto negativo não tem leitura de negócio direta aqui — nenhum apartamento tem 0 m^2 , e extrapolar a reta para fora da faixa de dados observada (40 a 100 m^2) é sempre arriscado, o assunto da próxima seção.

ARMADILHA COMUM

Extrapolação é o erro mais barato de cometer e mais caro de pagar. O modelo acima nunca viu um apartamento de 300 m^2 — usar a mesma reta para prever o preço de uma cobertura de 300 m^2 ($\approx \text{R}\$ 1,55$ milhão) assume que a relação linear continua válida bem além de onde foi observada. Relações lineares em pequenos intervalos frequentemente **saturam** ou **aceleram** fora deles — imóveis de luxo têm dinâmica de preço diferente de apartamentos padrão.

3. Interpretação de coeficientes

Em $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, o coeficiente β_1 é: **o quanto y muda, em média, para um aumento de uma unidade em x_1 , mantendo x_2 constante.**

NOTA

"Mantendo x_2 constante" não é retórica — é o teorema de Frisch-Waugh-Lovell do tema 2: β_1 é literalmente o coeficiente da parte de x_1 que é **ortogonal** a x_2 . Quando x_1 e x_2 são correlacionadas, o "efeito isolado" de x_1 só existe depois de remover dela o que x_2 já explica.

ARMADILHA COMUM

Coeficientes de features em escalas muito diferentes não são diretamente comparáveis em magnitude — um coeficiente de 50.000 numa feature em milhões e um coeficiente de 0,003 numa proporção podem representar efeitos de importância parecida. Para comparar magnitude de efeito entre features, padronize-as antes (tema 3) e compare os coeficientes padronizados.

NO MERCADO

Um caso real de leitura de coeficientes: uma fintech de crédito ajusta `limite_aprovado = f(renda, tempo_de_conta, score_bureau, ...)` e reporta ao time de risco "cada ano adicional de tempo de conta aumenta o limite aprovado em R\$ 340, controlando por renda e score". Essa frase só faz sentido porque o coeficiente de `tempo_de_conta` já é, por construção, **líquido** do efeito de renda e score — é exatamente essa propriedade que torna regressão linear a ferramenta preferida quando o objetivo não é só prever, mas **explicar e justificar** uma decisão de crédito para um órgão regulador ou para o próprio cliente.

3.1 Erro-padrão, intervalo de confiança e p-valor de um coeficiente

Sob os pressupostos LINE, $\hat{\beta}_j$ tem uma distribuição amostral com erro-padrão calculável a partir de $\hat{\sigma}^2(X^\top X)^{-1}$ (a diagonal dessa matriz, mais precisamente). Isso permite testar $H_0: \beta_j = 0$ (tema 1) e construir intervalos de confiança — a mesma lógica de inferência construída para médias, agora aplicada a coeficientes de regressão.

No exemplo do apartamento, se o erro-padrão de $\hat{\beta}_1$ fosse 0,62 (com $n - 2 = 3$ graus de liberdade), o intervalo de confiança de 95% seria aproximadamente $5,19 \pm 3,18 \times 0,62 \approx [3,22, 7,16]$ — ou seja, com apenas 5 observações, sabemos que cada metro quadrado vale **entre R\$ 3.220 e R\$ 7.160**, um intervalo largo que reflete honestamente quão pouco dado sustenta essa estimativa. É essa largura, raramente calculada por analistas apressados, que separa "o coeficiente deu 5,19" de "o coeficiente é 5,19 com razoável confiança".


NO MERCADO

Um coeficiente estatisticamente significativo ($p < 0,05$) não é automaticamente um coeficiente **relevante** para o negócio — com n grande, até efeitos minúsculos ficam significativos. E um coeficiente não significativo não prova ausência de efeito — pode ser apenas falta de poder estatístico (tema 1, módulo 4). Sempre reporte a magnitude do coeficiente (e seu intervalo de confiança) junto do p-valor.

4. R^2 : quanto da variância o modelo explica

$$R^2 = \frac{\text{SQ explicada}}{\text{SQ total}} = 1 - \frac{\text{SQ residual}}{\text{SQ total}}$$

Já visto no tema 2 como $\cos^2$ do ângulo entre y e $\hat{y}$ centrados. A figura abaixo mostra a mesma ideia de forma mais concreta: a soma de quadrados **total** (o quanto os dados variam em torno da própria média, ignorando qualquer modelo), a soma de quadrados **explicada** (o quanto a reta se afasta da média — a parte que o modelo "capturou") e a soma de quadrados **residual** (o que sobra, sem explicação). R^2 é exatamente a fração do primeiro painel que o segundo painel recupera.



Decomposição da soma de quadrados: $\text{SQ Total} = \text{SQ Explicada} + \text{SQ Residual}$ — Pitágoras no espaço das observações, já visto no tema 2.

No exemplo do apartamento, ajustando a reta aos 5 pontos obtemos $R^2 \approx 0,996$ — a área explica quase toda a variação de preço nessa amostra pequena e bem comportada. Em dados reais de mercado imobiliário, com milhares de imóveis e dezenas de variáveis de confusão (localização, padrão de acabamento, idade do imóvel), é comum R^2 ficar entre 0,5 e 0,7 — e isso **não** é um modelo ruim; é o reflexo de que preço de imóvel depende de fatores que a área sozinha não captura.

ARMADILHA COMUM

R^2 **nunca diminui** quando se adiciona uma nova feature ao modelo — mesmo uma feature de ruído puro. Isso torna R^2 enganoso para comparar modelos com números diferentes de features. O R^2 **ajustado** penaliza pelo número de parâmetros:

$$R_{aj}^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$


e só aumenta se a nova feature reduzir o erro mais do que o esperado por puro acaso.

5. Diagnóstico de resíduos: como saber se o modelo serve

O diagnóstico é a parte prática que decide se os pressupostos LINE são razoáveis para os dados em mãos — e é também a parte que a maioria dos cursos introdutórios pula, produzindo profissionais que sabem rodar `.fit()` mas não sabem dizer se deveriam confiar no resultado.

Gráfico	O que revela
Resíduo vs. valor previsto	Padrão curvo = não-linearidade; funil = heterocedasticidade
Q-Q plot dos resíduos	Desvio da reta = não-normalidade dos erros
Resíduo vs. cada feature	Padrão restante = a feature precisa de transformação (ex.: log, polinômio)
Alavancagem (leverage) vs. resíduo	Pontos influentes que distorcem o ajuste sozinhos

A figura a seguir mostra as quatro assinaturas visuais mais comuns lado a lado — o painel "saudável" (sem nenhum padrão discernível) serve de referência mental para comparar qualquer diagnóstico que você fizer daqui para frente.



Quatro padrões de resíduo vs. previsto: um saudável (sem padrão) e três violações clássicas de pressuposto, cada uma com uma assinatura visual reconhecível.

FORMULÁRIO

A **distância de Cook** combina alavancagem e magnitude do resíduo num único número por observação, medindo o quanto os coeficientes mudariam se aquele ponto fosse removido:

$$D_i = \frac{e_i^2}{p\hat{\sigma}^2} \cdot \frac{h_{ii}}{(1 - h_{ii})^2}$$

onde h_{ii} é a alavancagem (diagonal da matriz chapéu H , tema 2) do ponto i . Um limiar de referência comum é $D_i > 4/n$. Pontos com distância de Cook alta merecem investigação — não remoção automática (tema 3, módulo 2: outlier não é sinônimo de erro).

ARMADILHA COMUM

Um padrão em forma de funil no gráfico resíduo-vs-previsto (heterocedasticidade — variância do erro cresce com o valor previsto) não invalida os coeficientes estimados (eles continuam não-viesados), mas invalida os erros-padrão calculados da forma clássica — os intervalos de confiança ficam errados. A correção mais simples costuma ser transformar o alvo (log, se ele for positivo e a variância crescer com a média — o mesmo padrão de dados assimétricos do tema 1).

NO MERCADO

Heterocedasticidade é a regra, não a exceção, em dados financeiros: o erro absoluto de previsão de faturamento de uma empresa gigante costuma ser maior, em reais, que o erro de uma empresa pequena — mas proporcionalmente parecido. É exatamente esse padrão (variância proporcional ao nível) que motiva modelar `log(faturamento)` em vez de `faturamento` em praticamente toda aplicação de finanças corporativas e precificação de seguros.

6. Multicolinearidade, de novo

O tema 2 já mostrou que colinearidade **infla variância, não envies**a coeficientes. Aqui, a consequência prática: coeficientes instáveis (mudam muito com pequenas mudanças nos dados), sinais que trocam de forma contraintuitiva, e intervalos de confiança largos demais para serem úteis.

Um exemplo de mercado real: um modelo de precificação de imóveis com `area_construida_m2` e `numero_comodos` como features simultâneas costuma sofrer disso — as duas crescem juntas quase sempre (mais cômodos, mais área), e o modelo não tem como distinguir de forma confiável qual das duas realmente move o preço. O sintoma clássico: o coeficiente de `numero_comodos` aparece **negativo** em algumas execuções, o que não faz sentido de negócio nenhum — é ruído amostral herdado da colinearidade, não um efeito real.

NO MERCADO

VIF acima de 5-10 (tema 2) é o sinal de alerta. As saídas práticas: remover uma das features colineares, combiná-las, ou usar regularização (Ridge, próximo módulo) — que foi desenhada precisamente para estabilizar $X^T X$ mal condicionada.

7. Regressão linear como baseline

NO MERCADO

Antes de qualquer modelo mais sofisticado, treinar uma regressão linear (ou logística, para classificação) é o primeiro passo profissional em qualquer projeto novo — não por ingenuidade, mas porque ela estabelece um **piso de comparação interpretável**. Se um Random Forest bate a regressão linear por uma margem pequena, isso é informação: talvez o problema seja majoritariamente linear, e a complexidade extra não compense o custo de interpretabilidade perdido. Times de dados sênior costumam exigir esse baseline documentado antes de aprovar qualquer modelo de "caixa-preta" em produção — é o número contra o qual todo ganho futuro será justificado.

8. Erros que custam caro — checklist

- Reportar coeficientes sem checar resíduos — um modelo com pressupostos violados pode ter coeficientes tecnicamente calculados e estatisticamente sem sentido.
- Comparar magnitude de coeficientes de features em escalas diferentes sem padronizar.
- Usar R^2 para decidir se vale a pena adicionar uma feature — use R^2 ajustado ou validação cruzada (tema 6).
- Ignorar heterocedasticidade e reportar intervalos de confiança calculados da forma clássica mesmo assim.
- Tratar colinearidade removendo features às cegas, sem entender por que estão correlacionadas.
- Extrapolar a reta para uma faixa de valores de x nunca observada no treino.
- Pular direto para um modelo complexo sem primeiro estabelecer o baseline linear.

9. Para ir além

- Kutner et al., *Applied Linear Statistical Models* — o tratado de referência sobre diagnóstico de regressão.
- Gelman & Hill, *Data Analysis Using Regression and Multilevel Models* — a ponte entre a teoria clássica e a prática aplicada moderna.
- Cook & Weisberg, *Residuals and Influence in Regression* — o texto que formaliza a distância de Cook e outras medidas de influência.