

Regularização: Ridge, Lasso e Elastic Net

Aceitar um pouco de viés para comprar muito menos variância

Regressão linear sem regularização confia cegamente nos dados de treino — com features colineares ou em número grande demais, essa confiança produz coeficientes instáveis e overfitting. Ridge, Lasso e Elastic Net penalizam coeficientes grandes, trocando um pouco de viés por uma redução grande de variância. Este material constrói a geometria de cada penalidade, mostra por que Lasso zera coeficientes e Ridge não, e cobre a validação cruzada que escolhe a força da penalidade.

Nível: Intermediário — requer Regressão Linear (módulo anterior) e Cálculo e Gradiente Descendente (tema 2)

Pre-requisitos: Regressão Linear; Vetores, Matrizes e Projeções

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-ridge-e-lasso · 02-geometria-da-regularizacao · 03-elasticnet-e-tuning · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. O trade-off viés-variância, formalizado	4
3. Ridge: penalidade L2	5
4. Lasso: penalidade L1	6
4.1 Por que L1 zera e L2 não: a geometria	6
5. Elastic Net: o meio-termo	7
6. Escolhendo a força da penalidade: validação cruzada	8
7. Erros que custam caro — checklist	9
8. Para ir além	10

1. Por que este módulo existe

O módulo anterior mostrou dois problemas que regressão linear comum não resolve sozinha: colinearidade infla a variância dos coeficientes, e R^2 sempre sobe ao adicionar features — mesmo ruído puro. Regularização ataca os dois problemas com a mesma ideia: **penalizar coeficientes grandes**, tornando o modelo mais cético em relação a padrões que poderiam ser ruído amostral.

ANALOGIA

Regressão linear comum é como um estagiário que aceita qualquer padrão que vê nos dados de treino, sem questionar. Regularização é um supervisor experiente sussurrando "tem certeza? isso pode ser coincidência" toda vez que um coeficiente fica grande demais — o modelo só mantém um coeficiente alto se a evidência nos dados for forte o bastante para justificar a "objeção".

1.1 O que você vai conseguir fazer ao final

- Explicar a diferença matemática entre a penalidade L2 (Ridge) e L1 (Lasso), e por que só uma delas zera coeficientes.
 - Visualizar geometricamente por que Lasso produz soluções esparsas.
 - Escolher entre Ridge, Lasso e Elastic Net com um argumento técnico.
 - Ajustar a força da regularização por validação cruzada, sem vaziar o teste nesse processo.
-

2. O trade-off viés-variância, formalizado

Adicionar uma penalidade ao problema de mínimos quadrados introduz viés (o modelo já não encontra o mínimo *irrestrito* de erro no treino) em troca de menos variância (o modelo muda menos entre amostras de treino diferentes).

$$\text{Erro esperado} = \text{Viés}^2 + \text{Variância} + \text{Erro irreduzível}$$

FORMULARIO

Essa decomposição — construída em detalhe no tema 6 — é a justificativa formal de toda regularização: um pouco de viés, bem escolhido, pode reduzir a variância o suficiente para diminuir o erro total esperado em dados novos, mesmo que o erro no treino suba.

3. Ridge: penalidade L2

$$\hat{\beta}_{Ridge} = \arg \min_{\beta} \{ \|y - X\beta\|^2 + \lambda \|\beta\|_2^2 \}$$

A solução tem forma fechada:

$$\hat{\beta}_{Ridge} = (X^T X + \lambda I)^{-1} X^T y$$

FORMULARIO

Compare com a fórmula de mínimos quadrados do tema 2: $(X^T X)^{-1} X^T y$. Ridge soma λI à diagonal antes de inverter — e essa é a razão pela qual Ridge **sempre** tem solução, mesmo quando $X^T X$ é singular (posto deficiente, colinearidade perfeita). O nome técnico dessa soma na diagonal é exatamente o que resolve o problema de condicionamento do tema 2: λI eleva todos os autovalores de $X^T X$ em λ , o que **reduz diretamente o número de condição** quando os menores autovalores são o problema.

NOTA

Como $\lambda \rightarrow 0$, Ridge tende à solução de mínimos quadrados comum. Como $\lambda \rightarrow \infty$, todos os coeficientes tendem a zero (mas nenhum chega a ser **exatamente** zero, exceto no limite).

4. Lasso: penalidade L1

$$\hat{\beta}_{Lasso} = \arg \min_{\beta} \{ \|y - X\beta\|^2 + \lambda \|\beta\|_1 \}$$

Sem fórmula fechada — precisa de otimização numérica (coordinate descent é o algoritmo padrão). A diferença mais importante em relação a Ridge: **Lasso zera coeficientes exatamente**, produzindo soluções esparsas — uma forma embutida de seleção de features (tema 3, módulo 3).

4.1 Por que L1 zera e L2 não: a geometria

ANALOGIA

Minimizar erro sujeito a uma penalidade é equivalente a minimizar o erro dentro de uma **região restrita** ao redor da origem — uma bola para L2 (círculo em 2D), um losango para L1 (quadrado girado 45° em 2D). As curvas de nível do erro (elipses) crescem a partir da solução sem restrição e "colidem" com a fronteira da região restrita no ponto ótimo. Um losango tem **quinas exatamente sobre os eixos** — é muito mais provável que a elipse toque a região ali (onde um coeficiente é zero) do que num círculo, que não tem quinas em lugar nenhum. Essa diferença geométrica pura — quinas vs. superfície lisa — é a razão inteira pela qual L1 produz zeros exatos e L2 não.

NO MERCADO

Lasso é a ferramenta certa quando você acredita que **poucas** features entre muitas são realmente relevantes (esparsidade real) e quer um modelo mais simples de explicar. Ridge é a escolha certa quando muitas features têm efeitos pequenos e reais — zerar qualquer uma delas jogaria fora sinal genuíno, ainda que fraco.

ARMADILHA COMUM

Com features fortemente correlacionadas entre si, Lasso tende a escolher **uma** arbitrariamente e zerar as outras — mesmo que todas carreguem sinal parecido. Isso torna a escolha específica de qual sobrevive instável entre execuções com dados ligeiramente diferentes. Ridge, nesse cenário, tende a **dividir** o peso entre as features correlacionadas de forma mais estável.

5. Elastic Net: o meio-termo

$$\hat{\beta}_{EN} = \arg \min_{\beta} \{ \|y - X\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2 \}$$

Combina as duas penalidades, com um parâmetro adicional (`l1_ratio` no `sklearn`) controlando a proporção entre elas. Herda a esparsidade do Lasso e a estabilidade do Ridge sob colinearidade — o preço é mais um hiperparâmetro para ajustar.

NO MERCADO

Elastic Net é a escolha padrão de mercado quando há muitas features correlacionadas e se espera esparsidade real — o cenário mais comum em dados genômicos, texto (bag-of-words) e qualquer dataset com p próximo de ou maior que n .

6. Escolhendo a força da penalidade: validação cruzada

λ (ou o inverso, C , na convenção de outras bibliotecas) é um **hiperparâmetro** — não é estimado pelos dados da mesma forma que β ; é escolhido por validação cruzada, testando uma grade de valores e escolhendo o que minimiza o erro em dados que o ajuste de β não viu.

ARMADILHA COMUM

Ajustar λ observando o erro no **mesmo** conjunto de teste que depois será usado para reportar o desempenho final é uma forma de vazamento (tema 3): o teste deixa de ser "dados nunca vistos" porque influenciou a escolha do hiperparâmetro. A prática correta usa um terceiro conjunto (validação) ou validação cruzada aninhada — o tema 6 formaliza esse esquema em detalhe.

FORMULARIO

Antes de aplicar qualquer regularização, **padronize as features** (tema 3). A penalidade soma os coeficientes ao quadrado (ou em valor absoluto) — se as features estão em escalas diferentes, a penalidade afeta cada uma de forma desproporcional à sua escala, não à sua real importância. Sem padronizar, regularização pune arbitrariamente a feature medida em unidades menores.

7. Erros que custam caro — checklist

- Aplicar Ridge/Lasso/Elastic Net sem padronizar as features primeiro.
- Escolher λ olhando o desempenho no conjunto de teste final, em vez de usar validação cruzada isolada.
- Usar Lasso esperando que ele sempre escolha "as features certas" entre um grupo de correlacionadas — a escolha pode ser arbitrária e instável.
- Interpretar um coeficiente zerado pelo Lasso como prova de que a feature não tem relação real com o alvo — pode só significar que uma feature correlacionada "venceu" a disputa.
- Regularizar o intercepto junto com os demais coeficientes (a maioria das implementações, incluindo `sklearn`, já exclui o intercepto da penalidade corretamente por padrão — mas vale confirmar ao implementar do zero).

8. Para ir além

- Hastie, Tibshirani & Friedman, *The Elements of Statistical Learning*, capítulo 3 — o tratamento matemático de referência sobre regularização.
- Tibshirani (1996), o artigo original do Lasso.
- Zou & Hastie (2005), o artigo original do Elastic Net.
- Documentação do `sklearn.linear_model` (Ridge, Lasso, ElasticNet, RidgeCV, LassoCV) — as implementações usadas neste módulo.