

Regressão Logística

Por que uma reta não serve para prever probabilidade, e o que a substitui

Prever uma probabilidade com uma reta produz valores acima de 1 e abaixo de 0 — um problema estrutural, não um detalhe técnico. Regressão logística resolve isso trocando o alvo por uma transformação (o logit) que mapeia probabilidades para toda a reta real, e troca mínimos quadrados por máxima verossimilhança. Este material constrói o modelo do zero, interpreta coeficientes como odds ratio, e aplica tudo a um caso real de crédito.

Nível: Intermediário — requer Regressão Linear e Regularização (módulos deste tema)

Pre-requisitos: Regressão Linear; Máxima Verossimilhança (tema 1); Cálculo e Gradiente Descendente (tema 2)

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-logistica-do-zero · 02-interpretacao-odds-ratio · 03-caso-real-credito · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.1

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	4
2. Do linear ao logístico: o problema e a solução	5
2.1 Um exemplo numérico: calculando a probabilidade na mão	5
3. Máxima verossimilhança: de onde vem a função de perda	6
3.1 Separação perfeita: quando o ajuste diverge	6
4. Interpretando coeficientes: odds ratio	8
5. Fronteira de decisão: um hiperplano, de novo	10
6. Multiclasse: softmax e one-vs-rest	11
7. Erros que custam caro — checklist	12
8. Para ir além	13


1. Por que este módulo existe

Prever "vai cancelar ou não" com uma regressão linear comum produz previsões como $-0,3$ ou $1,4$ — números que não são probabilidades, porque probabilidade vive em $[0, 1]$ e uma reta não tem limites. Esse não é um detalhe estético: é a razão estrutural pela qual todo o arcabouço de inferência do módulo 1 (erros-padrão, testes de hipótese) deixa de valer quando o alvo é binário. Regressão logística resolve o problema transformando o alvo, não o modelo — e o resultado é o classificador mais usado, mais interpretável e mais citado como baseline em toda a indústria.

ANALOGIA

Tentar prever probabilidade com uma reta é como tentar desenhar um mapa do mundo inteiro numa folha de papel plana sem nenhuma projeção — em algum lugar as distâncias e proporções vão quebrar, porque a Terra é curva e o papel é plano. A função logit é a "projeção cartográfica" que faz o mapa (a reta) caber no globo (o intervalo $[0, 1]$) sem incoerência.

A figura a seguir mostra o problema e a solução lado a lado, no mesmo dataset: a reta (vermelha) extrapola para fora de $[0, 1]$ assim que x se afasta do centro dos dados — exatamente as regiões sombreadas, onde uma "probabilidade" de $1,3$ ou $-0,2$ não significa nada. A sigmoide (azul) nunca sai desse intervalo, para nenhum valor de x .



Regressão linear extrapola para fora do intervalo $[0, 1]$ (áreas sombreadas); a sigmoide da regressão logística nunca sai desse intervalo, para nenhum valor de x .

1.1 O que você vai conseguir fazer ao final

- Explicar por que regressão linear falha estruturalmente para prever probabilidade, e como o logit resolve isso.
 - Derivar a função de perda (entropia cruzada) a partir de máxima verossimilhança, ligando de volta ao tema 1.
 - Interpretar coeficientes como odds ratio, com o cuidado de não confundir odds com probabilidade.
 - Aplicar regressão logística a um problema real de crédito, incluindo regularização (módulo 2) e o cuidado com desbalanceamento (tema 3).
-

2. Do linear ao logístico: o problema e a solução

Se $y \in \{0, 1\}$ e modelamos $P(y=1|x) = \beta_0 + \beta_1 x$ diretamente (regressão linear no rótulo), nada impede a previsão de sair de $[0, 1]$. A solução: modelar uma **transformação** da probabilidade que possa assumir qualquer valor real.

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

$p/(1-p)$ é a **razão de chances (odds)** — familiar de apostas ("3 para 1"). $\ln(\text{odds})$ pode ser qualquer número real: odds de 1 (evento tão provável quanto improvável) dá $\ln(1) = 0$; odds acima de 1 dão log positivo; odds abaixo de 1 dão log negativo, sem limite em nenhuma direção.

Invertendo, chega-se à **função sigmoide**:

$$p = \sigma(z) = \frac{1}{1+e^{-z}}, \quad z = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

DEFINIÇÃO

A sigmoide comprime qualquer número real para o intervalo $(0, 1)$, com formato em S: perto de $z=0$ ela é quase linear; nos extremos, achata-se assintoticamente em 0 e 1. É essa forma que garante uma probabilidade sempre válida, para qualquer combinação linear das features.

2.1 Um exemplo numérico: calculando a probabilidade na mão

Suponha um modelo de churn com $z = -2,1 + 0,05 \cdot \text{idade} - 0,8 \cdot \text{engajamento_mensal}$ (engajamento numa escala de 0 a 5). Para um cliente de 40 anos com engajamento 1:

$$z = -2,1 + 0,05 \times 40 - 0,8 \times 1 = -2,1 + 2,0 - 0,8 = -0,9$$

$$p = \sigma(-0,9) = \frac{1}{1+e^{0,9}} \approx \frac{1}{1+2,46} \approx 0,289$$

O modelo prevê **28,9% de chance de cancelamento** para esse cliente. Repare que z negativo já garante $p < 0,5$ sem precisar calcular nada além do sinal — é por isso que a fronteira de decisão de $p = 0,5$ corresponde exatamente a $z = 0$ (mais adiante, isso vira a definição geométrica de fronteira de decisão).

3. Máxima verossimilhança: de onde vem a função de perda

O tema 1 (módulo 3) construiu máxima verossimilhança como princípio geral de estimação. Aqui ele decide a função de perda inteira: para dados (x_i, y_i) com $y_i \in \{0, 1\}$ modelados como Bernoulli com parâmetro $p_i = \sigma(\beta^\top x_i)$, a log-verossimilhança é:

$$\ell(\beta) = \sum_i [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

FORMULARIO

Maximizar $\ell(\beta)$ é equivalente a minimizar $-\ell(\beta)$ — a **entropia cruzada binária**, a função de perda que toda biblioteca usa para treinar regressão logística (e a camada final de praticamente toda rede neural de classificação, tema 8). Não é uma escolha arbitrária de engenharia: é a consequência direta de assumir que y segue uma Bernoulli e usar máxima verossimilhança.

Vale sentir o formato dessa perda com um exemplo: se o modelo prevê $\hat{p} = 0,9$ para uma observação que de fato é $y = 1$, a contribuição à perda é $-\ln(0,9) \approx 0,105$ — pequena, o modelo acertou com confiança. Se o mesmo $\hat{p} = 0,9$ for dado para uma observação que na verdade é $y = 0$, a contribuição é $-\ln(1 - 0,9) = -\ln(0,1) \approx 2,30$ — mais de 20 vezes maior. A entropia cruzada **pune erros confiantes de forma desproporcional**, o que é exatamente o comportamento desejado: um modelo que erra "tenho quase certeza que é 1" quando era 0 deveria pagar caro por isso.

ARMADILHA COMUM

Ao contrário da regressão linear, **não existe fórmula fechada** para $\hat{\beta}$ da regressão logística — a equação $\nabla \ell(\beta) = 0$ não tem solução analítica. O ajuste usa métodos iterativos: gradiente descendente (tema 2) ou, mais comumente na prática, variantes de Newton (IRLS — *Iteratively Reweighted Least Squares*), que convergem mais rápido por usar informação de segunda ordem (a Hessiana, tema 2).

3.1 Separação perfeita: quando o ajuste diverge

ARMADILHA COMUM

Se uma única feature (ou combinação delas) separa **perfeitamente** as duas classes, a verossimilhança é maximizada quando o coeficiente daquela feature tende a **infinito** — o algoritmo de otimização diverge ou para num limite arbitrário definido pelo número máximo de iterações. Isso costuma acontecer com datasets pequenos ou uma feature de vazamento (tema 3) forte demais. O sintoma: coeficientes gigantescos e erros-padrão enormes. A correção mais simples é regularização (módulo 2) — Ridge/Lasso aplicados à logística sempre têm solução finita.

NO MERCADO

Um caso real e recorrente: um analista júnior inclui `motivo_do_encerramento` como feature num modelo de "vai cancelar?" — mas essa coluna só é preenchida **depois** do cancelamento acontecer. O modelo "aprende" perfeitamente (separação perfeita, acurácia de treino de 100%) e falha completamente em produção, porque a feature nunca vai existir no momento real da previsão. É o mesmo vazamento de alvo do tema 3, módulo 4 — e a separação perfeita durante o treino é, com frequência, o primeiro sinal de alarme que expõe o problema.

4. Interpretando coeficientes: odds ratio


$$\frac{P(y=1|x_1+1)/P(y=0|x_1+1)}{P(y=1|x_1)/P(y=0|x_1)} = e^{\beta_1}$$

Aumentar x_1 em uma unidade multiplica a **razão de chances** por e^{β_1} — não soma um valor fixo à probabilidade, e não multiplica a probabilidade diretamente.

ARMADILHA COMUM

A confusão mais comum do módulo: $e^{\beta_1} = 1,5$ **não** significa "50% mais provável" em termos de probabilidade — significa que as **chances** (odds) aumentam 50%. Se a probabilidade de base já é alta (perto de 1), esse aumento de odds se traduz em uma mudança pequena na probabilidade; se a probabilidade de base é baixa, o mesmo aumento de odds pode mudar bastante a probabilidade. A relação entre odds e probabilidade não é linear.

A figura abaixo quantifica exatamente essa não-linearidade: para o mesmo odds ratio de 2 (as chances dobram), o quanto a probabilidade realmente se move depende de onde ela começa. Perto de 0% ou 100%, quase nada muda; perto de 50%, a mudança é máxima.



O mesmo odds ratio (as chances dobram) produz uma variação de probabilidade bem maior perto de 50% do que perto dos extremos — a não-linearidade entre odds e probabilidade, quantificada.


NO MERCADO

Em modelos de crédito e saúde, reportar odds ratio (não só o coeficiente bruto) é prática padrão de mercado — é a forma que analistas de negócio e reguladores esperam ver, precisamente porque tem interpretação multiplicativa direta ("cada atraso anterior praticamente dobra as chances de inadimplência"). Um relatório de crédito típico traz uma tabela como: `n_atrasos_12m`: odds ratio 1,85 (IC 95%: [1,62, 2,11]) — lido como "cada atraso adicional nos últimos 12 meses multiplica as chances de inadimplência por 1,85, mantendo as demais variáveis constantes".

5. Fronteira de decisão: um hiperplano, de novo

Classificar como 1 quando $p \geq 0,5$ equivale a classificar como 1 quando $z = \beta^\top x \geq 0$ — a fronteira de decisão é o **hiperplano** $\beta^\top x = 0$, a mesma estrutura geométrica linear vista em toda regressão linear (tema 2). Regressão logística é, geometricamente, um classificador **linear**: ela separa o espaço de features em duas regiões usando um hiperplano, ainda que a saída seja uma probabilidade suave em vez de um rótulo duro — visível no gradiente de cores da figura a seguir, que fica mais intenso conforme se afasta da fronteira em qualquer direção.

A fronteira $P=0,5$ (linha preta) é sempre um hiperplano — reta em 2D



A fronteira de decisão ($P=0,5$, linha preta) é sempre uma reta em 2D — um hiperplano em dimensões maiores. As cores mostram como a probabilidade prevista se afasta suavemente de 0,5 para cada lado.

NOTA

Essa é a razão pela qual regressão logística falha em problemas onde a fronteira real entre classes não é aproximadamente linear (um XOR, um círculo dentro de outro) — o mesmo tipo de limitação que motivou o módulo de SVM com kernels e, mais adiante, redes neurais com camadas ocultas (tema 8).

6. Multiclasse: softmax e one-vs-rest

Para K classes, duas estratégias comuns: **one-vs-rest** (treinar K classificadores binários, cada um "esta classe vs. todas as outras") e a generalização direta via **softmax**:

$$P(y = k|x) = \frac{e^{\beta_k^\top x}}{\sum_{j=1}^K e^{\beta_j^\top x}}$$

que reduz exatamente à sigmoide quando $K = 2$.

NO MERCADO

Um sistema de triagem de tickets de suporte com 5 categorias (**financeiro**, **técnico**, **cancelamento**, **elogio**, **outro**) é um caso típico de multiclasse via softmax — o modelo devolve uma distribuição de probabilidade sobre as 5 categorias, e a categoria de maior probabilidade vira o roteamento automático do ticket. É a mesma matemática usada na camada final de classificação de praticamente toda rede neural (tema 8).

7. Erros que custam caro — checklist

- Interpretar o coeficiente bruto (não exponenciado) como se fosse interpretável diretamente em termos de probabilidade.
- Confundir "as chances dobraram" com "a probabilidade dobrou".
- Ignorar sinais de separação perfeita (coeficientes e erros-padrão anormalmente grandes) e reportar o modelo como se tivesse convergido bem — investigue vazamento antes de comemorar.
- Usar o limiar de 0,5 sem considerar o desbalanceamento de classes ou o custo assimétrico de erros (tema 3, módulo 5).
- Esquecer que a fronteira de decisão é linear — aplicar regressão logística simples a um problema com fronteira claramente não-linear sem antes tentar features de interação ou um modelo não-linear.
- Não regularizar quando há muitas features ou risco de separação perfeita.

8. Para ir além

- Hosmer, Lemeshow & Sturdivant, *Applied Logistic Regression* — o texto de referência sobre interpretação e diagnóstico.
- Agresti, *Categorical Data Analysis* — o tratamento formal de odds ratio e modelos para dados categóricos.
- McCullagh & Nelder, *Generalized Linear Models* — o arcabouço unificado (GLM) do qual a regressão logística é um caso particular.