

k-NN e Naive Bayes

O modelo que não aprende nada e o que assume tudo independente — dois extremos que ainda ganham de modelos sofisticados

k-NN e Naive Bayes representam as duas filosofias mais opostas de aprendizado supervisionado. k-NN não constrói modelo nenhum — decide olhando os vizinhos mais parecidos no momento da previsão. Naive Bayes assume que todas as features são independentes entre si, uma premissa quase sempre falsa que, mesmo assim, produz um classificador rápido e surpreendentemente competente. Este material constrói os dois do zero e mapeia exatamente onde cada um vence e onde cada um quebra.

Nível: Intermediário — requer Vetores, Matrizes e Projeções (tema 2) e Teorema de Bayes (tema 1)

Pre-requisitos: Vetores, Matrizes e Projeções; Teorema de Bayes; Preparação de Dados (tema 3)

Carga sugerida: 6 a 8 horas (leitura + 2 notebooks)

Notebooks: 01-knn · 02-naive-bayes · 99-exercicios

Autoria: Material do curso de ML & DL

Versão: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. k-NN: aprendizado baseado em instância	4
2.1 Por que padronizar é obrigatório (revisão do tema 2 e 3)	4
2.2 A maldição da dimensionalidade	4
2.3 Escolhendo k: o trade-off viés-variância, de novo	4
2.4 k-NN ponderado e k-NN para regressão	5
3. Naive Bayes: tudo é independente (mesmo sabendo que não é)	6
3.1 Por que funciona mesmo sendo "errado"	6
3.2 As três variantes comuns	6
3.3 O problema da frequência zero e a suavização de Laplace	7
4. Comparando os dois: onde cada um vence	8
5. Erros que custam caro — checklist	9
6. Para ir além	10

1. Por que este módulo existe

Os módulos anteriores construíram modelos que **aprendem parâmetros**: uma regressão ajusta β , minimizando uma perda sobre o dataset inteiro, e depois descarta os dados de treino — só os coeficientes importam na hora de prever. Este módulo apresenta dois modelos que quebram essa lógica de formas opostas. k-NN **não aprende parâmetro nenhum**: ele guarda o dataset de treino inteiro e decide, a cada nova previsão, olhando para os vizinhos mais próximos. Naive Bayes aprende parâmetros, mas parte de uma suposição extrema — que todas as features são **independentes entre si** dado a classe — quase sempre falsa e, ainda assim, competitiva.

ANALOGIA

k-NN decide como alguém sem experiência prévia decidiria: "os cinco casos mais parecidos com este que eu já vi tinham esse resultado, então aposto nesse resultado". Naive Bayes decide como um burocrata excessivamente simplificador: "vou avaliar cada evidência separadamente e multiplicar as probabilidades, mesmo sabendo que elas provavelmente não são independentes na vida real" — e, surpreendentemente, ainda assim acerta bastante.

1.1 O que você vai conseguir fazer ao final

- Implementar k-NN do zero e explicar por que ele exige padronização e sofre com a maldição da dimensionalidade.
- Escolher k por validação cruzada, entendendo o trade-off viés-variância que ele controla.
- Implementar Naive Bayes Gaussiano do zero a partir do teorema de Bayes (tema 1) e da suposição de independência condicional.
- Explicar por que Naive Bayes funciona bem na prática apesar de sua premissa ser quase sempre falsa.

2. k-NN: aprendizado baseado em instância

O algoritmo inteiro: para classificar um ponto novo, encontre os k pontos de treino mais próximos (por alguma métrica de distância, tema 2) e vote pela classe majoritária entre eles (ou, em regressão, tire a média dos valores).

DEFINICAO

k-NN é chamado de **lazy learner** (aprendiz preguiçoso): não existe fase de "treino" que produza um modelo compacto — todo o trabalho acontece no momento da previsão (**predict**), quando o algoritmo precisa calcular distância até todos (ou muitos) os pontos de treino. Isso é o oposto de um modelo como regressão linear, que faz todo o trabalho pesado no **fit** e o **predict** é uma simples multiplicação de matrizes.

2.1 Por que padronizar é obrigatório (revisão do tema 2 e 3)

k-NN mede distância — e o tema 2 já mostrou que features em escalas diferentes distorcem qualquer cálculo de distância, deixando a feature de maior escala numérica dominar sozinha. Sem padronizar, k-NN na prática usa (quase) só a feature com maior variância numérica.

2.2 A maldição da dimensionalidade

ARMADILHA COMUM

Em dimensões altas, um fenômeno contraintuitivo acontece: a distância entre o ponto mais próximo e o mais distante de um ponto de referência **tende a ficar proporcionalmente pequena** — todos os pontos ficam "igualmente distantes". Isso acontece porque o volume do espaço cresce exponencialmente com o número de dimensões, e os dados ficam cada vez mais esparsos dentro dele. O conceito de "vizinho mais próximo" perde força discriminativa exatamente quando mais features são adicionadas sem discriminar as informativas das irrelevantes — a razão pela qual seleção de features (tema 3) importa ainda mais para k-NN do que para a maioria dos modelos.

2.3 Escolhendo k: o trade-off viés-variância, de novo

k	Comportamento
$k = 1$	Segue cada ponto de treino exatamente — variância altíssima, fronteira de decisão irregular, overfitting
k grande	Suaviza demais, pode ignorar estrutura local real — mais viés, mais estável
k ótimo	Escolhido por validação cruzada (tema 6), minimizando erro em dados não vistos

FORMULARIO

$k = 1$ classifica cada ponto de treino perfeitamente (o vizinho mais próximo de um ponto de treino é ele mesmo) — erro de treino zero, e ainda assim pode ter erro de generalização alto. É o exemplo mais direto de "erro de treino zero não significa modelo bom" do currículo inteiro.

2.4 k-NN ponderado e k-NN para regressão

Em vez de um voto igualitário entre os k vizinhos, pondera-se pelo inverso da distância — vizinhos mais próximos pesam mais. Para regressão, `KNeighborsRegressor` simplesmente tira a média (ponderada ou não) do valor dos k vizinhos, em vez de votar por classe.

3. Naive Bayes: tudo é independente (mesmo sabendo que não é)

Do teorema de Bayes (tema 1):

$$P(y|x_1, \dots, x_p) = \frac{P(x_1, \dots, x_p|y) P(y)}{P(x_1, \dots, x_p)}$$

Estimar $P(x_1, \dots, x_p|y)$ diretamente exigiria dados suficientes para cobrir toda combinação possível de features — inviável na prática. A suposição "naive" resolve isso à força:

$$P(x_1, \dots, x_p|y) \approx \prod_{j=1}^p P(x_j|y)$$

— cada feature é condicionalmente independente das outras, dado y . Isso reduz o problema a estimar p distribuições univariadas simples, uma por feature, em vez de uma distribuição conjunta complexa.

ARMADILHA COMUM

Essa suposição é **quase sempre falsa**: `renda` e `tempo_de_emprego`, por exemplo, tipicamente são correlacionadas mesmo dentro de uma mesma classe. O nome "naive" existe exatamente por isso.

3.1 Por que funciona mesmo sendo "errado"

NOTA

Classificação só precisa da **ordem relativa** das probabilidades posteriores entre as classes, não do valor exato de cada uma. Mesmo que a suposição de independência distorça a magnitude das probabilidades estimadas (Naive Bayes é notoriamente mal-calibrado — tema 6), a distorção frequentemente afeta todas as classes de forma parecida, preservando qual classe tem a maior probabilidade estimada — que é tudo que a decisão final precisa.

3.2 As três variantes comuns

Variante	Assume que $P(x_j y)$ é	Uso típico
Gaussian NB	Normal, por classe	Features contínuas
Multinomial NB	Multinomial (contagens)	Contagens de palavras, bag-of-words (tema 9)
Bernoulli NB	Bernoulli (presença/ausência)	Features binárias

3.3 O problema da frequência zero e a suavização de Laplace

Se uma categoria nunca apareceu com uma classe específica no treino, $P(x_j|y) = 0$ para essa combinação — e como as probabilidades se multiplicam, **um único zero zera o produto inteiro**, não importa quão forte seja a evidência das outras features.

FORMULARIO

Suavização de Laplace (add-one smoothing): soma um pseudo- contador pequeno a cada contagem antes de estimar a probabilidade:

$$P(x_j = v|y) = \frac{\text{contagem}(x_j = v, y) + \alpha}{\text{contagem}(y) + \alpha \cdot |\text{valores possíveis de } x_j|}$$

com $\alpha = 1$ sendo o padrão clássico. Isso garante que nenhuma probabilidade estimada seja exatamente zero, mesmo para combinações nunca observadas no treino.

4. Comparando os dois: onde cada um vence

NO MERCADO

k-NN tende a vencer quando a fronteira de decisão real é complexa e não-linear, há poucas features (dimensionalidade baixa a moderada) e o dataset não é gigante (custo de previsão cresce com n). Naive Bayes tende a vencer quando há **muitas** features (texto, bag-of-words — tema 9), o dataset é grande, velocidade de treino e previsão importam, e uma suposição aproximada de independência não destrói o sinal principal.

5. Erros que custam caro — checklist

- Aplicar k-NN sem padronizar features primeiro.
- Escolher $k = 1$ ou um valor arbitrário sem validação cruzada.
- Usar k-NN em datasets de altíssima dimensionalidade sem antes reduzir ou selecionar features (tema 3, 5).
- Esquecer a suavização de Laplace e deixar uma única categoria não vista zerar toda a previsão do Naive Bayes.
- Interpretar as probabilidades de saída do Naive Bayes como bem calibradas sem verificar (tema 6).
- Ignorar o custo computacional de k-NN em produção com datasets grandes — cada previsão exige (na implementação ingênua) uma varredura completa do treino.

6. Para ir além

- Cover & Hart (1967), o artigo original que formaliza k-NN e suas garantias assintóticas.
- Domingos & Pazzani (1997), *On the Optimality of the Simple Bayesian Classifier under Zero-One Loss* — a explicação formal de por que Naive Bayes funciona apesar da suposição errada.
- Bishop, *Pattern Recognition and Machine Learning*, capítulos sobre métodos não-paramétricos e classificadores Bayesianos.