

Bagging e Random Forest

Transformando a instabilidade de uma árvore em vantagem coletiva

O módulo anterior terminou com um problema — árvores de decisão têm variância altíssima, mudando de estrutura com pequenas variações no treino. Este módulo mostra que esse "defeito" é explorável: calcular a média de muitas árvores instáveis, cada uma treinada numa amostra bootstrap diferente, reduz a variância sem aumentar o viés. Random Forest injeta uma segunda fonte de aleatoriedade — subamostragem de features — para descorrelacionar as árvores ainda mais. Este material constrói bagging do zero, mede o ganho de descorrelação, e formaliza os dois tipos de importância de features.

Nível: Intermediário — requer Árvores de Decisão (módulo anterior) e Estimadores e Bootstrap (tema 1)

Pre-requisitos: Árvores de Decisão; Intervalos de Confiança e Bootstrap (tema 1)

Carga sugerida: 8 a 10 horas (leitura + 3 notebooks)

Notebooks: 01-bagging-e-variância · 02-random-forest · 03-importancia-de-features · 99-exercicios

Autoria: Material do curso de ML & DL

Versão: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. Bagging: bootstrap aggregating	4
3. Random Forest: uma segunda fonte de aleatoriedade	5
4. Erro out-of-bag: validação de graça	6
5. Dois tipos de importância de features	7
5.1 Importância por impureza (MDI — Mean Decrease Impurity)	7
5.2 Importância por permutação	7
6. Erros que custam caro — checklist	8
7. Para ir além	9

1. Por que este módulo existe

O módulo anterior identificou o defeito central de árvores de decisão: variância altíssima — pequenas mudanças no treino produzem árvores estruturalmente diferentes. A reação ingênua seria tentar estabilizar cada árvore individual. A reação inteligente, e o assunto deste módulo, é o oposto: **aceitar que cada árvore é instável, treinar muitas delas em variações dos dados, e usar a média**. O resultado — bagging, e sua evolução, Random Forest — transforma o pior defeito de árvores individuais na fonte da força do ensemble.

ANALOGIA

Perguntar a **uma pessoa** para adivinhar o peso de um boi numa feira produz um palpite ruidoso. Perguntar a **mil pessoas independentes** e tirar a média produz uma estimativa notavelmente precisa — é a "sabedoria das multidões". Bagging faz exatamente isso com árvores: cada árvore individual é um "palpite" ruidoso e enviesado por sua amostra específica; a média de muitas reduz o ruído sem introduzir nenhum viés novo, desde que os palpites sejam suficientemente independentes uns dos outros.

1.1 O que você vai conseguir fazer ao final

- Explicar matematicamente por que a média de estimadores reduz variância, e o papel crítico da correlação entre eles.
- Implementar bagging do zero e medir a redução de variância diretamente.
- Explicar a segunda fonte de aleatoriedade do Random Forest (subamostragem de features) e por que ela descorrelaciona as árvores além do que bagging sozinho consegue.
- Usar o erro out-of-bag como validação "de graça", e escolher entre importância por impureza e por permutação com um argumento técnico.

2. Bagging: bootstrap aggregating

O algoritmo: para $b = 1, \dots, B$, sorteie uma amostra bootstrap (com reposição, tema 1) do dataset de treino, treine um modelo nela, e agregue as previsões dos B modelos (média para regressão, voto majoritário para classificação).

FORMULARIO

Para B estimadores com variância individual σ^2 e correlação par a par ρ , a variância da média é:

$$\text{Var}\left(\frac{1}{B}\sum_b \hat{f}_b\right) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

Conforme $B \rightarrow \infty$, o segundo termo desaparece, mas o **primeiro termo, $\rho\sigma^2$, não** — é um piso que só a correlação entre os estimadores determina. Essa fórmula é a peça central de todo este módulo: **aumentar B além de um ponto tem retorno decrescente; reduzir ρ (a correlação entre árvores) é o que continua valendo a pena.**

NOTA

Árvores de decisão são o "material-base" ideal para bagging precisamente porque têm variância alta (muito a ganhar reduzindo) e, sem nenhuma poda agressiva, viés baixo (a agregação não introduz viés sistemático novo). Modelos de viés alto e variância baixa (como uma regressão linear simples) ganham pouco com bagging — não há muita variância para reduzir.

3. Random Forest: uma segunda fonte de aleatoriedade

Bagging sozinho tem uma limitação: se uma feature é muito mais informativa que as outras, **toda** árvore do bagging tende a escolhê-la no primeiro corte — as árvores continuam parecidas (correlação ρ alta), mesmo vindo de amostras bootstrap diferentes.

DEFINICAO

Random Forest adiciona: em cada corte, considere apenas um subconjunto **aleatório** de features (tipicamente $\sqrt{p}$ para classificação, $p/3$ para regressão) como candidatas, em vez de todas. Isso força árvores diferentes a explorar features diferentes, **reduzindo** ρ diretamente — o termo que bagging sozinho não ataca.

NO MERCADO

Esse é o motivo pelo qual Random Forest tipicamente supera bagging simples de árvores, mesmo usando exatamente o mesmo algoritmo de árvore por baixo — a diferença inteira está em reduzir a correlação entre os membros do ensemble, não em melhorar cada árvore individualmente.

4. Erro out-of-bag: validação de graça

Cada amostra bootstrap deixa de fora, em média, cerca de **36,8%** dos dados originais ($\lim_{n \rightarrow \infty} (1 - 1/n)^n = e^{-1} \approx 0.368$) — as observações **out-of-bag (OOB)** daquela árvore.

FORMULARIO

Para cada observação do treino, é possível calcular a previsão usando **apenas as árvores que não a viram** no treino (ela estava fora da amostra bootstrap daquelas árvores) — produzindo uma estimativa de erro de generalização **sem separar um conjunto de validação à parte**. O erro OOB tende a se aproximar do erro de validação cruzada, ao custo computacional de nada além do próprio treino do ensemble.

5. Dois tipos de importância de features

5.1 Importância por impureza (MDI — Mean Decrease Impurity)

Soma, sobre todas as árvores e todos os cortes que usam aquela feature, a redução de impureza (Gini, módulo anterior) proporcionada.

ARMADILHA COMUM

Como visto no tema 3 (módulo 3), MDI é **enviesada a favor de features de alta cardinalidade** — quanto mais valores distintos uma feature pode assumir, mais chances o algoritmo guloso tem de encontrar **algum** corte que pareça bom por puro acaso, mesmo sem relação real com o alvo. Esse viés é sistemático, não um problema raro.

5.2 Importância por permutação

Embaralha os valores de uma feature (destruindo sua relação real com o alvo, mas preservando sua distribuição marginal) e mede o quanto o desempenho do modelo **cai**. Quanto maior a queda, mais importante a feature era de fato.

NO MERCADO

Importância por permutação, calculada em dados de **validação** (não de treino), é mais confiável que MDI precisamente porque não sofre do viés de cardinalidade — ela mede o efeito real no desempenho preditivo, não uma propriedade estrutural de quantos cortes uma feature permite. O tema 11 (Interpretabilidade) aprofunda essa e outras técnicas — este módulo estabelece a base.

6. Erros que custam caro — checklist

- Usar poucas árvores (`n_estimators` baixo) e não perceber que o erro ainda está caindo — mais árvores quase nunca pioram o resultado, só custam mais tempo de treino.
- Confiar cegamente em importância por impureza (MDI) para decidir quais features remover, sem checar se o resultado é consistente com importância por permutação.
- Esquecer que o erro OOB já é uma estimativa de validação gratuita, e separar um conjunto de validação adicional desnecessariamente em datasets pequenos.
- Não ajustar `max_features` — o parâmetro que controla diretamente a decorrelação entre árvores, e que faz Random Forest ser mais que "bagging de árvores".
- Achar que Random Forest sempre supera Gradient Boosting (próximo módulo) — em dados tabulares, boosting tende a vencer com ajuste cuidadoso, ainda que Random Forest seja mais robusto a hiperparâmetros mal escolhidos.

7. Para ir além

- Breiman (2001), *Random Forests* — o artigo original, com a decomposição de variância usada neste módulo.
- Breiman (1996), *Bagging Predictors* — o artigo que introduz bagging.
- Louppe, *Understanding Random Forests* (tese de doutorado) — tratamento moderno e completo, incluindo os dois tipos de importância de features.