

Detecção de Anomalias

Encontrar o raro sem saber, de antemão, como ele se parece

Fraude, invasão de rede, falha de equipamento e erro de cadastro têm algo em comum: são raros, caros e mudam de forma o tempo todo — o que torna o aprendizado supervisionado insuficiente sozinho. Este material cobre os três tipos de anomalia (pontual, contextual e coletiva), os três regimes de rótulo (não supervisionado, novidade e supervisionado), os métodos estatísticos robustos (z-score com mediana e MAD, cercas de Tukey, distância de Mahalanobis com covariância robusta), Isolation Forest e LOF com suas fórmulas e exemplos numéricos, One-Class SVM e erro de reconstrução, a avaliação com orçamento de alertas (precisão@k) e a arquitetura de um sistema real de detecção de fraude, que combina escores não supervisionados com modelos supervisionados.

Nível: Intermediário/Avançado — encerra o tema de Aprendizado Não Supervisionado

Pre-requisitos: Clustering e Redução de Dimensionalidade (módulos anteriores); Dados Desbalanceados (tema 3); Árvores de Decisão (tema 4)

Carga sugerida: 10 a 12 horas (leitura + 3 notebooks)

Notebooks: 01-metodos-estatisticos · 02-isolation-forest-e-lof · 03-caso-real-fraude · 99-exercicios

Autoria: Material do curso de ML & DL

Versão: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. O que é uma anomalia	5
2.1 Três tipos	5
2.2 Anomalia não é ruído — e outlier não é erro	6
2.3 Três regimes de rótulo	6
3. Métodos estatísticos: simples, rápidos e frequentemente suficientes	7
3.1 O z-score e o problema do mascaramento	7
3.2 A versão robusta: mediana e MAD	7
3.3 Mahalanobis: anomalia multivariada	8
4. Isolation Forest	11
5. LOF: densidade relativa aos vizinhos	13
6. Outros métodos: One-Class SVM e erro de reconstrução	15
7. Avaliação: o orçamento de alertas	16
8. Caso real: um sistema de detecção de fraude	18
8.1 Resumo: qual método para qual situação	18
9. Erros que custam caro — checklist	20
10. Para ir além	21

1. Por que este módulo existe

O tema 3 (Dados Desbalanceados) tratou de problemas em que a classe rara tem **rótulo**: sabemos quais transações do passado foram fraude e treinamos um classificador. Esse cenário é o ideal — e quase nunca é o cenário completo. Em detecção de anomalias, três dificuldades aparecem juntas:

- **Rótulos são escassos ou inexistentes.** Uma falha de turbina pode acontecer duas vezes em uma década; um novo tipo de ataque de rede não tem nenhum exemplo histórico.
- **Rótulos chegam atrasados e incompletos.** Uma fraude de cartão só é confirmada quando o cliente contesta a fatura, semanas depois; as fraudes que ninguém contestou nunca recebem rótulo.
- **O raro muda de forma.** Fraudadores se adaptam ao modelo que os bloqueia. Um classificador supervisionado aprende a reconhecer as fraudes de **ontem**; a fraude de amanhã pode não se parecer com nenhuma delas.

Detecção de anomalias é a família de métodos que procura observações que se desviam do padrão da maioria, sem precisar (ou sem depender só) de exemplos rotulados do que é anômalo. A premissa central: anomalias são **poucas** e **diferentes** — e essas duas propriedades, por si só, já permitem encontrá-las.

ANALOGIA

Um segurança de shopping experiente não tem uma lista de todos os comportamentos criminosos possíveis. Ele conhece muito bem o comportamento **normal** — o ritmo de quem passeia, de quem compra, de quem espera alguém — e presta atenção em quem destoa: a pessoa que passa pela mesma porta seis vezes em dez minutos, o carrinho parado há uma hora no mesmo lugar. Nem todo comportamento destoante é crime (pode ser alguém perdido), mas quase todo crime destoa. Detecção de anomalias é isso: modelar o normal com cuidado e investigar o que foge dele.

1.1 O que você vai conseguir fazer ao final

- Classificar um problema quanto ao tipo de anomalia (pontual, contextual, coletiva) e ao regime de rótulo, e escolher a família de método adequada.
- Aplicar métodos estatísticos **robustos** e explicar, com números, por que a média e o desvio-padrão falham na presença das próprias anomalias.
- Calcular a distância de Mahalanobis à mão e usá-la com um limiar do qui-quadrado.
- Explicar Isolation Forest e LOF a partir das fórmulas, sabendo quando

cada um vence.


- Avaliar um detector pelo que o negócio consegue investigar — precisão e recall no orçamento de alertas — e desenhar um sistema que combine escores não supervisionados com modelos supervisionados.
-

2. O que é uma anomalia

Não existe definição matemática universal. A definição operacional mais útil é a de Hawkins (1980): *uma observação que se desvia tanto das demais que desperta suspeita de ter sido gerada por um mecanismo diferente*. A palavra-chave é **mecanismo**: a anomalia interessa porque sugere que algo diferente aconteceu — uma fraude, uma falha, um erro de digitação.

2.1 Três tipos

- **Pontual:** uma observação isolada muito diferente das demais — uma compra de R\$ 45.000 num cartão cujo maior gasto histórico foi R\$ 800.
- **Contextual (ou condicional):** o valor é normal em um contexto e anômalo em outro — 29 °C é uma temperatura comum no verão e anômala em julho numa cidade do sul; um pico de acessos às 3h da manhã é anômalo, o mesmo pico às 20h não.
- **Coletiva:** cada observação é normal isoladamente, mas a **sequência** ou o **conjunto** não é — um sinal de eletrocardiograma que "congela" num valor plausível por dois segundos; dezenas de compras pequenas e normais em sequência rápida, testando se um cartão roubado funciona.



Os três tipos de anomalia: pontual (longe de tudo), contextual (valor comum na época errada) e coletiva (cada valor é normal, a sequência não).

NOTA

Anomalias contextuais e coletivas se reduzem a pontuais com a **feature certa**. A temperatura de julho vira pontual quando a feature é "temperatura menos a média histórica do mês"; o teste de cartão vira pontual quando a feature é "número de transações do cartão na última hora". Boa parte do trabalho real de detecção de anomalias é feature engineering (tema 3) que transforma contexto em números.

2.2 Anomalia não é ruído — e outlier não é erro

Um valor extremo pode ser (1) um **erro** de medição ou digitação, que deve ser corrigido ou descartado; (2) um evento **legítimo e raro**, como o cliente que de fato comprou um carro no cartão; ou (3) o **sinal** que se procura, como a fraude. O tema 3 (módulo 2) tratou outliers como problema de qualidade de dados; aqui eles são o objeto de estudo. Um detector não distingue os três casos — ele aponta o que é diferente, e a interpretação fica com quem investiga.

2.3 Três regimes de rótulo

Regime	O que se tem no treino	Pergunta	Exemplos de método
Não supervisionado (<i>outlier detection</i>)	dados misturados, sem rótulo	quais pontos desta base são diferentes?	Isolation Forest, LOF, z robusto
Novidade (<i>novelty detection</i>)	só dados normais	este ponto novo é diferente do normal?	One-Class SVM, LOF com <i>novelty=True</i> , autoencoder
Supervisionado	exemplos rotulados das duas classes	este ponto é da classe rara?	classificação desbalanceada (tema 3)

ARMADILHA COMUM

No `scikit-learn`, `LocalOutlierFactor` funciona de dois modos diferentes. No padrão (*novelty=False*), ele só dá escores para os pontos do próprio treino (*fit_predict*) — não existe *predict* para pontos novos. Com *novelty=True*, ele deve ser treinado **só com dados normais** e passa a ter *predict* e *score_samples* para dados novos. Usar o modo novidade treinando com dados contaminados por anomalias faz o modelo aprender as anomalias como parte do "normal".

3. Métodos estatísticos: simples, rápidos e frequentemente suficientes

3.1 O z-score e o problema do mascaramento

O ponto de partida é o **z-score** (tema 1): quantos desvios-padrão uma observação está da média, $z = (x - \bar{x})/s$, com $|z| > 3$ como regra clássica de alerta. Para uma normal, só 0,27% das observações passam desse limiar por acaso.

O problema é que $\bar{x}$ e s são calculados com **todos** os dados — inclusive as anomalias. Se elas são numerosas ou extremas, elas próprias puxam a média e inflam o desvio-padrão, e o limiar se afasta até ficar **além** delas. Esse efeito se chama **mascaramento**.

Exemplo numérico. Tempo de resposta de uma API: 900 requisições normais em torno de 200 ms (desvio-padrão 20 ms) e 100 requisições lentas (10% do total, por causa de um servidor com defeito) em torno de 300 ms. Na amostra que gerou a figura abaixo, a média foi 209 ms e o desvio-padrão **36 ms** — quase o dobro do desvio real das requisições normais, inflado pelas lentas. O limiar clássico ficou em $209 + 3 \times 36 \approx 317$ ms, acima de quase todas as requisições lentas: o z-score detectou **só 4%** delas.

3.2 A versão robusta: mediana e MAD

A mediana e o **MAD** (*median absolute deviation*) são estatísticas robustas (tema 1, módulo 1): até metade dos dados pode ser contaminada antes que elas se desloquem arbitrariamente.


FORMULARIO

O z-score robusto troca média por mediana e desvio-padrão por MAD reescalado:

$$z_{rob} = \frac{x - \text{mediana}(x)}{1,4826 \cdot \text{MAD}}, \quad \text{MAD} = \text{mediana}(|x_i - \text{mediana}(x)|)$$

O fator 1,4826 (o inverso do quantil 75% da normal padrão, 1/0,6745) faz com que $1,4826 \cdot \text{MAD}$ estime o desvio-padrão quando os dados são normais — assim o limiar $|z_{rob}| > 3$ tem a mesma leitura do clássico.

No mesmo exemplo: mediana de 202,6 ms e MAD de 16,3 ms, o que dá um desvio robusto de $1,4826 \times 16,3 \approx 24,2$ ms e um limiar de $202,6 + 3 \times 24,2 \approx 275$ ms. O z robusto detectou **99%** das requisições lentas, sem nenhum falso alarme entre as normais.



Mascaramento: as requisições lentas inflam média e desvio-padrão e empurram o limiar clássico (âmbar) para além delas; o limiar robusto (verde) as separa das normais.

NOTA

As **cercas de Tukey** — o critério do boxplot, com alerta abaixo de $Q_1 - 1,5IQR$ ou acima de $Q_3 + 1,5IQR$ — também são robustas, porque quartis resistem a contaminação. Ambos os métodos supõem uma distribuição aproximadamente simétrica; para variáveis de cauda longa (valores monetários, contagens), aplique $\log(1+x)$ antes, ou quase toda a cauda direita legítima será marcada como anômala.

3.3 Mahalanobis: anomalia multivariada

Métodos univariados olham uma coluna de cada vez, e perdem anomalias que só aparecem na **combinação** de colunas. Uma pessoa com 1,90 m não é anômala; uma com 45 kg também não; uma com 1,90 m e 45 kg é. A distância de Mahalanobis mede o afastamento levando em conta a correlação entre as variáveis.

FORMULARIO

Para um vetor $\mathbf{x}$, com média $\boldsymbol{\mu}$ e matriz de covariância Σ :

$$D^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

Se os dados são normais multivariados em p dimensões, D^2 segue uma distribuição qui-quadrado com p graus de liberdade — o que dá um limiar com interpretação probabilística: $D^2 > \chi^2_{p, 0,975}$ marca os 2,5% mais improváveis.

Exemplo numérico. Duas variáveis padronizadas com correlação 0,8: Σ tem 1 na diagonal e 0,8 fora dela. Sua inversa é $\frac{1}{1-0,64}$ vezes a matriz com 1 na diagonal e $-0,8$ fora, isto é, 2,778 vezes essa matriz. Compare dois pontos à **mesma** distância euclidiana do centro, $\sqrt{2}$:


- $A = (1, 1)$, na direção da correlação:

$$D^2 = 2,778 \times (1 - 2 \cdot 0,8 + 1) = 2,778 \times 0,4 \approx 1,11.$$

- $B = (1, -1)$, contra a correlação:

$$D^2 = 2,778 \times (1 + 2 \cdot 0,8 + 1) = 2,778 \times 3,6 = 10,0.$$

Com $p = 2$, o limiar de 97,5% é $\chi^2_{2; 0,975} \approx 7,38$: B é anômalo, A não. A distância euclidiana trataria os dois como iguais.



A e B estão à mesma distância euclidiana do centro (círculo tracejado), mas só B está fora da elipse de Mahalanobis: ele viola a correlação que os dados seguem.

ARMADILHA COMUM

O mascaramento volta, agora em várias dimensões: se μ e Σ são estimados com dados contaminados, as anomalias distorcem a elipse a seu favor. A solução robusta é o **MCD** (*Minimum Covariance Determinant*, Rousseeuw, 1984): estima média e covariância usando só o subconjunto de h pontos (tipicamente cerca de metade mais um) cuja matriz de covariância tem o **menor determinante** — o subconjunto mais "compacto", que tende a excluir as anomalias. No `scikit-learn`, é o `MinCovDet`, usado internamente pelo `EllipticEnvelope`.

NO MERCADO


Em monitoramento industrial, Mahalanobis com covariância robusta sobre algumas dezenas de sensores é, até hoje, uma das primeiras linhas de defesa — em especial na forma do **gráfico T^2 de Hotelling** do controle estatístico de processos, que é exatamente D^2 monitorado ao longo do tempo. É barato, interpretável (dá para decompor D^2 na contribuição de cada sensor) e tem um limiar com significado probabilístico. Sua limitação é a premissa de uma única nuvem elíptica: uma planta que opera em vários regimes diferentes precisa de um modelo por regime — ou de um método que não suponha forma nenhuma.

4. Isolation Forest

Os métodos anteriores modelam o **normal** (uma média, uma elipse) e medem o afastamento dele. O Isolation Forest (Liu, Ting & Zhou, 2008) inverte a lógica: tenta **isolar** cada ponto, e parte da observação de que anomalias, por serem poucas e diferentes, são isoladas com muito menos esforço.

O algoritmo constrói árvores completamente aleatórias: em cada nó, sorteia uma feature e um ponto de corte uniforme entre o mínimo e o máximo dela naquele nó, e divide os dados. Repete até cada ponto ficar sozinho numa folha (ou até uma profundidade máxima). O número de cortes necessários para isolar um ponto é o **comprimento do caminho** $h(\mathbf{x})$ da raiz até sua folha.

Um ponto no meio da nuvem precisa de muitos cortes, porque está cercado de vizinhos que precisam ser separados dele; um ponto afastado cai sozinho num dos lados logo nos primeiros cortes. Na figura abaixo, com 121 pontos, isolar o ponto normal exigiu em média 11,7 cortes; isolar a anomalia, 2,9.



Isolar um ponto no meio da nuvem exige muitos cortes aleatórios; isolar a anomalia, poucos. À direita, a distribuição do número de cortes em 300 árvores aleatórias.

FORMULARIO

O escore de anomalia normaliza o comprimento médio do caminho sobre todas as árvores, $E[h(\mathbf{x})]$, pelo comprimento médio esperado de uma busca sem sucesso numa árvore binária de busca com n pontos:

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n}, \quad H(i) \approx \ln(i) + 0,5772$$

$$s(\mathbf{x}, n) = 2^{-E[h(\mathbf{x})]/c(n)}$$

s perto de 1 indica anomalia; s bem abaixo de 0,5, ponto normal; s perto de 0,5 para todos os pontos indica que não há anomalias distinguíveis.

Exemplo numérico. O padrão do algoritmo é construir cada árvore numa subamostra de $n = 256$ pontos. Então $H(255) \approx \ln 255 + 0,5772 \approx 6,119$
 $c(256) \approx 2 \times 6,119 - 2 \times 255/256 \approx 10,25$. Um ponto isolado, em média, em 4 cortes tem escore $s = 2^{-4/10,25} \approx 0,76$ (anômalo); um isolado em 10,25 cortes tem $s = 0,5$; um isolado

em 14 cortes tem $s = 2^{-14/10,25} \approx 0,39$ (normal).

Três detalhes que fazem o método funcionar na prática:

- **Subamostragem** (`max_samples=256`): cada árvore vê só uma pequena

amostra. Parece desperdício, mas reduz o **mascaramento** (menos anomalias juntas em cada árvore para se protegerem mutuamente) e o **encharcamento** (*swamping*, normais próximos de anomalias sendo confundidos com elas). Também torna o método muito rápido: custo linear em n .

- **Não usa distância**: não precisa de escalonamento e lida bem com

features de escalas diferentes. Mas sofre com **features irrelevantes**: cada corte sorteia uma feature, e se a anomalia aparece em só 3 de 50 colunas, a maioria dos cortes é desperdiçada nas outras 47. Nesse cenário, o notebook [02-isolation-forest-e-lof](#) mostra o Isolation Forest caindo para o pior lugar entre os métodos do módulo — selecionar as features relevantes antes ajuda muito.

- `contamination` não muda o modelo — só define o **limiar** que separa

o rótulo -1 (anomalia) do 1 (normal) em `predict`. O escore (`score_samples`) é o mesmo para qualquer valor de `contamination`.

ARMADILHA COMUM

Deixar `contamination="auto"` e usar `predict` como se fosse a resposta final é um erro comum: o limiar resultante não tem relação com a sua taxa real de anomalias nem com a capacidade do seu time de investigar alertas. Use o **escore** e escolha o limiar pelo orçamento de investigação (último capítulo). Outra limitação conhecida: os cortes paralelos aos eixos criam "faixas" artificiais de escore baixo ao longo das direções dos eixos; o **Extended Isolation Forest** usa cortes em direções aleatórias para corrigir isso.

5. LOF: densidade relativa aos vizinhos

Isolation Forest e Mahalanobis têm uma noção **global** de anomalia: longe do conjunto como um todo. Mas imagine duas populações com densidades muito diferentes — clientes corporativos, com comportamento muito homogêneo, e pessoas físicas, com comportamento muito espalhado. Um cliente corporativo ligeiramente fora do padrão corporativo é muito suspeito, mesmo estando **mais perto** do centro geral do que uma pessoa física perfeitamente normal. O **LOF** (*Local Outlier Factor*, Breunig et al., 2000) compara a densidade de cada ponto com a densidade dos **seus vizinhos**.

FORMULARIO

Com $N_k(A)$ os k vizinhos mais próximos de A e $d_k(B)$ a distância de B ao seu k -ésimo vizinho:

Distância de alcançabilidade (suaviza distâncias muito pequenas):

$$\text{reach}_k(A, B) = \max \{d_k(B), d(A, B)\}$$



Densidade local de alcançabilidade (o inverso da distância média):

$$\text{lrd}_k(A) = \left(\frac{1}{k} \sum_{B \in N_k(A)} \text{reach}_k(A, B) \right)^{-1}$$

Fator local de outlier (densidade média dos vizinhos dividida pela própria):

$$\text{LOF}_k(A) = \frac{1}{k} \sum_{B \in N_k(A)} \frac{\text{lrd}_k(B)}{\text{lrd}_k(A)}$$

A leitura é direta: $\text{LOF} \approx 1$ significa que o ponto tem a mesma densidade que seus vizinhos (normal, seja numa região densa ou esparsa); $\text{LOF} \gg 1$ significa que ele está numa região muito menos densa que a de seus vizinhos. **Exemplo numérico:** se os vizinhos de A têm densidade local média de 2,0 (vizinhos a cerca de 0,5 unidade entre si) e A tem densidade 0,5 (seus vizinhos estão, em média, a 2 unidades dele), então $\text{LOF}(A) = 2,0/0,5 = 4$: A está numa região quatro vezes mais rarefeita que a de seus vizinhos.



Um ponto suspeito (x roxo) perto do grupo denso, mas fora dele. Pela distância ao 10º vizinho, ele é só o 29º mais anômalo — os pontos da borda do grupo esparsa ganham dele. Pelo LOF (4,98), é o 1º.

NOTA

Na figura, a distância ao k -ésimo vizinho — uma noção global — coloca o ponto suspeito apenas em 29º lugar, atrás de dezenas de pontos perfeitamente normais da periferia do grupo esparso. O LOF, que compara o ponto com seus próprios vizinhos (todos do grupo denso), dá a ele o maior escore da base. O preço: LOF é baseado em distância (precisa de escalonamento, sofre em alta dimensão) e custa $O(n^2)$ no pior caso. O hiperparâmetro k (`n_neighbors`) define o que é "local"; valores entre 10 e 50 são comuns, e ele deve ser maior que o tamanho dos pequenos grupos de anomalias que se quer detectar — senão um bando de anomalias vira sua própria vizinhança densa.

6. Outros métodos: One-Class SVM e erro de reconstrução

One-Class SVM (Schölkopf et al., 2001) aplica a ideia de margem do tema 4 a uma única classe: procura, no espaço de um kernel (tipicamente RBF), a fronteira que envolve a maior parte dos dados normais, deixando no máximo uma fração ν de fora. O hiperparâmetro ν é um limite superior para a fração de pontos de treino tratados como anomalia. Funciona bem em **detecção de novidade** com dados de dimensão moderada, mas escala mal (custo entre $O(n^2)$ e $O(n^3)$) e é sensível ao γ do kernel.

Erro de reconstrução. Qualquer método de redução de dimensionalidade (módulo anterior) aprende a comprimir e reconstruir os dados **normais**. Observações anômalas, que não seguem a estrutura aprendida, são mal reconstruídas:

$$\text{escore}(\mathbf{x}) = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$$

Com PCA, $\hat{\mathbf{x}}$ é a projeção nos k primeiros componentes; com um autoencoder, a saída da rede. É o método padrão para dados de alta dimensão com estrutura forte — imagens de inspeção visual, espectros, séries de sensores em janelas — e a base de muitos sistemas de manutenção preditiva.

NO MERCADO


Em manutenção preditiva de motores elétricos, é comum treinar um autoencoder (ou um PCA) com janelas de vibração de motores **saudáveis** e monitorar o erro de reconstrução em produção. Rolamentos começando a falhar produzem assinaturas de frequência que o modelo nunca viu, e o erro sobe semanas antes da quebra. O regime é o de **novidade**: o treino usa só dados normais, porque exemplos de falha são raros demais para um classificador — e cada falha tem uma assinatura um pouco diferente.

7. Avaliação: o orçamento de alertas

Sem rótulos, não há métrica de desempenho — há só a inspeção manual dos casos com maior escore. Com alguns rótulos (casos investigados no passado, fraudes confirmadas), a avaliação deve refletir **como o detector é usado**: um time com capacidade limitada investiga, todo dia, os casos com maior escore.

DEFINIÇÃO

Precisão@k: fração dos k casos de maior escore que são de fato anomalias. **Recall@k**: fração de todas as anomalias que estão entre os k casos de maior escore. Quando k é a capacidade de investigação (o **orçamento de alertas**), essas duas métricas respondem diretamente às perguntas do negócio: "quanto do tempo do meu time é gasto com casos reais?" e "quanto do problema eu estou pegando?".



Precisão e recall em função do número de casos investigados, em 20 mil registros com 60 anomalias. Com 100 alertas, 45% são anomalias reais e 75% das anomalias são encontradas; ampliar para 300 alertas sobe o recall para 90%, mas derruba a precisão para 18%.

Exemplo numérico. Um banco processa 1 milhão de transações por dia, das quais 0,1% (1.000) são fraude. O time de prevenção investiga 500 casos por dia. Se o detector tem precisão@500 de 40%, o time encontra 200 fraudes por dia — recall de 20%. Dobrar a precisão (para 80%) dobra as fraudes encontradas **sem contratar ninguém**; dobrar o time, com a mesma precisão média nos alertas adicionais, também dobraria — mas a precisão costuma cair conforme se desce no ranking. É por isso que a curva precisão@k x recall@k, e não um número isolado, é o objeto de decisão.

ARMADILHA COMUM

ROC-AUC é uma métrica ruim para detecção de anomalias com prevalência muito baixa, pelo mesmo motivo discutido no tema 3: a taxa de falso positivo é calculada sobre uma base gigante de normais e quase não se mexe. Um detector com ROC-AUC de 0,98 pode ter precisão@ k medíocre. Prefira PR-AUC (*average precision*) e, principalmente, precisão e recall no k que o negócio consegue operar.

NOTA

Rótulos de detecção de anomalias vêm com **viés de seleção**: só se sabe se um caso era fraude se alguém o investigou — e só se investiga o que o detector atual (ou o anterior) apontou. Anomalias que nenhum detector apontou nunca recebem rótulo e parecem "normais" na base de avaliação. Uma prática para medir o que está escapando é investigar também uma pequena **amostra aleatória** de casos não alertados.

8. Caso real: um sistema de detecção de fraude

Sistemas reais de fraude raramente usam um único método. A arquitetura típica combina camadas:

- 1 **Regras de negócio** — "bloquear transação acima de R\$ 10.000 em cartão emitido há menos de 7 dias". Rápidas, auditáveis e escritas por especialistas; pegam os padrões conhecidos e óbvios.
- 2 **Features de contexto e comportamento** — valor relativo à média do próprio cliente, distância da localização habitual, número de transações na última hora, dispositivo novo. É aqui que anomalias contextuais e coletivas viram pontuais.
- 3 **Modelo supervisionado** — um gradient boosting (tema 4) treinado com o histórico de fraudes confirmadas, com tratamento de desbalanceamento (tema 3). É o componente mais preciso para fraudes **conhecidas**.
- 4 **Escore não supervisionados** — Isolation Forest, LOF ou erro de reconstrução, que capturam o que é **diferente** mesmo sem nunca ter sido rotulado. Entram de duas formas: como **feature** do modelo supervisionado e como fila **separada** de investigação para casos estranhos que o supervisionado considera seguros. A diferença importa: como feature, o escore só ajuda nos padrões que já têm rótulo (o modelo aprende a usá-lo onde viu fraude); só a fila separada alcança os tipos de fraude que ainda não aconteceram no histórico.
- 5 **Ciclo de feedback** — os casos investigados viram rótulos, que retreinam o modelo supervisionado. O notebook [03-caso-real-fraude](#) mostra por que a camada não supervisionada é indispensável: um tipo de fraude que **não existia** no histórico de treino passa despercebido pelo modelo supervisionado e é parcialmente capturado pelo detector de anomalias.

NO MERCADO

Em meios de pagamento, a decisão precisa sair em dezenas de milissegundos, durante a autorização da compra. Isso restringe o que roda em tempo real: árvores de boosting e Isolation Forest (com escore calculado por percurso em árvores) são rápidos; LOF, que precisa buscar vizinhos numa base grande a cada transação, raramente vai para o caminho crítico — costuma rodar em lote, em revisões posteriores. A escolha do método é também uma decisão de **latência**, tema do tema 13.

8.1 Resumo: qual método para qual situação

Método	Noção de anomalia	Precisa escalar?	Escala	Força	Fraqueza
z robusto / Tukey	longe da mediana, uma coluna por vez	não	ilimitada	simples, interpretável	não vê combinações

Método	Noção de anomalia	Precisa escalonar?	Escala	Força	Fraqueza
Mahalanobis + MCD	fora da elipse dos dados	não (é invariante)	milhões (p moderado)	limiar probabilístico	supõe uma nuvem elíptica
Isolation Forest	fácil de isolar	não	milhões	rápido, insensível à escala	noção global; perde força com muitas features irrelevantes
LOF	densidade menor que a dos vizinhos	sim	dezenas de milhares	anomalias locais	lento; sofre em alta dimensão
One-Class SVM	fora da fronteira do normal	sim	dezenas de milhares	novidade com kernel	escala mal; sensível a gamma
Erro de reconstrução	mal comprimido	sim	milhões	alta dimensão estruturada	exige treino só com normais

9. Erros que custam caro — checklist

- Usar média e desvio-padrão para definir limiar numa base contaminada — as próprias anomalias escondem a si mesmas (mascaramento).
- Aplicar z-score em variáveis de cauda longa sem transformar, marcando toda a cauda legítima como anômala.
- Olhar uma coluna de cada vez quando a anomalia está na combinação.
- Usar `contamination` (ou o `predict` com o limiar padrão) como decisão final, em vez de escolher o limiar pelo orçamento de investigação.
- Treinar um detector de novidade (One-Class SVM, LOF com `novelty=True`, autoencoder) com dados contaminados por anomalias.
- Avaliar com ROC-AUC quando a prevalência é de 0,1% — use `precisão@k`, `recall@k` e PR-AUC.
- Esquecer que os rótulos vêm só dos casos investigados, e concluir que o detector é ótimo porque "nada que ele deixou passar era fraude".
- Confiar só no modelo supervisionado num domínio adversarial — ele não enxerga o tipo de anomalia que ainda não aconteceu.
- Não monitorar a taxa de alertas em produção: se ela dobra de um dia para o outro, ou o mundo mudou ou o pipeline de features quebrou (tema 13).

10. Para ir além

- Chandola, Banerjee & Kumar (2009), *Anomaly Detection: A Survey* — a taxonomia clássica de tipos de anomalia e métodos.
- Liu, Ting & Zhou (2008), *Isolation Forest* — o artigo original, curto e muito legível.
- Breunig, Kriegel, Ng & Sander (2000), *LOF: Identifying Density-Based Local Outliers*.
- Rousseeuw & Van Driessen (1999), *A Fast Algorithm for the Minimum Covariance Determinant Estimator* — o algoritmo usado pelo [MinCovDet](#).
- Aggarwal, *Outlier Analysis* (Springer) — o livro-texto da área.
- Hariri, Kind & Brunner (2021), *Extended Isolation Forest*.