

Métricas de Classificação

A métrica é a definição de "bom" — escolha a errada e o modelo otimiza o problema errado

Todo modelo de classificação é avaliado por um número, e esse número decide qual modelo vai para produção. Este material constrói, a partir da matriz de confusão, o catálogo completo de métricas de classificação — acurácia, precisão, recall, especificidade, F-beta, acurácia balanceada, MCC e kappa —, mostra como a prevalência muda a precisão pelo teorema de Bayes, trata o caso multiclasse (macro, micro, ponderada), explica ROC-AUC como probabilidade de ordenar um par, PR-AUC e average precision, Gini e KS do mercado de crédito, curvas de ganho e lift, e fecha com a escolha do limiar pelo custo de negócio, intervalos de confiança por bootstrap e o teste de McNemar para comparar dois modelos no mesmo conjunto de teste.

Nível: Intermediário — abre o tema de Avaliação e Validação

Pre-requisitos: Testes de Hipótese e Bootstrap (tema 1); Dados Desbalanceados (tema 3); Regressão Logística (tema 4)

Carga sugerida: 10 a 12 horas (leitura + 3 notebooks)

Notebooks: 01-matriz-de-confusao-e-metricas · 02-roc-e-pr · 03-metrica-guiada-por-custo · 99-exercicios

Autoria: Material do curso de ML & DL

Versão: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. A matriz de confusão	4
2.1 As métricas de base	4
2.2 F-beta: combinar precisão e recall com pesos	5
2.3 Métricas que usam a matriz inteira: acurácia balanceada, MCC e kappa	6
3. A prevalência muda a precisão	7
4. Métricas multiclasse	8
5. Métricas de ranking: ROC-AUC e PR-AUC	9
5.1 A curva ROC e o significado da AUC	9
5.2 Precisão-recall e average precision	10
5.3 Por que a ROC é otimista quando a classe positiva é rara	11
5.4 Curvas de ganho e lift	11
6. Do score à decisão: o limiar	13
7. Quão certo é o número? Incerteza e comparação	15
8. Qual métrica para qual problema	16
9. Erros que custam caro — checklist	17
10. Para ir além	18

1. Por que este módulo existe

Os temas anteriores usaram métricas o tempo todo — acurácia, AUC, F1, PR-AUC — quase sempre como ferramenta, raramente como objeto de estudo. Este tema inverte a perspectiva. A pergunta deixa de ser "qual modelo é melhor?" e passa a ser "**o que significa ser melhor**, e como saber se a diferença que eu medi é real?".

A escolha da métrica não é um detalhe técnico no fim do projeto. Ela é a **definição operacional do problema**. Um modelo de triagem de câncer otimizado por acurácia, um modelo de fraude otimizado por ROC-AUC e um modelo de marketing otimizado por F1 podem estar, os três, resolvendo com competência o problema errado — porque o número que eles maximizam não é o número que o negócio precisa.

ANALOGIA

Uma escola que avalia professores só pela taxa de aprovação dos alunos vai, com o tempo, ter professores excelentes em aprovar alunos — o que não é o mesmo que professores excelentes em ensinar. Métricas moldam o comportamento de quem é avaliado por elas (a **lei de Goodhart**: quando uma medida vira meta, deixa de ser uma boa medida). Um modelo de machine learning é o avaliado mais obediente que existe: ele otimiza exatamente o que você mandou, sem nenhum bom senso sobre o que você quis dizer.

1.1 O que você vai conseguir fazer ao final

- Calcular, a partir de uma matriz de confusão, todas as métricas de classificação usuais — e explicar o que cada uma ignora.
 - Prever como a precisão de um modelo muda quando a prevalência muda, sem retreinar nada.
 - Escolher entre média macro, micro e ponderada num problema multiclasse.
 - Interpretar ROC-AUC como probabilidade, saber quando PR-AUC é mais informativa e traduzir AUC em Gini e KS para conversar com o mercado de crédito.
 - Escolher o limiar de decisão pelo custo e pela capacidade operacional, e comparar dois modelos com um teste estatístico em vez de "no olho".
-

2. A matriz de confusão

Todo classificador binário, depois de escolhido um limiar, produz quatro contagens. Usaremos a notação em português, com a equivalente em inglês entre parênteses, porque ambas aparecem na literatura e nas bibliotecas:

- **VP** — verdadeiro positivo (TP): era positivo e o modelo disse positivo.
- **FN** — falso negativo (FN): era positivo e o modelo disse negativo.
- **FP** — falso positivo (FP): era negativo e o modelo disse positivo.
- **VN** — verdadeiro negativo (TN): era negativo e o modelo disse negativo.

O exemplo que atravessa o módulo: um exame de triagem aplicado a **1.000 pacientes**, dos quais **100 têm a doença**. O modelo acerta 80 dos 100 doentes e dá alarme falso para 40 dos 900 saudáveis.

Matriz de confusão do exemplo: 1.000 pacientes, 100 doentes

	previsto: doente	previsto: saudável	
real: doente (100)	VP = 80 verdadeiro positivo	FN = 20 falso negativo	recall = 80/100 = 80%
real: saudável (900)	FP = 40 falso positivo	VN = 860 verdadeiro negativo	especificidade = 860/900 = 95.6%
	precisão = 80/120 = 66.7%		

A matriz de confusão do exemplo, com recall, especificidade e precisão calculados a partir dela.

2.1 As métricas de base

FORMULARIO

Com $n = VP + FN + FP + VN$:

$$\text{acurácia} = \frac{VP + VN}{n} \quad \text{precisão} = \frac{VP}{VP + FP} \quad \text{recall} = \frac{VP}{VP + FN} \quad \text{especificidade} = \frac{VN}{VN + FP}$$

Recall também se chama **sensibilidade** ou taxa de verdadeiro positivo (TPR); a taxa de falso positivo é $FPR = 1 - \text{especificidade}$. A precisão também se chama valor preditivo positivo (VPP).

No exemplo: acurácia = $940/1.000 = 94\%$; precisão = $80/120 \approx 66,7\%$; recall = $80/100 = 80\%$; especificidade = $860/900 \approx 95,6\%$.

Cada métrica responde a uma pergunta diferente — e ignora o resto:

- **Precisão:** "quando o modelo alarma, com que frequência acerta?" — ignora os doentes que ficaram sem alarme.
- **Recall:** "de todos os doentes, quantos o modelo encontrou?" — ignora quantos saudáveis foram incomodados.
- **Especificidade:** "de todos os saudáveis, quantos foram deixados em paz?" — ignora os doentes.
- **Acurácia:** "quantos acertos no total?" — mistura tudo, dominada pela classe majoritária.

ARMADILHA COMUM

O classificador que diz "saudável" para todo mundo tem acurácia de **90%** neste exemplo — só 4 pontos abaixo do modelo real — e não encontra um único doente. O tema 3 (módulo de Dados Desbalanceados) já mostrou esse efeito; aqui fica a regra geral: **acurácia só é informativa quando as classes são aproximadamente balanceadas e os dois tipos de erro custam parecido**. Fora disso, ela é a métrica mais enganosa do catálogo.

2.2 F-beta: combinar precisão e recall com pesos

FORMULARIO

A média harmônica ponderada de precisão (P) e recall (R):

$$F_{\beta} = (1 + \beta^2) \frac{P \cdot R}{\beta^2 P + R}$$

Com $\beta = 1$, precisão e recall pesam igual (é o F_1 , que também se escreve $F_1 = \frac{2VP}{2VP + FP + FN}$). Com $\beta = 2$, o recall pesa quatro vezes mais (β^2); com $\beta = 0,5$, a precisão pesa mais.

No exemplo, $F_1 = 160/220 \approx 0,727$ e $F_2 = 5 \cdot 0,667 \cdot 0,8 / (4 \cdot 0,667 + 0,8) \approx 0,769$ — maior que o F_1 , porque o modelo é melhor em recall (80%) que em precisão (67%), e o F_2 premia o recall.

Por que média **harmônica** e não aritmética? Porque ela é dominada pelo menor dos dois valores: um modelo com precisão 100% e recall 1% tem média aritmética de 50,5% e F_1 de apenas 2%. O F_1 não deixa um dos lados compensar o colapso do outro.

ARMADILHA COMUM

F_1 ignora completamente os **verdadeiros negativos**. Isso é conveniente quando a classe negativa é enorme e desinteressante (fraude, busca de documentos), mas faz o F_1 mudar de valor se você simplesmente **trocar qual classe chama de positiva** — algo que acurácia, MCC e kappa não fazem. Sempre declare qual é a classe positiva ao reportar F_1 .

2.3 Métricas que usam a matriz inteira: acurácia balanceada, MCC e kappa

FORMULARIO

Acurácia balanceada: a média do recall de cada classe.

$$\text{acurácia balanceada} = \frac{\text{recall} + \text{especificidade}}{2}$$

Coefficiente de correlação de Matthews (MCC): a correlação de Pearson entre o rótulo real e o previsto, calculada direto da matriz:

$$\text{MCC} = \frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}$$

Kappa de Cohen: a concordância observada p_o (a acurácia) corrigida pela concordância esperada por acaso p_e , dadas as proporções de cada classe no real e no previsto:

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

No exemplo: $\text{acurácia balanceada} = (0,80 + 0,956)/2 \approx 0,878$. $\text{MCC} = (80 \cdot 860 - 40 \cdot 20) / \sqrt{120 \cdot 100 \cdot 900 \cdot 880} = 68.000 / 97.488 \approx 0,698$. Para o kappa, o modelo prevê "doente" para 12% dos pacientes e 10% são doentes, então $p_e = 0,12 \cdot 0,10 + 0,88 \cdot 0,90 = 0,804$ e $\kappa = (0,94 - 0,804) / (1 - 0,804) \approx 0,694$.

O classificador que diz "saudável" para todos tem acurácia 90%, mas acurácia balanceada 0,5, MCC 0 e kappa 0 — essas três métricas **não se deixam enganar** pelo desbalanceamento.

NO MERCADO

MCC é considerado por boa parte da literatura a métrica escalar mais honesta para classificação binária desbalanceada (Chicco & Jurman, 2020), porque só é alto quando o modelo vai bem nos **quatro** quadrantes. Na prática de mercado, porém, ele é pouco conhecido por times de negócio; o caminho mais eficaz costuma ser reportar precisão e recall (que qualquer gestor entende) no limiar de operação, e usar MCC ou PR-AUC internamente para comparar modelos.

3. A prevalência muda a precisão

Recall e especificidade são propriedades do modelo **condicionadas à classe real**: "dado que o paciente é doente, qual a chance de o modelo alarmar?". Elas não dependem de quantos doentes existem na população. A precisão, ao contrário, depende — e o teorema de Bayes (tema 1, módulo 5) diz exatamente como.

FORMULÁRIO

Com prevalência π (fração de positivos na população):

$$\text{precisão} = \frac{\text{recall} \cdot \pi}{\text{recall} \cdot \pi + (1 - \text{especificidade})(1 - \pi)}$$

Exemplo numérico. O mesmo exame (recall 80%, especificidade 95,6%) aplicado a uma população com prevalência de **1%**, em vez de 10%:

$$\text{precisão} = \frac{0,80 \cdot 0,01}{0,80 \cdot 0,01 + 0,044 \cdot 0,99} = \frac{0,0080}{0,0080 + 0,0440} \approx 15,4\%$$

O modelo é exatamente o mesmo; a precisão caiu de 66,7% para 15,4% porque agora há muito mais saudáveis para gerar falsos positivos. De cada 100 alarmes, 85 são falsos.

ARMADILHA COMUM

Um modelo validado num conjunto de teste com prevalência artificial — por exemplo, um teste balanceado 50/50 montado para "facilitar a avaliação", ou uma amostra de hospital de referência, onde a doença é muito mais comum que na população geral — vai reportar uma precisão que **não se repete em produção**. Recall e especificidade viajam entre populações; precisão, F_1 e acurácia não. Sempre avalie na prevalência em que o modelo vai operar, ou recalcule a precisão com a fórmula acima.

4. Métricas multiclasse

Com K classes, a matriz de confusão é $K \times K$, e precisão, recall e F_1 são calculados **por classe** (cada classe como "positiva" contra todas as outras). A questão é como resumir K números em um:

- **Macro:** média simples das métricas por classe. Cada classe pesa igual, não importa quão rara — uma classe rara com desempenho ruim derruba a média.
- ****Ponderada (*weighted*):**** média ponderada pelo número de exemplos de cada classe. Dominada pelas classes grandes.
- **Micro:** soma VP, FP e FN de todas as classes e calcula a métrica uma

vez. Em classificação com um único rótulo por exemplo, micro-precisão, micro-recall e micro- F_1 são todos **iguais à acurácia**.

Exemplo numérico. Um classificador de tickets de suporte com três classes: "dúvida" (800 tickets, $F_1 = 0,95$), "reclamação" (150, $F_1 = 0,70$) e "cancelamento" (50, $F_1 = 0,40$). A média macro é $(0,95 + 0,70 + 0,40)/3 \approx 0,683$; a ponderada é $0,8 \cdot 0,95 + 0,15 \cdot 0,70 + 0,05 \cdot 0,40 = 0,885$. Se o que importa para o negócio são os cancelamentos — os tickets raros em que um cliente está indo embora —, a ponderada de 0,885 esconde o problema e a macro de 0,683 o revela.

NOTA

Regra prática: use **macro** quando todas as classes importam igualmente (ou as raras importam mais); **ponderada** quando o custo de erro é proporcional ao volume; e sempre olhe a tabela por classe (`classification_report`) antes de confiar em qualquer média.

5. Métricas de ranking: ROC-AUC e PR-AUC

As métricas até aqui exigem um limiar. Muitas vezes, porém, o que se quer avaliar é o **escore** em si — a capacidade do modelo de colocar positivos acima de negativos —, independentemente do limiar que será escolhido depois. Para isso servem as curvas ROC e precisão-recall.

5.1 A curva ROC e o significado da AUC

A curva ROC plota a taxa de verdadeiro positivo (recall) contra a taxa de falso positivo, variando o limiar de $+\infty$ (ninguém é positivo, ponto $(0, 0)$) até $-\infty$ (todos são positivos, ponto $(1, 1)$). Um modelo aleatório fica na diagonal; um perfeito passa pelo canto $(0, 1)$.

A área sob a curva, a **AUC**, tem uma interpretação probabilística exata, que é a forma mais útil de pensar nela:


FORMULARIO

A AUC é a probabilidade de que um positivo sorteado ao acaso receba um escore **maior** que um negativo sorteado ao acaso:

$$AUC = P(s^+ > s^-) = \frac{1}{n_+ n_-} \sum_{i \in +} \sum_{j \in -} [\mathbf{1}(s_i > s_j) + \frac{1}{2} \mathbf{1}(s_i = s_j)]$$

É a estatística U de Mann-Whitney (tema 1, testes não paramétricos) dividida pelo número de pares.

Exemplo numérico. Três positivos com escores $\{0,9; 0,6; 0,4\}$ e quatro negativos com $\{0,7; 0,3; 0,2; 0,1\}$. Dos $3 \times 4 = 12$ pares: o 0,9 vence os 4 negativos; o 0,6 vence 3 (perde para o 0,7); o 0,4 vence 3. Total: $10/12 \approx 0,833$.



Distribuições de escore de positivos e negativos. Sortear 200 mil pares (um positivo, um negativo) e contar quantas vezes o positivo tem escore maior dá a mesma AUC do roc_auc_score.

NO MERCADO

No mercado de crédito, a AUC costuma aparecer disfarçada de **Gini** — $\text{Gini} = 2 \cdot \text{AUC} - 1$, que vai de 0 (aleatório) a 1 (perfeito) — e ao lado da estatística **KS** (Kolmogorov-Smirnov), a maior distância vertical entre as curvas de distribuição acumulada dos escores de bons e maus pagadores, que equivale a $\max(\text{TPR} - \text{FPR})$ ao longo dos limiares. Um modelo de crédito com AUC 0,75 é apresentado como "Gini de 50"; KS acima de 40 é considerado bom para modelos de concessão. As três métricas medem a mesma coisa — separação entre as classes — em escalas diferentes.

5.2 Precisão-recall e average precision


A curva precisão-recall plota precisão contra recall ao longo dos limiares. Sua área é resumida pela **average precision** (AP):

$$\text{AP} = \sum_k (R_k - R_{k-1}) P_k$$

— a média das precisões em cada ponto em que o recall aumenta, ponderada pelo aumento. Diferente da ROC, a linha de base da curva PR **não** é fixa: um modelo aleatório tem precisão igual à prevalência em todos os níveis de recall, então AP de 0,10 é "aleatório" com 10% de positivos e ótima com 0,1% de positivos.

5.3 Por que a ROC é otimista quando a classe positiva é rara

Os dois eixos da ROC são taxas condicionadas à classe real (TPR sobre os positivos, FPR sobre os negativos), e por isso a curva **não muda** com a prevalência. Isso é uma vantagem (a ROC descreve o modelo, não a população) e uma armadilha (a ROC não mostra o que o usuário do modelo vai viver). Com 1% de positivos, uma FPR de 5% — que parece baixa no gráfico ROC — gera cinco falsos positivos para cada positivo real.




O mesmo modelo avaliado em três populações. A curva ROC é praticamente idêntica (AUC de 0,822 a 0,826); a curva precisão-recall despenca, com AP caindo de 0,82 (50% de positivos) para 0,40 (10%) e 0,10 (1%). As linhas pontilhadas são a precisão de um modelo aleatório.

NOTA

Nenhuma das duas é "a certa". ROC-AUC é ótima para comparar modelos entre populações e períodos (é estável), e para problemas em que as duas classes importam. PR-AUC é mais informativa quando a classe positiva é rara e é o foco — fraude, doença rara, busca —, porque reflete diretamente a experiência de quem recebe os alertas. Reportar as duas, com a prevalência ao lado, é o padrão mais honesto.

5.4 Curvas de ganho e lift

Em marketing e cobrança, a pergunta operacional é: "se eu contatar os x% clientes de maior escore, que fração dos positivos eu alcanço?". A **curva de ganho acumulado** responde exatamente isso, e o **lift** é a razão entre a taxa de positivos num segmento da lista ordenada e a taxa média da base.



Curva de ganho (esquerda) e lift por decil (direita) para o modelo de referência com 10% de positivos: os 20% de maior escore contêm 61% dos positivos, e o primeiro decil tem 4,2 vezes a taxa média.


NO MERCADO

"Lift de 4 no primeiro decil" é a frase que vende um modelo para uma diretoria de marketing: contatar os 10% de maior escore rende quatro vezes mais respostas por contato do que uma campanha aleatória. Convertida em custo por resposta, a curva de ganho vira diretamente o argumento financeiro do projeto — e define até onde descer na lista (o ponto em que a margem de mais um contato fica negativa).


6. Do score à decisão: o limiar

A curva ROC e a AUC avaliam o escore; em produção, porém, alguém precisa decidir "sim" ou "não". Três formas de escolher o limiar, em ordem crescente de conexão com o negócio:

- 1 **Otimizar uma métrica** — o limiar que maximiza F_1 , ou a estatística de Youden ($J = \text{TPR} - \text{FPR}$, o ponto da ROC mais distante da diagonal, que é também o KS). Fácil, mas arbitrário: F_1 supõe que precisão e recall valem o mesmo.
- 2 **Minimizar o custo esperado** — com custo C_{FP} por falso positivo e C_{FN} por falso negativo, e probabilidades **calibradas** (módulo 5), o limiar ótimo é $p^* = \frac{C_{FP}}{C_{FP} + C_{FN}}$ (a derivação completa está no tema 3, módulo de Dados Desbalanceados).
- 3 **Respeitar a capacidade** — quando só é possível agir sobre k casos (investigar 50 alertas, ligar para 2.000 clientes), o "limiar" é simplesmente o k -ésimo maior escore, e as métricas relevantes são precisão@ k e recall@ k (módulo de Detecção de Anomalias, tema 5).



Métricas do mesmo modelo em função do limiar. O F1 máximo acontece em 0,24, não em 0,5 (F1 de 0,43 contra 0,26); a acurácia quase não se mexe.



Custo médio por caso em função do limiar, com falso positivo a R10 e falso negativo a R 200. O mínimo empírico (0,043) fica colado no teórico (0,048); usar 0,5 custaria R17,20 por caso em vez de R 6,43.

ARMADILHA COMUM

Comparar modelos pela AUC e depois operar num limiar específico pode escolher o modelo errado. Dois modelos com curvas ROC que se cruzam têm AUCs parecidas, mas um deles pode ser muito melhor **na região da curva em que você vai operar** (por exemplo, com FPR abaixo de 1%, a única região aceitável para bloquear transações). Quando o ponto de operação é conhecido, compare os modelos **no ponto de operação** — pelo custo, ou por métricas como TPR a FPR fixa, ou pela AUC parcial.

7. Quão certo é o número? Incerteza e comparação

Toda métrica calculada num conjunto de teste é uma **estimativa** com erro-padrão — o livro dois do tema 4 mostrou isso para a acurácia. Duas ferramentas resolvem a maior parte dos casos:

Intervalo de confiança por bootstrap (tema 1, módulo 3): reamostre o conjunto de teste com reposição milhares de vezes, recalcule a métrica em cada reamostra e use os percentis 2,5% e 97,5% como intervalo de 95%. Funciona para qualquer métrica — inclusive F_1 , AUC e AP, que não têm fórmula simples de erro-padrão.

Teste de McNemar para comparar dois classificadores **no mesmo conjunto de teste**. O que importa são só os casos em que eles discordam:

FORMULARIO

Seja b o número de exemplos que o modelo 1 acerta e o modelo 2 erra, e c o contrário. Sob a hipótese de desempenho igual, b e c deveriam ser parecidos, e

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c}$$

segue aproximadamente uma qui-quadrado com 1 grau de liberdade (o -1 é a correção de continuidade). Com $b = 40$ e $c = 20$: $\chi^2 = 19^2/60 \approx 6,02$, p-valor $\approx 0,014$.

ARMADILHA COMUM

Comparar dois modelos com dois intervalos de confiança independentes ("os intervalos se sobrepõem, então não há diferença") ignora que os dois foram avaliados **nos mesmos exemplos** — seus erros são correlacionados, e a diferença entre eles é muito mais precisa do que cada métrica isolada. Testes pareados (McNemar para acertos, bootstrap pareado ou o teste de DeLong para AUC) exploram essa correlação e detectam diferenças que a comparação de intervalos não detecta.

8. Qual métrica para qual problema

Situação	Métrica principal	Por quê
Classes balanceadas, erros com custos parecidos	acurácia (e F1)	simples e informativa nesse caso
Classe positiva rara e é o foco (fraude, doença)	PR-AUC; precisão e recall no limiar	reflete a experiência de quem recebe os alertas
Comparar modelos entre períodos ou populações	ROC-AUC (Gini, KS)	estável à prevalência
Custos de erro conhecidos	custo esperado no limiar ótimo	é o que o negócio de fato paga
Capacidade de ação limitada	precisão@k, recall@k, lift	o limiar é o k-ésimo score
Multiclasse com classes raras importantes	F1 macro + tabela por classe	não deixa a classe grande esconder as pequenas
Probabilidades usadas diretamente (preço, risco)	log loss, Brier	premiar probabilidades calibradas (módulo 5)
Resumo escalar honesto para desbalanceado	MCC	só é alto se os quatro quadrantes vão bem

9. Erros que custam caro — checklist

- Reportar acurácia num problema desbalanceado sem mostrar o baseline de "sempre a classe majoritária".
- Reportar precisão ou F1 medidos numa prevalência diferente da de produção.
- Reportar F1 sem dizer qual é a classe positiva.
- Usar a média ponderada num multiclasse em que as classes raras são as que importam.
- Escolher modelos por ROC-AUC quando a classe positiva é rara e o foco — e se surpreender com a enxurrada de falsos positivos.
- Usar o limiar de 0,5 por padrão, sem olhar custo nem capacidade.
- Escolher o limiar olhando o conjunto de teste (o limiar é um hiperparâmetro: escolha na validação).
- Reportar uma métrica sem intervalo de confiança, e declarar um vencedor por uma diferença na terceira casa decimal.
- Comparar dois modelos com testes não pareados quando eles foram avaliados nos mesmos exemplos.

10. Para ir além

- Fawcett (2006), *An introduction to ROC analysis* — o tutorial de referência sobre curvas ROC.
- Saito & Rehmsmeier (2015), **The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets**.
- Chicco & Jurman (2020), **The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation**.
- Dietterich (1998), **Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms** — a origem da recomendação do teste de McNemar.
- Provost & Fawcett, *Data Science for Business*, capítulos 7 e 8 — curvas de lucro, ganho e lift com a lógica de negócio.