

Métricas de Regressão

Toda métrica de regressão é uma pergunta sobre a distribuição de y — a média, a mediana ou um quantil

Em regressão, escolher a métrica é escolher qual estatística da distribuição do alvo o modelo vai estimar: o erro quadrático leva à média, o absoluto à mediana, a perda pinball a um quantil, e o MAPE a uma previsão sistematicamente baixa. Este material cobre MAE, MSE e RMSE, MAPE e suas patologias, WAPE, RMSLE, R^2 e o que ele não diz, a robustez a outliers (Huber), a perda pinball e a regressão quantílica, o problema do jornaleiro (quanto estocar quando faltar e sobrar custam diferente), intervalos de previsão e sua cobertura, previsão conformal, e as deviances de Poisson e Tweedie para contagens e sinistros.

Nível: Intermediário

Pre-requisitos: Métricas de Classificação (módulo anterior); Estatística Descritiva e Robustez (tema 1); Regressão Linear (tema 4)

Carga sugerida: 8 a 10 horas (leitura + 2 notebooks)

Notebooks: 01-metricas-e-o-que-elas-punem · 02-erro-assimetrico-e-quantis · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. O catálogo básico	4
2.1 Um exemplo numérico	4
2.2 MAE, MSE e o que cada um estima	4
2.3 Outliers: o quadrado amplifica	5
3. MAPE e as métricas relativas	7
4. R^2: o que ele diz e o que ele não diz	8
5. Erro assimétrico e quantis	9
5.1 O problema do jornaleiro	9
5.2 Regressão quantílica e intervalos de previsão	9
5.3 Previsão conformal: cobertura garantida	10
6. Alvos de contagem e de valor: Poisson e Tweedie	12
7. Qual métrica para qual problema	13
8. Erros que custam caro — checklist	14
9. Para ir além	15

1. Por que este módulo existe

Em classificação, a pergunta "o modelo acertou?" tem resposta binária. Em regressão, todo modelo erra — a pergunta é **como** ele erra, e qual erro importa. Prever 50 unidades de um produto quando a demanda foi 60 é tão grave quanto prever 70? Errar 10 minutos numa entrega de 15 minutos é o mesmo que errar 10 minutos numa entrega de 2 horas? Um único erro de 100 é pior que dez erros de 10?

Cada métrica de regressão responde a essas perguntas de um jeito, e a consequência é mais profunda do que parece: **a métrica determina qual estatística da distribuição do alvo o modelo aprende a estimar**. Um modelo treinado com erro quadrático aprende a média condicional; com erro absoluto, a mediana condicional; com a perda pinball, um quantil. Não são detalhes de otimização — são produtos diferentes.

ANALOGIA

Pergunte a três pessoas "quanto tempo leva para chegar ao aeroporto?". A primeira responde com a média das viagens (40 minutos). A segunda, com o tempo típico (35 minutos, a mediana). A terceira, que já perdeu um voo, responde "saia com 70 minutos, porque em 9 de cada 10 viagens isso basta" (o quantil de 90%). As três respostas estão corretas — para perguntas diferentes. Uma métrica de regressão é a escolha da pergunta.

1.1 O que você vai conseguir fazer ao final

- Calcular e interpretar MAE, MSE, RMSE, MAPE, WAPE, RMSLE e R^2 , e dizer qual estatística do alvo cada uma premia.
- Reconhecer as patologias do MAPE e do R^2 antes que elas apareçam num relatório.
- Escolher uma perda robusta a outliers (Huber, absoluta) quando os dados têm erros de registro.
- Usar a perda pinball e a regressão quantílica para decisões com custos assimétricos, e resolver o problema do jornaleiro.
- Construir intervalos de previsão e verificar sua **cobertura** — com regressão quantílica e com previsão conformal.

2. O catálogo básico

Com $e_i = y_i - \hat{y}_i$ o resíduo do exemplo i :

FORMULARIO

$$\begin{aligned} \text{MAE} &= \frac{1}{n} \sum_i |e_i| & \text{MSE} &= \frac{1}{n} \sum_i e_i^2 & \text{RMSE} &= \sqrt{\text{MSE}} \\ \text{MAPE} &= \frac{100\%}{n} \sum_i \left| \frac{e_i}{y_i} \right| & \text{WAPE} &= \frac{\sum_i |e_i|}{\sum_i |y_i|} & R^2 &= 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2} \end{aligned}$$

2.1 Um exemplo numérico

Cinco lojas, demanda real $y = [100, 120, 80, 200, 50]$ e previsão $\hat{y} = [110, 115, 90, 150, 55]$. Os resíduos são $e = [-10, 5, -10, 50, -5]$.

- $\text{MAE} = (10 + 5 + 10 + 50 + 5)/5 = 16$.
- $\text{MSE} = (100 + 25 + 100 + 2.500 + 25)/5 = 550$, e

$$\text{RMSE} = \sqrt{550} \approx 23,5.$$

- $\text{MAPE} = (10\% + 4,2\% + 12,5\% + 25\% + 10\%)/5 \approx 12,3\%$.
- $\text{WAPE} = 80/550 \approx 14,5\%$.
- Com $\bar{y} = 110$, a soma dos quadrados total é

$$100 + 100 + 900 + 8.100 + 3.600 = 12.800, \text{ e } R^2 = 1 - 2.750/12.800 \approx 0,785.$$

Repare no RMSE: ele é quase 50% maior que o MAE porque um único erro (o de 50 unidades, na loja 4) responde por 91% da soma dos quadrados. A razão RMSE/MAE é um diagnóstico útil: perto de 1, os erros são parecidos entre si; muito acima de 1, poucos erros grandes dominam.

2.2 MAE, MSE e o que cada um estima


A pergunta-chave: se o modelo pudesse prever **uma única constante** c para todos os exemplos, qual c minimizaria cada métrica?

FORMULARIO

$$\arg \min_c \frac{1}{n} \sum_i (y_i - c)^2 = \bar{y} \text{ (a média)} \quad \arg \min_c \frac{1}{n} \sum_i |y_i - c| = \text{mediana}(y)$$

A primeira sai de derivar e igualar a zero (tema 1). A segunda: a derivada de $|y_i - c|$ é -1 ou $+1$ conforme y_i esteja acima ou abaixo de c , e a soma só zera quando há tantos pontos acima quanto abaixo — a mediana.

O mesmo vale **condicionalmente**: um modelo que minimiza o MSE estima $E[y | x]$; um que minimiza o MAE estima $\text{mediana}(y | x)$. Para alvos simétricos, as duas coincidem. Para alvos assimétricos — valores monetários, tempos, demandas, sinistros — elas se afastam, e a escolha da métrica muda a previsão.



Tempos de entrega com cauda longa à direita: a constante que minimiza cada métrica. MSE leva à média (40,3 min), MAE à mediana (34,7 min), MAPE a um valor abaixo da mediana (26,0 min) e a perda pinball de 90% ao quantil de 90% (70,1 min).

NO MERCADO

Em previsão de tempo de entrega, a escolha é explícita: o aplicativo que mostra ao cliente um tempo "típico" usa algo perto da mediana; o que promete um prazo que quase sempre é cumprido usa um quantil alto; o planejamento de frota, que precisa do total de horas, usa a média (a soma das médias é a média da soma — a soma das medianas não é a mediana da soma). Três modelos, três métricas, um mesmo alvo.

2.3 Outliers: o quadrado amplifica


Como o MSE eleva o resíduo ao quadrado, um erro 10 vezes maior pesa 100 vezes mais. Isso é desejável quando erros grandes são **de fato** muito mais graves (subestimar a carga de um servidor em 50% derruba o sistema) e indesejável quando os resíduos grandes vêm de **erros de registro**: o modelo distorce toda a previsão para acomodar alguns pontos que nem deveriam estar ali.

DEFINIÇÃO

A **perda de Huber** é quadrática para resíduos pequenos e linear para grandes, com a transição em δ :


$$L_{\delta}(e) = \frac{1}{2}e^2 \text{ se } |e| \leq \delta, \quad L_{\delta}(e) = \delta(|e| - \frac{\delta}{2}) \text{ caso contrário}$$

Combina a eficiência do MSE quando os erros são normais com a robustez do MAE quando há contaminação.



Dez registros com erro de digitação no fim da faixa. A reta de mínimos quadrados tem sua inclinação puxada de 2 para 1,10; Huber (1,89) e a regressão na mediana (1,92) praticamente os ignoram.

**Cada métrica pune o resíduo de um jeito: a quadrática explode nos erros grandes;
a pinball pune erro para baixo 9 vezes mais que error para cima**



As funções de perda em função do resíduo.

3. MAPE e as métricas relativas

O MAPE é popular por um bom motivo: é **adimensional** e fácil de comunicar ("erramos 12% em média"), permitindo comparar a qualidade da previsão de um produto que vende 10 unidades com a de um que vende 10.000. E tem três patologias sérias.

ARMADILHA COMUM

1. Divisão por zero e explosão perto de zero. Se algum $y_i = 0$ (um produto que não vendeu no dia), o MAPE é indefinido; se y_i é pequeno, um erro pequeno vira um percentual enorme. Em varejo, com milhares de itens de baixo giro, o MAPE da carteira pode ser dominado por itens que vendem 1 ou 2 unidades por semana.

2. Assimetria. Para um valor real fixo, errar para baixo tem um teto (prever 0 dá erro de 100%) e errar para cima, não. Com $y = 10$ e $\hat{y} = 30$, o erro é de 200%; com $y = 30$ e $\hat{y} = 10$, é de 67% — o mesmo erro absoluto de 20 unidades.

3. Viés para baixo. Por causa da assimetria, o MAPE premia previsões **baixas**: o valor constante que minimiza o MAPE é uma mediana ponderada por $1/y_i$, sistematicamente abaixo da mediana. Nos tempos de entrega da figura anterior, o ótimo do MAPE foi 26,0 minutos, contra uma mediana de 34,7. Um modelo otimizado para MAPE **subestima** — e numa previsão de demanda, isso significa ruptura de estoque.

Alternativas mais saudáveis:

- **WAPE** (ou MAD/média): $\sum |e_i| / \sum |y_i|$ — um MAE relativo ao

volume total. Não explode com y_i pequeno e é ponderado pelo volume, o que costuma ser o que o negócio quer. É o padrão de muitos times de demanda.

- **sMAPE**: divide por $(|y_i| + |\hat{y}_i|)/2$; reduz, mas não elimina, a assimetria, e continua instável perto de zero.

- **MASE** (erro absoluto escalado): divide o MAE pelo MAE de uma previsão ingênua (repetir o último valor). Será central no tema 7, Séries Temporais.

- **RMSLE**: o RMSE sobre $\log(1 + y)$. Mede erro **relativo** (prever 110 para 100 custa o mesmo que prever 1.100 para 1.000) e penaliza mais a subestimação que a superestimação do mesmo tamanho **absoluto** (com $y = 100$, prever 50 custa $\ln(101/51) \approx 0,68$; prever 150 custa $\ln(151/101) \approx 0,40$). Minimizar o RMSLE equivale a prever a média geométrica condicional (a média na escala log).


4. R^2 : o que ele diz e o que ele não diz

O R^2 compara o erro do modelo com o erro de uma previsão constante — a média de y . $R^2 = 0,785$ significa "o modelo reduz a soma dos quadrados dos erros em 78,5% em relação a prever sempre a média".

ARMADILHA COMUM

O R^2 não é uma medida de erro. Ele depende da variância de y na amostra: o mesmo modelo, com o mesmo erro típico, tem R^2 alto numa amostra heterogênea e baixo numa homogênea. Na figura abaixo, o modelo é o verdadeiro nos dois painéis e o RMSE é praticamente o mesmo (4,8 e 4,7); o R^2 cai de 0,97 para 0,61 só porque a faixa de x encolheu. Comparar R^2 entre bases diferentes, ou entre segmentos da mesma base, é comparar variâncias, não modelos.

O mesmo modelo, o mesmo erro típico: o R^2 muda só porque a faixa de x mudou



O mesmo modelo avaliado em duas faixas de x : o RMSE fica em torno de 4,7; o R^2 vai de 0,97 para 0,61.

Três outras observações que evitam leituras erradas:

- R^2 pode ser negativo fora da amostra de treino: basta o modelo

errar mais que a média — o que acontece com um modelo sobreajustado avaliado no teste.

- No teste, a referência deve ser a média do treino, não a do teste

(o `r2_score` do `scikit-learn` usa a média dos próprios dados passados a ele, o que dá ao baseline uma informação que ele não teria em produção).

- R^2 baixo não significa modelo inútil. Em finanças ou em

comportamento humano, um R^2 de 0,05 pode valer muito dinheiro; em física, um de 0,95 pode ser inaceitável. Reporte sempre o erro em unidades do problema (MAE, RMSE) ao lado do R^2 .

5. Erro assimétrico e quantis

Muitas decisões têm custos assimétricos: faltar produto na prateleira custa a margem perdida e o cliente irritado; sobrar custa o desperdício ou o capital parado. Não faz sentido prever a média nesses casos — faz sentido prever o quantil que equilibra os dois custos.

FORMULARIO

A **perda pinball** (ou perda quantílica) no nível τ :

$$L_{\tau}(y, q) = \tau(y - q) \text{ se } y \geq q, \quad L_{\tau}(y, q) = (1 - \tau)(q - y) \text{ se } y < q$$

Seu minimizador é o **quantil** τ da distribuição de y (condicional a x , quando é a perda de um modelo). Com $\tau = 0,5$, ela é metade do erro absoluto — e o minimizador é a mediana.

5.1 O problema do jornaleiro

Um jornaleiro compra jornais pela manhã sem saber a demanda do dia. Cada jornal que falta custa c_u (a margem perdida, *underage*); cada um que sobra custa c_o (o encalhe, *overage*). A quantidade ótima a comprar é o quantil da demanda no nível

$$\tau^* = \frac{c_u}{c_u + c_o}$$

— a mesma estrutura do limiar ótimo de classificação do módulo anterior.


Exemplo numérico. Uma padaria vende um pão especial com margem de R\$ 3 por unidade; cada pão que sobra no fim do dia é descartado, com custo de produção de R\$ 1. Então $\tau^* = 3/(3 + 1) = 0,75$: a padaria deve produzir o **percentil 75** da demanda prevista, não a média. Se a demanda do dia é aproximadamente normal com média 200 e desvio-padrão 30, isso dá $200 + 0,674 \times 30 \approx 220$ pães — 20 a mais que a média, porque faltar custa três vezes mais que sobrar.

NO MERCADO

Essa é a lógica central do planejamento de estoques no varejo, da escala de funcionários em call centers (subdimensionar custa clientes na fila; superdimensionar, salários ociosos) e do provisionamento de servidores em nuvem. Um time que treina o modelo de demanda com MSE e depois usa a previsão diretamente como pedido de compra está resolvendo o problema errado — está pedindo a média quando o custo pede um quantil.

5.2 Regressão quantílica e intervalos de previsão

Treinar um modelo com a perda pinball no nível τ produz uma estimativa do quantil condicional $q_{\tau}(x)$. Treinar dois — em $\tau = 0,1$ e $\tau = 0,9$ — produz um **intervalo de previsão** de 80%: a faixa em que, idealmente, 80% dos valores reais cairão. No `scikit-learn`, `GradientBoostingRegressor(loss="quantile", alpha= $\tau$ )`, `HistGradientBoostingRegressor(loss="quantile", quantile= $\tau$ )` e `QuantileRegressor` (linear) fazem isso.



Regressão quantílica com ruído que cresce com x: a faixa entre os quantis de 10% e 90% se alarga onde a incerteza é maior. A cobertura observada foi de 80,1%.

A diferença para um intervalo "média $\pm$ 2 desvios-padrão" é que a regressão quantílica não supõe que o erro seja normal nem que tenha a mesma variância em todo lugar (homocedasticidade, tema 4): o intervalo se adapta à incerteza local.

ARMADILHA COMUM

Um intervalo de previsão só vale se sua **cobertura** for a prometida — e ela deve ser medida **fora da amostra**. Modelos quantílicos flexíveis tendem a produzir intervalos estreitos demais no teste (cobertura de 70% quando se prometeu 80%), pelo mesmo motivo que qualquer modelo parece melhor no treino. Avalie sempre duas coisas: a cobertura empírica no teste e a largura média do intervalo. Um intervalo largo o bastante sempre cobre; a arte é cobrir com a menor largura.

5.3 Previsão conformal: cobertura garantida

A **previsão conformal** (Vovk et al., 2005; Angelopoulos & Bates, 2021) transforma qualquer modelo num gerador de intervalos com cobertura garantida, sem supor distribuição nenhuma. A versão mais simples, a **conformal por divisão**:

- 1 Treine o modelo num conjunto de treino.
- 2 Num conjunto de **calibração** separado, calcule os resíduos absolutos $r_i = |y_i - \hat{y}_i|$.
- 3 Tome $\hat{q}$ como o quantil $[(n + 1)(1 - \alpha)]/n$ desses resíduos.
- 4 Para um ponto novo, o intervalo é $[\hat{y} - \hat{q}, \hat{y} + \hat{q}]$.

Se os dados de calibração e os novos são permutáveis (grosso modo, vêm da mesma distribuição), a cobertura é de **pelo menos** $1 - \alpha$ — uma garantia de amostra finita, não assintótica. A versão acima dá intervalos de largura constante; a **regressão quantílica conformalizada** (CQR) combina as duas ideias: usa os quantis de um modelo quantílico e os corrige com os resíduos de calibração, obtendo intervalos adaptativos e com cobertura garantida. O notebook [02-erro-assimetrico-e-quantis](#) implementa as duas.

6. Alvos de contagem e de valor: Poisson e Tweedie

Quando o alvo é uma **contagem** (número de chamados, de sinistros, de itens vendidos) ou um **valor com muitos zeros** (valor de sinistro por apólice: a maioria é zero, alguns são enormes), o MSE trata mal o problema: supõe variância constante, quando a variância de uma contagem cresce com a média.

- A **deviance de Poisson** é a perda natural para contagens (variância proporcional à média) — `loss="poisson"` no `HistGradientBoostingRegressor`.

• A **deviance Tweedie**, com potência entre 1 e 2, modela uma massa em zero seguida de uma cauda contínua positiva — o padrão de sinistros de seguros, e o modelo de prêmio puro da indústria de seguros (Poisson para a frequência × Gama para a severidade, numa só distribuição).

Essas deviances também são métricas: `mean_poisson_deviance` e `mean_tweedie_deviance` no `scikit-learn`. Comparar modelos de contagem pelo MSE favorece quem acerta os valores grandes e ignora o comportamento nos pequenos, que são a maioria.

7. Qual métrica para qual problema

Situação	Métrica	Estatística estimada
Custo proporcional ao erro, sem assimetria	MAE	mediana
Erros grandes são desproporcionalmente graves	RMSE / MSE	média
Dados com erros de registro que não se pode limpar	Huber, MAE	robusta
Comparar itens de escalas diferentes	WAPE, MASE	—
Erro relativo importa (preços, volumes com várias ordens de grandeza)	RMSLE	média geométrica
Custo de faltar difere do custo de sobrar	pinball no nível $c_u/(c_u+c_o)$	quantil
Intervalo de previsão	cobertura + largura (pinball nos dois quantis)	par de quantis
Contagens, sinistros	deviance Poisson / Tweedie	média condicional com variância adequada
Comunicar "quanto do fenômeno o modelo explica"	R^2 (ao lado de MAE/RMSE)	—

NOTA

Treine e avalie com a **mesma** métrica, ou pelo menos com métricas coerentes. Um modelo treinado com MSE (que estima a média) e avaliado com MAE (que premia a mediana) será julgado por um critério que ele não tentou otimizar — e pode perder para um modelo pior que foi treinado com MAE. O notebook [01-metricas-e-o-que-elas-punem](#) mostra cada modelo vencendo nas métricas cuja estatística ele estima: os modelos de média no RMSE, o de mediana no MAE, o de quantil na pinball.

8. Erros que custam caro — checklist

- Reportar só o R^2 , sem o erro em unidades do problema.
- Comparar R^2 entre bases ou segmentos com variâncias diferentes.
- Usar MAPE com alvos que podem ser zero ou muito pequenos.
- Otimizar MAPE numa previsão de demanda e descobrir a ruptura de estoque depois — o MAPE puxa as previsões para baixo.
- Usar a previsão da média como decisão quando o custo de errar para cima e para baixo é diferente.
- Treinar com MSE em dados com erros de registro grosseiros.
- Prometer um intervalo de 90% sem medir sua cobertura fora da amostra.
- Avaliar um modelo de contagem ou de sinistros pelo MSE.
- Treinar com uma perda e avaliar com outra sem perceber que elas estimam estatísticas diferentes.

9. Para ir além

- Hyndman & Koehler (2006), **Another look at measures of forecast accuracy** — a crítica clássica ao MAPE e a proposta do MASE.
- Gneiting (2011), *Making and Evaluating Point Forecasts* — a teoria de qual métrica corresponde a qual estatística (funções de perda "consistentes").
- Koenker, *Quantile Regression* — o livro-texto de regressão quantílica.
- Angelopoulos & Bates (2021), **A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification**.
- Romano, Patterson & Candès (2019), *Conformalized Quantile Regression*.