

Validação Cruzada

O que a validação cruzada realmente estima, com que precisão — e as mil formas de ela mentir

A validação cruzada é a ferramenta mais usada para estimar o desempenho de um modelo, e uma das mais mal compreendidas. O livro dois do tema 4 apresentou o K-Fold e suas variantes; este módulo aprofunda o que a CV de fato estima (o desempenho médio do procedimento de treino, não o do seu modelo específico), o trade-off entre viés, variância e custo na escolha de K, por que o erro-padrão ingênuo entre folds subestima a incerteza e como comparar dois modelos com o teste t corrigido de Nadeau e Bengio, como escolher o esquema de divisão a partir da estrutura dos dados (estratos, grupos, tempo), o otimismo do melhor score de CV (a maldição do vencedor) e a validação aninhada que o corrige, e um catálogo de vazamentos na validação — incluindo o experimento clássico em que a seleção de atributos fora da CV produz 98% de acurácia em ruído puro.

Nível: Intermediário/Avançado

Pre-requisitos: Métricas de Classificação e de Regressão (módulos anteriores); livro dois do tema 4 (teoria-avancada.pdf); Encoding, Escala e Vazamento (tema 3)

Carga sugerida: 10 a 12 horas (leitura + 3 notebooks)

Notebooks: 01-esquemas-de-validacao · 02-validacao-aninhada · 03-vazamento-na-validacao · 99-exercicios

Autoria: Material do curso de ML & DL

Versao: 1.0

Sumário

1. Por que este módulo existe	3
1.1 O que você vai conseguir fazer ao final	3
2. O que a validação cruzada estima	4
3. Escolhendo K: viés, variância e custo	6
4. A incerteza da estimativa e a comparação de modelos	8
4.1 O teste t corrigido para CV	8
5. A divisão tem de imitar a produção	9
5.1 Estratos	9
5.2 Grupos	10
5.3 Tempo	10
6. A maldição do vencedor e a validação aninhada	11
7. Vazamento na validação	13
7.1 O experimento de Ambroise e McLachlan	13
7.2 Catálogo de vazamentos na validação	14
8. Depois da CV: qual é o modelo final?	15
9. Erros que custam caro — checklist	16
10. Para ir além	17

1. Por que este módulo existe

O livro dois do tema 4 ([teoria-avancada.pdf](#)) já mostrou a mecânica: um único `train_test_split` é uma loteria, e o K-Fold substitui a loteria pela média de K avaliações. Também apresentou as variantes — estratificada, por grupos, temporal, aninhada. Este módulo parte daí e trata das perguntas que a mecânica não responde:

- O número que a validação cruzada devolve é uma estimativa **de quê**, exatamente?
- Quão **precisa** é essa estimativa — e por que o desvio-padrão entre os folds engana?
- Como **comparar** dois modelos pela CV sem declarar vencedores por acaso?
- Quando o esquema de divisão está errado para os dados — e como descobrir antes que a produção descubra?
- Quais são as formas, algumas muito sutis, de a CV **vazar** informação e inflar o resultado?

ANALOGIA

Validação cruzada é um ensaio geral. Uma orquestra que ensaia a sinfonia inteira cinco vezes, com públicos diferentes, tem uma boa ideia de como será a estreia. Mas o ensaio só prevê a estreia se imitar as condições dela: se nos ensaios os músicos puderem ler a partitura e na estreia tiverem de tocar de cor, o ensaio mede outra coisa. Toda falha de validação deste módulo é, no fundo, um ensaio que não imitou a estreia — um fold de validação com informação que o modelo não terá em produção.

1.1 O que você vai conseguir fazer ao final

- Explicar o que a CV estima e por que isso não é o erro do modelo final.
- Escolher K pelo trade-off entre pessimismo, variância e custo.
- Comparar dois modelos com o teste t corrigido para CV, em vez de com o erro-padrão ingênuo entre folds.
- Escolher o esquema de divisão a partir de uma única regra — imitar a separação entre treino e produção — e aplicá-la a estratos, grupos e tempo.
- Reconhecer o otimismo do melhor escore após o tuning e corrigi-lo com validação aninhada.
- Auditar um pipeline de validação contra os vazamentos mais comuns.

2. O que a validação cruzada estima


Vale separar duas quantidades que costumam ser confundidas:

- Err_{XY} : o erro de generalização do **modelo específico** que você treinou com a **sua** amostra de treino.
- Err : o erro **médio** do procedimento de treino — a média de

Err_{XY} sobre todas as amostras de treino possíveis do mesmo tamanho, tiradas da mesma população.

Intuitivamente, espera-se que a CV estime o primeiro: "quão bom é **este** modelo?". Um resultado importante (Bates, Hastie & Tibshirani, 2023) mostra que ela estima, na verdade, o **segundo** — e muito mal o primeiro.

O experimento da figura abaixo. De uma população fixa, sorteamos 150 amostras de 80 observações. Em cada uma, treinamos uma regressão logística e medimos (1) o erro **real** do modelo treinado com as 80 observações, numa base de teste enorme, e (2) as estimativas de CV com $K = 2, 5, 10$ e com *leave-one-out* (LOO). O erro real médio foi 0,289, com desvio-padrão de apenas 0,013 entre as amostras. As estimativas de CV com $K = 10$ acertaram a média (0,285), mas com desvio-padrão de **0,048** — quase quatro vezes maior que a variação do erro real — e correlação de apenas **0,15** com o erro real de cada amostra.



Distribuição, em 150 amostras de $n = 80$, do erro real do modelo final e das estimativas de CV. $K=2$ é pessimista (média 0,310 contra 0,289 real); $K=5$, $K=10$ e LOO acertam a média, mas cada estimativa individual tem um ruído muito maior que a variação do próprio erro real.

NOTA

A leitura prática: a CV é uma ótima ferramenta para responder "este **procedimento** (este algoritmo, com estes hiperparâmetros, neste tipo de dado e com este tamanho de amostra) funciona bem?". É uma ferramenta fraca para responder "este **modelo específico** é melhor que a média dos modelos que eu poderia ter obtido?". Com amostras pequenas, o ruído da estimativa domina — e duas CVs na mesma base, com sementes diferentes, podem discordar mais do que dois modelos diferentes discordam entre si.

3. Escolhendo K: viés, variância e custo

Com K folds, cada modelo é treinado com uma fração $(K - 1)/K$ dos dados. Três forças disputam a escolha:

- **Viés (pessimismo).** Modelos treinados com menos dados erram mais. Com

$K = 2$, cada modelo vê só metade dos dados, e a CV **superestima** o erro — na figura, 0,310 contra 0,289. O pessimismo diminui com K e é maior quando a curva de aprendizado (módulo 4) ainda está subindo.

- **Variância.** A média de K avaliações é mais estável que uma

avaliação única, mas os K modelos compartilham dados de treino (com $K = 10$, dois modelos quaisquer compartilham 8/9 das observações), e por isso seus erros são correlacionados — a média de avaliações correlacionadas reduz menos a variância do que $1/K$ sugere.

- **Custo.** K treinos. Com LOO, n treinos.

NOTA

A fama de que LOO tem "variância alta" vale para modelos **instáveis** (árvores profundas, k-NN com k pequeno), em que os n modelos quase idênticos respondem de forma errática aos pontos deixados de fora. Para modelos estáveis, como a logística do experimento, LOO teve até a menor variância (0,046). O argumento decisivo contra LOO costuma ser o **custo** — e o fato de que, para seleção de modelos, $K = 5$ ou $K = 10$ dão resultados equivalentes por uma fração do custo.

K	Pessimismo	Variância	Custo	Uso típico
2-3	alto	alta	baixo	bases muito grandes, modelos caros
5	pequeno	moderada	5 treinos	padrão para seleção de modelos
10	muito pequeno	moderada	10 treinos	padrão para estimar desempenho
LOO (n)	quase nulo	depende da estabilidade	n treinos	bases minúsculas; modelos com atalho analítico (regressão linear, ridge)
K repetido r vezes	igual ao do K	menor (média de r CVs)	r·K treinos	reduzir o ruído da partição, comparar modelos

NO MERCADO

A repetição (`RepeatedKFold`, `RepeatedStratifiedKFold`) é o ajuste mais barato e mais subutilizado: 5 repetições de 5-fold custam 25 treinos e eliminam boa parte da "sorte da partição". Se dois modelos trocam de posição quando se muda a semente do K-Fold, a comparação não estava decidida — e a repetição mostra isso antes de alguém tomar uma decisão com base num único sorteio.

4. A incerteza da estimativa e a comparação de modelos

É tentador reportar "acurácia de $0,85 \pm 0,02$ ", com o $\pm$ sendo o desvio-padrão dos K escores divididos por $\sqrt{K}$ — o erro-padrão de uma média de K observações independentes. O problema é o "independentes": os escores dos folds não são independentes, porque os modelos compartilham dados de treino. Esse erro-padrão ingênuo **subestima** a incerteza real, e Bengio & Grandvalet (2004) mostraram que não existe estimador não viesado da variância da CV a partir de uma única execução.

4.1 O teste t corrigido para CV

Para comparar dois modelos A e B avaliados nos **mesmos** folds, olha-se a diferença de desempenho em cada fold, d_j ($j = 1, \dots, J$, com J o total de avaliações — por exemplo $J = 50$ em 5 repetições de 10-fold). O teste t pareado ingênuo usa o erro-padrão $s_d/\sqrt{J}$. Nadeau & Bengio (2003) propuseram uma correção que aproxima o efeito da sobreposição entre conjuntos de treino:

FORMULARIO

Teste t corrigido para reamostragem, com n_{te} e n_{tr} os tamanhos dos conjuntos de teste e de treino de cada fold:

$$t = \frac{\bar{d}}{\sqrt{(\frac{1}{J} + \frac{n_{te}}{n_{tr}})s_d^2}}$$

comparado com uma t de Student com $J - 1$ graus de liberdade. O termo $n_{te}/n_{tr} - 1/9$ em 10-fold — é a correção: ele **não diminui** com J , o que impede que repetir a CV muitas vezes fabrique significância.


Exemplo numérico. Em 10-fold ($J = 10$, $n_{te}/n_{tr} = 1/9$), o modelo A supera o B por $\bar{d} = 0,012$ de acurácia em média, com desvio-padrão das diferenças $s_d = 0,020$. O teste ingênuo dá $t = 0,012/(0,020/\sqrt{10}) \approx 1,90$ (p-valor bilateral perto de 0,09). O corrigido dá $t = 0,012/\sqrt{(0,1 + 0,111) \times 0,0004} \approx 1,31$ (p-valor perto de 0,22). A diferença, que parecia "quase significativa", está bem dentro do ruído.

ARMADILHA COMUM

Repetir o K-Fold 100 vezes e aplicar o teste t ingênuo aos 1.000 escores é uma forma garantida de encontrar significância para qualquer diferença, por menor que seja: com $J = 1.000$, o erro-padrão ingênuo encolhe como $1/\sqrt{1000}$, mas a incerteza real — que vem de ter **uma única** amostra de dados — não encolhe. A repetição reduz o ruído da **partição**, não o ruído da **amostra**. O termo n_{te}/n_{tr} do teste corrigido existe exatamente para isso.

5. A divisão tem de imitar a produção

Uma única regra resolve quase todos os casos: **a separação entre treino e validação deve reproduzir a separação entre os dados de treino e os dados que o modelo verá em produção**. As variantes de K-Fold são aplicações dessa regra a estruturas diferentes de dados.



Quatro esquemas de divisão em 5 folds. O estratificado garante a mesma proporção da classe rara em cada fold; o por grupos mantém todas as observações de um grupo do mesmo lado; o temporal só valida com dados posteriores ao treino.

5.1 Estratos

Com uma classe rara, um fold pode receber, por azar, poucos exemplos positivos — e a métrica daquele fold vira ruído puro. **StratifiedKFold** reparte a classe rara igualmente entre os folds. Em regressão, pode-se estratificar por faixas (quantis) do alvo. Não há motivo para **não** estratificar em classificação.

5.2 Grupos

Quando as observações vêm em grupos — várias consultas do mesmo paciente, várias compras do mesmo cliente, vários dias da mesma loja, várias fotos do mesmo objeto —, a pergunta de produção costuma ser: "como o modelo se sai num paciente (cliente, loja) **novo**". Um K-Fold comum espalha as observações de cada grupo entre treino e validação, e o modelo é validado em pacientes que ele **já viu**. Se o grupo tem características próprias (a fisiologia de um paciente, o hábito de um cliente), o modelo aprende a reconhecer o grupo, não o fenômeno — e a CV premia isso.

ARMADILHA COMUM

O sintoma clássico: CV com K-Fold comum excelente, CV com `GroupKFold` muito pior, e produção parecida com a segunda. O notebook [01-esquemas-de-validacao](#) constrói um caso com pacientes em que a diferença é dramática. Se existe uma coluna de identidade (paciente, cliente, dispositivo, loja) e a produção vai lidar com identidades novas, `GroupKFold` (ou `StratifiedGroupKFold`) não é opcional.

5.3 Tempo

Se o modelo vai prever o futuro a partir do passado, a validação precisa fazer o mesmo: treinar com dados até uma data e validar com dados **posteriores**. `TimeSeriesSplit` implementa a janela expansiva (cada fold treina com tudo até um ponto e valida no bloco seguinte). Dois refinamentos importantes:

- ****Intervalo (gap)****: deixar um espaço entre o fim do treino e o início

da validação quando o rótulo demora a ser conhecido (um alvo de "churn nos próximos 90 dias" só é conhecido 90 dias depois) ou quando features usam janelas que atravessariam a fronteira.

- **Embargo e purga** (finanças, López de Prado): remover do treino as observações cujo rótulo se sobrepõe no tempo às da validação.


O tema 7 (Séries Temporais) aprofunda a validação com origem móvel.

NOTA

Estruturas podem se combinar: dados de clientes ao longo do tempo pedem validação por grupo e por tempo — clientes novos, em datas futuras. Quando nenhum esquema pronto serve, escreva o seu: um gerador de pares (`índices_treino`, `índices_validação`) pode ser passado diretamente como `cv=` para qualquer função do `scikit-learn`.

6. A maldição do vencedor e a validação aninhada

Ao testar muitas configurações e escolher a de melhor escore de CV, o escore do vencedor é uma estimativa **otimista** do seu desempenho real. Não por vazamento de dados, mas por **seleção**: entre muitas estimativas ruidosas, a maior tende a ser uma das que o ruído empurrou para cima — o mesmo fenômeno das comparações múltiplas do tema 1.



M configurações com exatamente o mesmo desempenho real (0,80) e ruído de CV de 0,02. O melhor escore observado é, em média, 0,031 acima do real com 10 configurações e 0,050 acima com 100.

FORMULARIO

Se M configurações têm o mesmo desempenho real μ e as estimativas de CV têm ruído aproximadamente normal com desvio σ , o valor esperado do máximo é aproximadamente

$$E[\max] \approx \mu + \sigma \sqrt{2 \ln M}$$

(uma aproximação assintótica, que superestima um pouco para M pequeno). Com $\sigma = 0,02$ e $M = 100$, o otimismo previsto é da ordem de $0,02 \times 3,03 \approx 0,06$; a simulação da figura dá 0,050.

A correção é a **validação aninhada**: um laço **externo** de CV estima o desempenho, e, dentro de cada fold externo, um laço **interno** de CV escolhe os hiperparâmetros usando só os dados de treino daquele fold. O fold externo de validação nunca participa da escolha, e a média dos escores externos estima o desempenho do **procedimento completo** — "treinar com busca de hiperparâmetros" —, sem o otimismo da seleção.

```
from sklearn.model_selection import GridSearchCV, cross_val_score, KFold

busca = GridSearchCV(modelo, grade, cv=KFold(5, shuffle=True, random_state=1))
escores_externos = cross_val_score(busca, X, y, cv=KFold(5, shuffle=True, random_state=2))
# escores_externos.mean(): desempenho honesto do procedimento "modelo + tuning"
```

ARMADILHA COMUM

O custo é multiplicativo: 5 folds externos × 5 internos × 50 configurações = 1.250 treinos. Duas saídas práticas: usar a validação aninhada só para o **relatório** final (o tuning do dia a dia pode ser simples), ou reservar um conjunto de **teste** que só é tocado uma vez, no fim — que é uma validação aninhada com um único fold externo. O que não se pode é reportar o melhor escore do `GridSearchCV` como estimativa de desempenho.


7. Vazamento na validação

Vazamento é qualquer caminho pelo qual o fold de validação influencia o modelo que será avaliado nele. O tema 3 (módulo 4) tratou do vazamento no pré-processamento; na validação cruzada ele ganha formas novas, porque o fluxo de dados passa por muitas etapas repetidas.

7.1 O experimento de Ambroise e McLachlan

Em 2002, Ambroise & McLachlan mostraram que vários estudos de expressão gênica publicados relatavam classificadores com erro quase zero... em dados que, analisados corretamente, não tinham sinal suficiente para isso. O padrão era sempre o mesmo: selecionar os genes mais associados ao rótulo **usando todas as amostras**, e só depois fazer a CV com os genes selecionados.

A figura reproduz o experimento com **ruído puro**: 50 amostras, 5.000 atributos sem nenhuma relação com o rótulo. Selecionando os k atributos mais "associados" ao rótulo antes da CV, a acurácia estimada chega a **0,98**. Com a seleção feita dentro de cada fold (num **Pipeline**), a estimativa fica em torno de 0,5 — o acaso, que é a verdade.



Acurácia estimada pela CV em dados de ruído puro, em função do número de atributos selecionados: com a seleção antes da CV, 0,78 a 1,0; dentro de cada fold, em torno de 0,5.

NOTA

Por que funciona tão bem para enganar? Com 5.000 atributos de ruído e 50 amostras, alguns atributos se correlacionam com o rótulo **por puro acaso** — nessa amostra específica. Selecioná-los com todos os rótulos embute nos atributos escolhidos a informação dos rótulos de validação. O classificador depois "descobre" exatamente o padrão que a seleção plantou.

7.2 Catálogo de vazamentos na validação

Vazamento	Como acontece	Tamanho típico	Correção
Pré-processamento global	escalar, imputar ou reduzir dimensão com a base inteira	pequeno	tudo dentro de um <i>Pipeline</i>
Seleção de atributos global	escolher atributos pela associação com y na base inteira	enorme com p grande e n pequeno	seleção dentro do <i>Pipeline</i>
Target encoding global	média do alvo por categoria calculada com a base inteira	grande com categorias raras	encoder dentro do <i>Pipeline</i> (com CV interna)
Reamostragem antes do split	SMOTE ou oversampling antes de dividir	grande	reamostrar só no treino de cada fold (tema 3)
Duplicatas e quase-duplicatas	a mesma entidade em treino e validação	de pequeno a enorme	deduplicar; validar por grupo
Grupo	observações do mesmo paciente/cliente dos dois lados	grande	GroupKFold
Tempo	features ou rótulos com informação posterior à data de previsão	enorme	TimeSeriesSplit, gap, auditoria de features
Tuning no teste	escolher hiperparâmetros (ou o limiar) olhando o teste	moderado, cresce com o nº de tentativas	validação aninhada; teste tocado uma vez

NO MERCADO

Numa competição de dados famosa sobre câncer de pulmão, as imagens de um mesmo paciente apareciam várias vezes na base, e o identificador do paciente — ou até propriedades do equipamento do hospital de origem — permitia "prever" o diagnóstico sem olhar o tumor. Casos parecidos se repetem na indústria: um modelo de risco de crédito que usa "número de contatos da cobrança" (que só acontecem **depois** do atraso) ou um modelo de churn que usa "motivo do cancelamento". O teste mais eficaz contra esse tipo de vazamento é humano: para cada feature, perguntar **"no instante da previsão, eu teria esse valor?"**.

8. Depois da CV: qual é o modelo final?

A CV treina K modelos e os descarta. O modelo que vai para produção é, em geral, **re-treinado com todos os dados** usando o procedimento validado (algoritmo e hiperparâmetros escolhidos). O escore da CV é a estimativa de desempenho **desse procedimento** — ligeiramente pessimista, porque o modelo final vê mais dados que cada modelo dos folds.

Duas alternativas legítimas: usar os K modelos dos folds como um **ensemble** (média das previsões), prática comum em competições; ou, com dados temporais, re-treinar com a janela mais recente, que é a mais parecida com a produção.

9. Erros que custam caro — checklist

- Tratar o escore de CV como o desempenho do seu modelo específico, e não do procedimento.
- Reportar o desvio-padrão entre folds dividido por $\sqrt{K}$ como erro-padrão.
- Comparar modelos com o teste t ingênuo sobre muitos folds repetidos.
- Declarar um vencedor sem verificar se ele se mantém com outra semente de partição.
- Usar K-Fold comum com observações agrupadas por entidade, quando a produção lida com entidades novas.
- Usar K-Fold embaralhado em dados com ordem temporal.
- Reportar o melhor escore de uma busca de hiperparâmetros como estimativa de desempenho.
- Selecionar atributos, codificar alvos ou reamostrar fora da CV.
- Usar features que não existiriam no instante da previsão.

10. Para ir além

- Bates, Hastie & Tibshirani (2023), **Cross-validation: what does it estimate and how well does it do it?** — a origem da distinção entre Err e Err_{XY} , e da validação aninhada para intervalos.
- Nadeau & Bengio (2003), *Inference for the Generalization Error* — o teste t corrigido.
- Bengio & Grandvalet (2004), **No Unbiased Estimator of the Variance of K-Fold Cross-Validation**.
- Ambroise & McLachlan (2002), **Selection bias in gene extraction on the basis of microarray gene-expression data**.
- Cawley & Talbot (2010), **On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation** — a referência sobre validação aninhada.
- Kaufman, Rosset & Perlich (2012), **Leakage in Data Mining: Formulation, Detection, and Avoidance**.